



电子科技
Electronic Science and Technology
ISSN 1007-7820, CN 61-1291/TN

《电子科技》网络首发论文

题目: 使用多策略改进的哈里斯鹰优化算法
作者: 徐天宇, 单志勇
DOI: 10.16180/j.cnki.issn1007-7820.2026.08.003
收稿日期: 2024-09-24
网络首发日期: 2025-09-02
引用格式: 徐天宇, 单志勇. 使用多策略改进的哈里斯鹰优化算法[J/OL]. 电子科技.
<https://doi.org/10.16180/j.cnki.issn1007-7820.2026.08.003>



网络首发: 在编辑部工作流程中, 稿件从录用到出版要经历录用定稿、排版定稿、整期汇编定稿等阶段。录用定稿指内容已经确定, 且通过同行评议、主编终审同意刊用的稿件。排版定稿指录用定稿按照期刊特定版式(包括网络呈现版式)排版后的稿件, 可暂不确定出版年、卷、期和页码。整期汇编定稿指出版年、卷、期、页码均已确定的印刷或数字出版的整期汇编稿件。录用定稿网络首发稿件内容必须符合《出版管理条例》和《期刊出版管理规定》的有关规定; 学术研究成果具有创新性、科学性和先进性, 符合编辑部对刊文的录用要求, 不存在学术不端行为及其他侵权行为; 稿件内容应基本符合国家有关书刊编辑、出版的技术标准, 正确使用和统一规范语言文字、符号、数字、外文字母、法定计量单位及地图标注等。为确保录用定稿网络首发的严肃性, 录用定稿一经发布, 不得修改论文题目、作者、机构名称和学术内容, 只可基于编辑规范进行少量文字的修改。

出版确认: 纸质期刊编辑部通过与《中国学术期刊(光盘版)》电子杂志社有限公司签约, 在《中国学术期刊(网络版)》出版传播平台上创办与纸质期刊内容一致的网络版, 以单篇或整期出版形式, 在印刷出版之前刊发论文的录用定稿、排版定稿、整期汇编定稿。因为《中国学术期刊(网络版)》是国家新闻出版广电总局批准的网络连续型出版物(ISSN 2096-4188, CN 11-6037/Z), 所以签约期刊的网络版上网络首发论文视为正式出版。

doi:10.16180/j.cnki.issn1007-7820.2026.08.003

使用多策略改进的哈里斯鹰优化算法

徐天宇, 单志勇

(东华大学 信息科学与技术学院, 上海 201620)

摘要: 针对哈里斯鹰算法易于陷入局部最优且寻优精度不高问题, 文中提出了一种多策略改进的哈里斯鹰优化算法。在经典哈里斯鹰算法的基础上利用 Circle 混沌映射对种群进行初始化, 以此提升初始种群的多样性。采用一种非线性能量因子的更新方式较好地平衡所提算法的开发与探索过程。将柯西变异权重设为特定区间内的随机变量, 该区间随迭代次数增加而变小, 从而提升了种群在前期阶段的探索能力和后期阶段的搜索能力。引入一种基于正交设计的学习策略产生新个体作为学习对象, 并在每次迭代结束前随机选择一个个体执行该策略, 从而进一步提升所提算法的寻优能力。仿真实验结果表明, 所提改进算法具有更高的寻优精度和较快的寻优速度, 明显优于其他对比算法, 在实际工程问题中具有较好的应用前景。

关键词: 哈里斯鹰算法; 寻优精度; 多策略; Circle 混沌映射; 非线性能量因子; 柯西变异权重; 正交设计; 学习策略

中图分类号: TP301.6

文献标识码: A

An Improved Harris Hawk Optimization Algorithm Using Multiple Strategies

XU Tianyu, SHAN Zhiyong

(College of Information Science and Technology, Donghua University, Shanghai 201620, China)

Abstract: In view of the problems that the Harris hawks optimization is prone to fall into local optimum and has low optimization accuracy, a multi-strategy improved Harris hawks optimization is proposed. Based on the classic Harris hawks optimization, the circle chaotic mapping is utilized to initialize the population, thereby enhancing the diversity of the initial population. A nonlinear energy factor update method is adopted to better balance the development and exploration process of the proposed algorithm. The Cauchy variation weight is set as a random variable within a specific interval, which decreases as the number of iterations increases, thereby enhancing the population's exploration ability in the early stage and search ability in the later stage. A learning strategy based on orthogonal design is introduced to generate new individuals as learning objects, and an individual is randomly selected to execute this strategy before the end of each iteration, thereby further enhancing the optimization ability of the proposed algorithm. The simulation experiment results show that the proposed improved algorithm has higher optimization accuracy and faster optimization speed, which is significantly better than other comparison algorithms and has a good application prospect in practical engineering problems.

Keywords: Harris hawks optimization; optimization accuracy; multi-strategy; Circle chaotic mapping; nonlinear energy factor; weight of Cauchy mutation; orthogonal design; learning strategy

群智能优化算法作为启发式算法的重要分支, 得到了研究者的广泛关注, 在其发展过程中研究者还提出了粒子群算法^[1]、蝙蝠算法^[2]、象群算法^[3]

等优化算法。哈里斯鹰优化算法(Harris Hawk Optimization, HHO)是一种基于种群的优化方法, 广泛应用于任务调度^[4]、参数提取^[5]、阵列天线方向

图赋形^[6]等领域。该算法应具有参数简洁、搜索精度高、操作简便等优势,但存在收敛速度慢、寻优精度低、易陷入局部最优等缺点。

文献[7]通过周期性递减逃逸能量的更新方式并结合牛顿局部增强策略在每次迭代末期对猎物位置进行精细搜索,该算法在高维问题中具有较好的适用性,但仅对最优解实施局部增强可能导致搜索范围变动有限,进而影响其收敛精度和可靠性。文献[8]采用 Sobel 序列初始化种群并融合了精英反向学习策略、逃逸能量更新优化策略以及高斯随机游走策略提升了其准确性和稳定性。文献[9]提出了一种融合非线性收敛因子与变异准反射学习的 HHO 算法,利用 Circle 混沌映射进行初始化并引入 Sigmoid 非线性收敛因子平衡种群探索和开发阶段,结合变异准反射学习策略更新个体位置,从而提高其的收敛速度和精度,但该算法的时间复杂度较高,且在高维问题中的提升效果并不明显。文献[10]提出了一种基于精英引导的改进 HHO 算法,利用精英反向学习和精英演化策略更新个体位置,通过调整选择概率平衡两种策略的执行显著提升了该算法的寻优能力和鲁棒性,然而仅对精英个体进行演化,对种群多样性的改善有限。文献[11]提出了一种基于多种群与协同量子化的 HHO 算法,通过引入多种群策略解决初始化种群单一问题,并对不同种群采用不同能量策略来提高种群的搜索能力,同时加入协同量子化策略避免其陷入局部极值,提升寻优精度,但直接使用协同量子化策略方法在处理高维问题时增加了该算法的时间复杂度。

哈里斯鹰种群的位置变动依赖最优解,尽管较多改进算法在一定程度上提高了 HHO 的寻优能力,但是随着迭代次数增加,最优解的变异策略不能进行快速且有效地调整。部分改进算法的时间复杂度较高,因此本文提出了一种多策略改进的哈里斯鹰优化算法 MSIHHO(Multiple Strategy Improved Harris Optimization)。首先,采用 Circle 混沌映射初始化种群,确保初始种群分布均匀。其次,采用新的逃逸能量更新方式使能量因子非线性递减,以更好地平衡算法的开发和探索阶段。再次,对最优解进行柯西变异,并且变异的权重范围随着迭代次数增加而逐渐缩小,既保证了前期种群的探索能力,又兼顾了后期种群的开发能力。最后,引入一种基于正交设计的学习策略并在每次迭代结束前随机选择一个个体执行该策略,进一步提升种群的寻优能力,由于正交设计实验次数较少,该策略不会显著增加计算量。

1 哈里斯鹰优化算法

哈里斯鹰算法是一种基于种群的无梯度优化算

法,整个算法分为搜索阶段、过渡阶段和开发阶段 3 个阶段^[12]。

1.1 探索阶段

哈里斯鹰在探索阶段使用两种策略,鹰群在活动范围内搜索猎物,在发现猎物前,根据上一个时刻位置栖息在某棵树上。在发现猎物后,根据猎物位置和种群中其他成员进行探索^[13]。两种策略执行概率相等。

1.2 过渡阶段

猎物在逃跑过程中能量减少,哈里斯鹰算法逐渐由探索转向开发,进而捕捉猎物,猎物的逃逸能量和跳跃强度分别为

$$E = 2E_0(1 - \frac{t}{T}) \quad (1)$$

$$J = 2(1 - r) \quad (2)$$

其中, E 是猎物的逃逸能量; E_0 是 $(-1,1)$ 之间的随机数; t 和 T 分别表示当前和最大迭代次数; J 表示猎物的跳跃强度; r 是 $(0,1)$ 之间的随机数。当 $|E| > 1$ 时,猎物逃逸能量高,进行探索过程。当 $|E| \leq 1$ 时,猎物逃逸能量低,进行开发过程。

1.3 开发阶段

在开发阶段,哈里斯鹰使用 4 种策略攻击猎物。设 r 为猎物成功逃脱的几率,且是 $(0,1)$ 之间的随机数。当 $r \geq 0.5$ 且 $|E| \geq 0.5$ 时,猎物仍具有逃逸能量,但逃脱概率较小,哈里斯鹰采用软包围策略。当 $r \geq 0.5$ 且 $|E| < 0.5$ 时,猎物的能量不足,不能进行跳跃,哈里斯鹰采用硬包围策略。当 $r < 0.5$ 且 $|E| \geq 0.5$ 时,猎物仍具有逃逸能量和跳跃能力,逃脱概率较大,哈里斯鹰采用俯冲式软包围策略。当 $r < 0.5$ 且 $|E| < 0.5$ 时,猎物逃逸能量不足,不具备跳跃能力,哈里斯鹰采用俯冲式硬包围策略^[14]。

2 哈里斯鹰优化算法改进

2.1 种群初始化

混沌映射具有随机性和遍历性特点,能够有效提高种群的多样性,有利于算法跳出局部极值区^[15]。Circle 混沌映射具有遍历性、非周期性和对初始值敏感等特点,适合应用于种群初始化, Circle 混沌映射方法为^[16]

$$\mathbf{x}_{k+1} = \text{mod}(\mathbf{x}_k + 0.2 - \frac{0.5}{2\pi} \sin(2\pi \mathbf{x}_k), 1) \quad (3)$$

其中, $\mathbf{x}_k$ 表示第 k 个映射值,第 1 个映射值在 $(0,1)$ 之间随机产生; mod 表示求余运算。在产生映射值后将其进行转换,即可产生初始化种群。

2.2 非线性能量因子

哈里斯鹰算法通过逃逸能量的不同来切换探索和开发阶段,原能量因子在迭代过程中线性递减,哈里斯鹰算法在后期易陷入局部最优,为此采用一

种新的非线性的能量因子更新方式, 如式(4)所示。

$$E = E_0 \left(\frac{2}{\pi} \arccos \left(\frac{2(t-0.5T)}{T} \right) \right) \quad (4)$$

改进前后的能量因子与迭代次数的关系如图 1 所示。改进后的能量因子在前期下降较快, 后期下降较慢, 更好地平衡了种群的开发和探索过程。




图 1 非线性能量因子更新过程

Figure 1 Nonlinear energy factor updating process

2.3 随机权重的柯西变异扰动最优解

柯西分布是一个不存在数学期望、方差和高阶矩的连续型概率分布, 柯西分布的概率密度函数为^[17]

$$f(x; x_0, \gamma) = \frac{1}{\pi} \left[\frac{\gamma}{(x - x_0)^2 + \gamma^2} \right] \quad (5)$$

其中, x_0 是定义分布峰值位置的位置参数; γ 为最大值一半处的半宽度尺度参数。当 $\gamma=1$ 、 $x_0=0$ 时式(5)是标准柯西分布。柯西变异在需要变异的个体上增加一个服从柯西分布的随机变量^[18], 由于最优个体引导其余个体更新, 所以对最优个体进行变异后能够有效减小其他个体受局部极值区的影响, 扩大搜索范围, 避免种群开发过程陷入局部最优。

本文调整了柯西变异的系数, 使其在范围内动态变化。针对每个个体, 柯西变异的权重和步长均不再固定, 可以进一步扩大搜索范围。通过式(6)产生最优个体的变异个体。

$$\mathbf{X}_{\text{rabbit}}(i) = \mathbf{X}_{\text{best}} + w(i) \times (\text{ub} - \text{lb}) \times \text{Cauchy}(0,1) \quad (6)$$

其中, $\mathbf{X}_{\text{rabbit}}(i)$ 表示对第 i 个个体而言的变异个体; $\mathbf{X}_{\text{best}}$ 表示当前最优个体; ub 和 lb 分别表示搜索空间的上下边界; $\text{Cauchy}(0,1)$ 表示标准柯西分布函数; $w(i)$ 是 $(0,c)$ 之间的随机数, 区间上限 c 随着迭代次数增加而线性递减, 其值为

$$c = C_0 \left(1 - \frac{t}{T} \right) \quad (7)$$

其中, C_0 是固定常数。随着迭代次数增加, 边界变量 c 越来越小, 柯西变异的最大幅度越来越小, 有

利于在前期提升种群的探索能力, 后期提升种群的开发能力。

2.4 基于正交设计的学习策略

反向学习策略随问题维度的增加, 学习效果越来越差, 为此本文提出一种基于正交设计的学习策略, 对任意选中的一个个体产生该个体需要学习的新解 $\mathbf{x}_b$, 之后该个体学习 $\mathbf{x}_b$ 的部分维度, 从而提升种群的搜索能力。

假设问题维度为 D , 则原个体向 $\mathbf{x}_b$ 学习产生的所有部分维度解个数为 $2^D - 2$ 。若对所有部分维度解进行评价, 将增加评价次数和算法的运行时间。正交设计具有均匀分散、整齐可比的特点, 仅做少量实验可以取得良好的实验条件^[19], 适用于产生部分维度解。根据正交表产生正交设计的结果, 使用 $L_M(Q^K)$ 表示, 其中 L 表示正交矩阵, K 表示因素个数, 对应问题的维度, Q 表示水平个数, M 表示实验次数。正交表 $L_4(2^3)$ 为式

$$L_4(2^3) = \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 2 \\ 2 & 1 & 2 \\ 2 & 2 & 1 \end{bmatrix} \quad (8)$$

其中, 1 表示产生的新个体在此维度处的值跟原个体相同; 2 表示产生的新个体在此维度处的值跟另一个个体相同。第 1 行为全 1, 表示当前个体本身, 其他个体是当前个体和新解在维度上的正交组合。对 3 因素 2 水平问题, 只需产生 3 个个体进行评估即可找到最佳正交学习组合^[20]。

本文对 $\mathbf{x}$ 和 $\mathbf{x}_b$ 设计一个 2 水平 D 因素的实验, 产生 M 个部分维度解, 其中 M 的计算式如式(9)所示^[21]。

$$M = 2^{\lceil \log_2(D+1) \rceil} \quad (9)$$

在计算得到 M 后, 使用正交表的设计方法生成正交表 $L_M(Q^K)$ 。除了第 1 行代表的当前个体不用评估, 其余 $M-1$ 个部分维度解以及新解 $\mathbf{x}_b$ 本身均需评估, 所以总评估次数为 M 次。为了兼顾本文算法的运行时间, 在每次迭代过程中选择一个个体执行基于正交设计的学习策略。

为了使选中的个体进行有效学习, 本文提出了一种学习策略来产生新解 $\mathbf{x}_b$ 。在前期以区间中点为中心产生反向解作为 $\mathbf{x}_b$, 后期利用精英个体位置产生 $\mathbf{x}_b$, 如式(10)和(11)所示。

$$\mathbf{x}_b = \begin{cases} r_1(\text{lb} + \text{ub} - \mathbf{x}) + (1 - r_1)\mathbf{x}, & |a| > 1 \\ \mathbf{x}_c, & |a| \leq 1 \wedge r > 0.5 \\ \mathbf{x}_c + r_2(\mathbf{x}_c - \mathbf{x}), & |a| \leq 1 \wedge r > 0.5 \end{cases} \quad (10)$$

$$a = A \left(\frac{2}{\pi} \arccos \left(\frac{2(t-0.5T)}{T} \right) \right) \quad (11)$$

其中, r 、 r_1 、 r_2 是(0,1)之间的随机数; $\mathbf{x}_c$ 在适应度值排名最靠前的 3 个精英个体中随机选择, 在除了精英个体的剩余个体中随机选择原个体 $\mathbf{x}$; A 是(0,2)之间的随机数; a 的产生方式和改进后的逃逸能量产生方式保持一致。前期种群分布松散, $|a|$ 偏大, 此时以区间中点为中心产生反向解可以扩大搜索范围, 提升种群的探索能力。后期种群分布集中, $|a|$ 偏小, 此时将精英个体位置作为 $\mathbf{x}_b$, 或以精英个体位置为中心产生反向解, 两种方案执行概率相同, 从而可以提升种群后期的开发能力和探索能力。

2.5 改进算法 MSIHHO

MSIHHO 算法过程包括种群初始化、根据计算式更新种群位置并评估以及随机选择一个个体进行基于正交设计的反向学习并评估。假设种群由 N 个个体组成, 维度为 D , 算法总共迭代 T 次, 则本文算法初始化过程的时间复杂度为 $O(N \times D)$, 使用经典计算式更新种群位置的时间复杂度为 $O(N \times D \times T)$, 执行基于正交设计的学习策略的时间复杂度为 $O(M \times D \times T)$, 因此 MSIHHO 算法的时间复杂度为 $O((N+M) \times D \times T)$ 。MSIHHO 的总评估次数为 $((N+M) \times T + N)$ 次。

MSIHHO 算法步骤如下所示:

步骤 1 使用 Circle 混沌映射策略产生初始化种群。

步骤 2 在每次迭代更新过程中, 利用随机权重的柯西变异扰动当前最优解。

步骤 3 将最优解变异产生的个体代入位置更新计算式, 更新个体位置。

步骤 4 根据边界条件限制个体位置, 使用边界值代替越界的部分。计算适应度值, 按照贪婪策略保留个体。

步骤 5 随机选择一个个体, 使用基于正交设计的学习策略寻找更优位置, 若找到更优位置则替换当前位置, 否则保留原位置。

步骤 6 判断迭代是否终止。若终止, 则将当前最优解作为全局最优解, 结束迭代。若未终止, 则返回步骤 2 继续迭代。

3 本文算法的测试和分析

3.1 测试环境

CEC2017 测试集包括 29 个测试函数, 单峰函数($F_1 \sim F_2$)用于测试算法的开发能力, 简单多峰函数($F_3 \sim F_9$)用于测试算法的搜索能力, 混合函数($F_{10} \sim F_{19}$)和组合函数($F_{20} \sim F_{29}$)用于测试算法解决复杂优化问题的能力。CEC2017 测试函数的求解较复杂, 随着维度的增加, 求解时间复杂度变得较为困

难。本文使用 CEC2017 中的测试函数 F_1 、 F_3 、 F_4 、 F_6 、 F_{11} 、 F_{13} 、 F_{16} 、 F_{19} 、 F_{20} 、 F_{23} 、 F_{27} 、 F_{29} 进行测试, 每种优化算法独立运行 30 次, 运行过程的迭代次数均为 800 次, 种群数量均为 60, 求解维度均为 30。在配置 Intel i5-12400 处理器和 16 GB 内存的电脑进行本文实验, 使用 Python 编程。CEC2017 测试函数如表 1 所示。

表 1 CEC2017 测试函数
Table 1. CEC2017 test functions

编号	函数	最优解
F_1	Shifted and Rotated Bent Cigar	100
F_3	Shifted and Rotated Rosenbrock's Function	300
F_4	Shifted and Rotated Rastrigin's Function	400
F_6	Shifted and Rotated Lunacek Bi-Rastrigin's Function	600
F_{11}	Hybrid Function 2	1 100
F_{13}	Hybrid Function 4	1 300
F_{16}	Hybrid Function 7	1 600
F_{19}	Hybrid Function 10	1 900
F_{20}	Composition Function 1	2 000
F_{23}	Composition Function 4	2 300
F_{27}	Composition Function 8	2 700
F_{29}	Composition Function 10	2 900

3.2 MSIHHO 的参数取值分析

MSIHHO 的参数 C_0 对 MSIHHO 的性能具有较大影响。当 C_0 取值较大时, 最优解变异的范围较大, 更有利于算法探索, 但较大的 C_0 不利于算法开发。当 C_0 取值较小时, 最优解变异的范围较小, 有利于算法开发, 但较小的 C_0 不利于算法探索。本文将 C_0 依次取值为 10^{-2} 、 10^{-3} 、 10^{-4} 、 10^{-5} 来优化测试函数, 统计每种情况下运行 30 次结果的平均值进行分析, 如表 2 所示, 其中加粗数值表示本文算法在不同 C_0 取值条件下求解测试函数取得的平均值最优解。

表 2 不同 C_0 取值的 MSIHHO 运行结果
Table 2. MSIHHO operation results for different C_0 values

	$C_0=10^{-1}$	$C_0=10^{-2}$	$C_0=10^{-3}$	$C_0=10^{-4}$	$C_0=10^{-5}$
F_1	2.69×10^6	4.76×10^4	2.71×10^3	2.43×10^3	2.22×10^3
F_3	3.71×10^2	3.88×10^2	3.62×10^2	3.66×10^2	3.77×10^2
F_4	7.65×10^2	5.44×10^2	6.19×10^2	8.44×10^2	1.26×10^3
F_6	1.19×10^3	9.17×10^2	7.92×10^2	9.86×10^2	1.33×10^3
F_{11}	1.15×10^6	2.31×10^5	1.15×10^5	5.19×10^4	7.46×10^4
F_{13}	2.98×10^5	8.05×10^4	6.64×10^4	8.01×10^4	1.42×10^5
F_{16}	2.89×10^3	2.37×10^3	2.34×10^3	2.51×10^3	3.24×10^3
F_{19}	1.92×10^3	1.78×10^3	1.90×10^3	1.96×10^3	2.43×10^3
F_{20}	2.42×10^3	2.24×10^3	2.25×10^3	2.49×10^3	2.39×10^3
F_{23}	2.68×10^3	2.57×10^3	2.56×10^3	2.86×10^3	2.65×10^3
F_{27}	3.00×10^3	2.80×10^3	2.78×10^3	2.88×10^3	3.01×10^3
F_{29}	5.27×10^4	3.90×10^4	4.55×10^4	2.70×10^4	1.20×10^5

由表 2 可知, 当 C_0 取值为 10^{-1} 时, MSIHHO 在测试函数的表现总体落后, 说明较大的 C_0 取值降低了 MSIHHO 的开发能力, 同时不利于提升 MSIHHO 的搜索能力。当 C_0 取值为 10^{-2} 时, MSIHHO 在 F_1 表现较落后, 在 F_4 、 F_{19} 和 F_{20} 的表现最好, 说明此时 MSIHHO 的搜索能力较强, 但开发能力较弱。当 C_0 取值为 10^{-3} 时, MSIHHO 在

F_3 、 F_6 、 F_{13} 、 F_{16} 、 F_{23} 和 F_{27} 的表现最好, 在其他测试函数的表现居中, 说明 MSIHHO 此时在开发和探索能力方面具有较好的平衡。当 C_0 取值为 10^{-4} 时, MSIHHO 在 F_{11} 和 F_{29} 的表现最好, 但在 F_4 、 F_6 等测试函数的表现靠后, 说明 C_0 取值较小时 MSIHHO 的开发能力较强, 但其搜索能力较弱。当 C_0 取值为 10^{-5} 时, MSIHHO 在 F_1 的表现最好, 说明 C_0 取值较小时 MSIHHO 的开发能力较强, 但在 F_4 、 F_6 、 F_{16} 、 F_{19} 和 F_{27} 的表现最差, 说明此时该算法的搜索能力较弱。

C_0 的取值应兼顾 MSIHHO 的开发和探索能力, 合适的取值范围约为 $(10^{-4}, 10^{-2})$, 本文取值为 10^{-3} 。

3.3 消融实验

通过消融实验来比较随机权重的柯西变异策略和基于正交设计的学习策略这两种策略对 MSIHHO 的影响。在 HHO 的基础上仅使用随机权重的柯西变异策略的算法记作 AHHO, 在 HHO 的基础上仅使用基于正交设计的学习策略的算法记作 BHHO。依次使用 HHO、AHHO、BHHO、MSIHHO 对 CEC2017 测试集中的函数进行优化, 统计每种算法运行 30 次结果的平均值进行分析, 结果如表 3 所示, 其中加粗数值表示 MSIHHO 及其子算法求解相同测试函数时取得的平均值最优解。

表 3 MSIHHO 的模型消融实验结果

Table 3. Results of model ablation experiments in MSIHHO

	HHO	AHHO	BHHO	MSIHHO
F_1	1.47×10^7	4.28×10^3	1.09×10^5	2.71×10^3
F_3	4.29×10^2	3.71×10^2	3.90×10^2	3.62×10^2
F_4	1.08×10^3	6.88×10^2	1.06×10^3	6.19×10^2
F_6	1.92×10^3	8.04×10^2	1.73×10^3	7.92×10^2
F_{11}	8.56×10^6	1.41×10^5	9.64×10^5	7.75×10^4
F_{13}	1.10×10^6	1.88×10^5	2.42×10^5	6.64×10^4
F_{16}	1.36×10^4	2.67×10^3	3.73×10^3	2.34×10^3
F_{19}	3.93×10^3	1.94×10^3	2.95×10^3	1.90×10^3
F_{20}	2.56×10^3	2.29×10^3	2.47×10^3	2.25×10^3
F_{23}	2.84×10^3	2.63×10^3	2.76×10^3	2.56×10^3
F_{27}	3.14×10^3	2.80×10^3	3.07×10^3	2.78×10^3
F_{29}	5.37×10^6	5.29×10^4	1.20×10^5	4.55×10^4

由表 3 可以看出, MSIHHO 在所有测试函数上表现最好, 说明 MSIHHO 具有更强的开发和探索能力以及解决复杂优化问题的能力。AHHO、BHHO 在所有测试函数上的表现均优于 HHO, 说明两种策

略均能够较好地提升 MSIHHO 的寻优能力, 避免其陷入局部最优。通过比较 AHHO 和 BHHO 的运行结果可以看出, AHHO 的运行结果均优于 BHHO, 说明随机权重的柯西变异策略在较大程度上影响了 MSIHHO 的寻优能力。相较于固定权重的柯西变异策略, 该策略更能兼顾 MSIHHO 的前期探索过程和后期开发过程, 提升 MSIHHO 的寻优能力。

3.4 MSIHHO 和其他算法对比

依次使用经典算法麻雀搜索算法 (Sparrow Search Algorithm, SSA)^[22]、鲸鱼算法 (Whale Optimization Algorithm, WOA)^[23]、被囊群算法 (Tunicate Swarm Algorithm, TSA)^[24]、灰狼算法 (Grey Wolf Optimizer, GWO)^[25]、HHO^[12] 和改进 HHO 算法 IHHO1^[7]、IHHO2^[9]、IHHA^[6] 对 CEC2017 测试集中的函数进行优化, 上述优化算法的控制参数取值如表 4 所示。

表 4 算法的控制参数取值

Table 4. Control parameter values for the algorithms

算法	控制参数
SSA	ST=0.8, PD=0.2, SD=0.1
WOA	P=0.5, b=1
TSA	$P_{\min}=1, P_{\max}=4$
GWO	None
HHO	$\beta=1.5$
IHHO1	k=6, n=4
IHHO2	w=2
IHHA	a=0.5
MSIHHO	$C_0=10^{-3}$

统计每种算法运行 30 次结果的平均值, 与 MSIHHO 的运行结果进行对比, 评估 MSIHHO 相对其他算法的寻优能力, 统计 MSIHHO 和其他算法运行 30 次结果的平均值, 如表 5 所示, 其中加粗数值表示不同算法求解相同测试函数时取得的平均值最优解。

使用 Wilcoxon 秩和检验方法来检验其他算法和 MSIHHO 的运行 30 次结果是否存在显著性差异。Wilcoxon 秩和检验是一种无参数检验方法, 可以检验两个不同数据集中的数据是否来自同一个分布总体。在显著性水平为 5% 的条件下进行 Wilcoxon 秩和检验, 结果如表 6 所示, 其中加粗数值表示秩和检验结果大于 0.05。

表 5 各算法运行结果的平均值

Table 5. Average of the running results of each algorithm

测试函数	SSA	WOA	TSA	GWO	HHO	IHHO1	IHHO2	IHHA	MSIHHO
F_1	2.16×10^7	3.23×10^9	2.32×10^{10}	4.59×10^8	1.47×10^7	1.00×10^7	8.91×10^6	6.46×10^6	2.71×10^3
F_3	1.69×10^3	7.69×10^2	3.69×10^3	3.97×10^2	4.29×10^2	4.15×10^2	3.99×10^2	4.08×10^2	3.62×10^2
F_4	7.86×10^3	1.58×10^4	2.90×10^4	1.22×10^3	1.08×10^3	9.77×10^2	9.04×10^2	1.01×10^3	6.19×10^2
F_6	1.36×10^4	2.08×10^5	9.41×10^5	2.86×10^4	1.92×10^3	1.49×10^3	1.43×10^3	1.43×10^3	7.92×10^2
F_{11}	6.86×10^8	6.55×10^6	2.92×10^9	1.78×10^7	8.56×10^6	5.22×10^6	5.54×10^6	6.13×10^6	7.75×10^4
F_{13}	3.30×10^6	7.38×10^5	1.72×10^6	3.12×10^5	1.10×10^6	8.28×10^5	4.02×10^5	8.42×10^5	6.64×10^4

F_{16}	6.03×10^{11}	4.38×10^4	2.13×10^6	3.84×10^4	1.36×10^4	8.39×10^3	5.68×10^3	4.29×10^3	2.34×10^3
F_{19}	1.14×10^4	1.02×10^4	5.36×10^3	2.04×10^3	3.93×10^3	3.62×10^3	2.92×10^3	3.54×10^3	1.90×10^3
F_{20}	8.71×10^3	1.02×10^4	1.47×10^4	2.92×10^3	2.56×10^3	2.59×10^3	2.55×10^3	2.58×10^3	2.25×10^3
F_{23}	4.04×10^3	1.01×10^4	1.83×10^4	3.37×10^3	2.84×10^3	2.78×10^3	2.79×10^3	2.76×10^3	2.56×10^3
F_{27}	4.21×10^3	3.39×10^3	3.80×10^3	3.15×10^3	3.14×10^3	3.08×10^3	3.07×10^3	3.10×10^3	2.72×10^3
F_{29}	5.15×10^9	3.70×10^7	2.38×10^9	9.07×10^6	5.37×10^6	3.59×10^6	9.67×10^5	3.00×10^6	4.55×10^4

表 6 MSIHHO 和其他算法运行结果的 Wilcoxon 秩和检验结果

Table 6. Wilcoxon rank sum test results for the running results of MSIHHO and other algorithm

测试函数	SSA	WOA	TSA	GWO	HHO	IHHO1	IHHO2	IHHA
F_1	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}
F_3	1.02×10^{-9}	4.29×10^{-11}	2.87×10^{-11}	8.37×10^{-2}	1.48×10^{-5}	1.21×10^{-4}	1.56×10^{-3}	2.10×10^{-3}
F_4	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	6.28×10^{-7}	1.54×10^{-10}	3.06×10^{-9}	3.50×10^{-8}	5.32×10^{-10}
F_6	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	3.18×10^{-11}	2.87×10^{-11}	2.87×10^{-11}
F_{11}	8.49×10^{-10}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}
F_{13}	9.31×10^{-10}	1.15×10^{-8}	4.78×10^{-9}	1.84×10^{-4}	4.78×10^{-9}	4.78×10^{-9}	2.23×10^{-6}	1.93×10^{-8}
F_{16}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	2.87×10^{-11}	8.56×10^{-11}	1.12×10^{-9}	3.80×10^{-8}	3.70×10^{-6}
F_{19}	2.87×10^{-11}	2.87×10^{-11}	3.18×10^{-11}	6.68×10^{-1}	2.87×10^{-11}	3.18×10^{-11}	2.05×10^{-10}	4.29×10^{-11}
F_{20}	2.79×10^{-9}	7.03×10^{-11}	2.87×10^{-11}	2.47×10^{-7}	1.37×10^{-4}	1.38×10^{-5}	6.07×10^{-6}	3.45×10^{-6}
F_{23}	4.28×10^{-7}	2.87×10^{-11}	2.87×10^{-11}	3.66×10^{-9}	5.39×10^{-7}	6.78×10^{-7}	4.99×10^{-7}	5.39×10^{-7}
F_{27}	9.44×10^{-11}	1.86×10^{-10}	2.87×10^{-11}	9.85×10^{-6}	5.82×10^{-7}	2.32×10^{-4}	4.34×10^{-4}	2.35×10^{-5}
F_{29}	4.73×10^{-11}	4.29×10^{-11}	2.87×10^{-11}	8.56×10^{-11}	3.18×10^{-11}	3.18×10^{-11}	3.88×10^{-11}	4.73×10^{-11}

由表 5 可以看出, 对于单峰函数 F_1 和简单多峰函数 F_3 、 F_4 、 F_6 , MSIHHO 表现最好。相比其他算法, MSIHHO 具有更强的开发和探索能力。MSIHHO 在组合函数和混合函数上均表现最好, 说明 MSIHHO 相比其他算法具备更好的解决复杂优化问题的能力。

由表 6 可以看出, MSIHHO 和 GWO 在 F_{19} 以外的所有测试函数的运行结果均存在显著性差异, 和其他算法在所有函数的运行结果均存在显著性差异, 说明 MSIHHO 和其他算法之间存在显著差异, MSIHHO 的寻优性能优于其他算法。

仅由最终结果并不能得出改进算法 MSIHHO 的迭代过程的特点, 因此需观察当前最优解随迭代次数的变化曲线, 将迭代次数设置为 400 次, 观察测试函数 F_1 、 F_6 的收敛曲线。MSIHHO、HHO 以及其他改进 HHO 算法的收敛曲线如图 2 所示, MSIHHO 以及其他经典算法的收敛曲线如图 3 所示。

由图 2 可知, 相比其他改进 HHO 算法, MSIHHO 收敛速度最快, 所得结果最优。

由图 3 可知, MSIHHO、GWO 的前期收敛速度较快, 但 GWO 后期陷入局部最优解, 最终 MSIHHO 取得的结果最优。综上所述, MSIHHO 具有较强的开发和探索能力, 收敛速度较快, 并且不易陷入局部最优解。





图 2 MSIHHO、HHO 和其他改进算法的收敛曲线

Figure 2. Convergence curves of MSIHHO, HHO and other improved algorithms
(a) F_1 (b) F_6





图 3 MSIHHO 和经典算法的收敛曲线

(a) F_1 (b) F_6

Figure 3. Convergence curves of MSIHHO and classical algorithms

(a) F_1 (b) F_6

3.5 MSIHHO 在工程问题中的应用

利用压力容器设计问题来验证 MSIHHO 在实际工程问题中的有效性。压力容器设计问题指在一定的约束条件下找到使成本最小的变量组合, 问题变量包括外壳厚度 $T_s(x_1)$ 、封头厚度 $T_h(x_2)$ 、内径 $R(x_3)$ 以及容器管深长度 $L(x_4)$ 。压力容器问题的目标函数为

$$f(x) = 0.6224x_1x_3x_4 + 1.7781x_2x_3^2 + 3.1661x_1^2x_4 + 19.84x_1^2x_3 \quad (12)$$

约束条件为

$$\begin{aligned} g_1(x) &= -x_1 + 0.0193x_3 \leq 0 \\ g_2(x) &= -x_3 + 0.00954x_3 \leq 0 \\ g_3(x) &= -\pi x_3^2x_4 - \frac{4}{3}\pi x_3^3 + 1296000 \leq 0 \\ g_4(x) &= x_4 - 240 \leq 0 \end{aligned} \quad (13)$$

各个变量的取值范围如式(14)所示。

$$\begin{aligned} 0 &\leq x_1 \leq 99 \\ 0 &\leq x_2 \leq 99 \\ 10 &\leq x_3 \leq 200 \\ 10 &\leq x_4 \leq 200 \end{aligned} \quad (14)$$

使用 MSIHHO 和对比算法对压力容器问题进行优化, 将每种算法的运行 30 次的结果取平均值, 结果如表 7 所示。可以看出 MSIHHO 最终所得结果优于其他算法, 因此 MSIHHO 在实际工程问题中具有较好的应用前景。

表 7 压力容器设计问题的优化结果

Table 7. Optimization results for pressure vessel design problems

算法	$T_s(x_1)$	$T_h(x_2)$	$R(x_3)$	$L(x_4)$	$f(x)$
MSIHHO	0.778 5	0.384 8	40.334 6	199.792 8	5 885.88
HHO	0.978 0	0.487 2	50.525 1	94.232 6	6 354.19
SSA	0.925 5	0.457 5	47.954 2	115.452 3	6 187.90
WOA	0.984 2	0.447 4	46.907 2	124.945 9	6 916.53
TSA	0.780 6	0.398 1	40.372 6	199.987 4	5 951.02
GWO	0.779 9	0.386 1	40.401 4	198.893 0	5 892.30
IHHO1	0.815 0	0.407 9	42.141 8	177.135 7	6 002.98
IHHO2	0.813 4	0.404 4	42.143 9	176.109 7	5 956.99
IHHA	0.907 2	0.472 7	47.006 1	124.025 8	6 240.16

4 结束语

针对哈里斯鹰算法寻优精度较低和易陷入局部最优问题, 本文使用多种策略对哈里斯鹰算法进行改进。结合 Circle 混沌映射进行初始化, 保证初始个体分布均匀。将能量因子的更新方式由线性递减改为非线性递减, 更好地平衡种群的开发和探索

阶段。利用随机权重的柯西变异策略扰动当前最优解, 引导其他个体进行更新, 扩大了搜索范围。随着迭代次数增加, 变异权重的范围由大变小, 提升了种群前期的探索能力和后期的开发能力。在每次迭代的最后选择一个个体, 使用基于正交设计的反向学习策略寻找更优位置, 进一步提升所提算法的寻优能力。

使用 MSIHHO 和其他算法优化 CEC2017 测试函数, 结果表明 MSIHHO 具有更强的开发能力、探索能力以及解决复杂优化问题的能力。由 MSIHHO 的收敛曲线可以看出, MSIHHO 的寻优精度更高, 收敛速度较快且不易陷入局部最优。由 Wilcoxon 秩和检验结果可以看出, MSIHHO 和其他算法之间具有显著性差异。压力容器问题的优化结果表明, MSIHHO 在实际工程问题中具有较好的应用前景。

本文未调整哈里斯鹰位置更新计算式, 未来将分析和改进哈里斯鹰位置更新计算式。

参考文献

- [1] Zuo Y, Guo L, Liu W, et al. Mixing ratio optimization of chaff elements for wideband jamming using PSO[J]. IEEE Antennas and Wireless Propagation Letters, 2020, 19(12): 2408-2412.
- [2] Senthilnath J, Kulkarni S, Benediktsson J A, et al. A novel approach for multispectral satellite image classification based on the bat algorithm[J]. IEEE Geoscience and Remote Sensing Letters, 2016, 13(4): 599-603.
- [3] Wang G G, Deb S, Gao X Z, et al. A new metaheuristic optimisation algorithm motivated by elephant herding behaviour[J]. International Journal of Bio-Inspired Comput, 2017, 8(6): 394-409.
- [4] Ali A, Shah S A A, Shloul T A, et al. Multiobjective Harris hawks optimization-based task scheduling in cloud-fog computing[J]. IEEE Internet of Things Journal, 2024, 11(13): 24334-24352.
- [5] Menesy A S, Sultan H M, Selim A, et al. Developing and applying chaotic Harris hawks optimization technique for extracting parameters of several proton exchange membrane fuel cell stacks[J]. IEEE Access, 2020, 8(2): 1146-1159.
- [6] 朱智坚, 华伟. 改进哈里斯鹰算法用于阵列天线方向图赋形[J]. 现代计算机, 2024, 30(6): 94-98.
Zhu Zhijian, Hua Wei. Improved Harris hawks algorithm for pattern shaping of linear antenna arrays[J]. Modern Computer, 2024, 30(6): 94-98.
- [7] 赵世杰, 高雷阜, 于冬梅, 等. 融合能量周期性递减与牛顿局部增强的改进 HHO 算法[J]. 控制与决策, 2021, 36(3): 629-636.
Zhao Shijie, Gao Leifu, Yu Dongmei, et al. Improved Harris hawks optimization coupling energy cycle decline

- mechanism and Newton local enhancement strategy[J].Control and Decision,2021,36(3):629-636.
- [8] 田福林.基于多策略哈里斯鹰算法的微电网优化调度研究与应用[D].长沙:中南大学,2023:16-19.
Tian Fulin.Research and application of microgrid optimal scheduling based on multi-strategy Harris hawk algorithm[D].Changsha:Central South University,2023:16-19.
- [9] 宋美佳,贾鹤鸣,林志兴,等.融合非线性收敛因子与变异准反射学习的哈里斯鹰优化算法[J].智能系统学报,2024,19(3):738-748.
Song Meijia,Jia Heming,Lin Zhixing,et al.Harris hawks optimization algorithm based on nonlinear convergence factor and mutation quasi-reflected-based learning[J].CAAI Transactions on Intelligent Systems,2024,19(3):738-748.
- [10] 李雨恒,高尚,孟祥宇.基于精英引导的改进哈里斯鹰优化算法[J].计算机工程与科学,2024,46(2):363-373.
Li Yuheng,Gao Shang,Meng Xiangyu.An improved Harris hawks optimization algorithm based on elite guidance[J].Computer Engineering and Science,2024,46(2):363-373.
- [11] 李岩,钱谦.基于多种群与协同量子化的哈里斯鹰优化算法[J].控制与决策,2024,39(2):2169-2176.
Li Yan,Qian Qian.Harris hawks optimization algorithm based on multigroup and collaborative quantization[J].Control and Decision,2024,39(2):2169-2176.
- [12] Heidari A A,Mirjalili S,Faris H,et al.Harris hawks optimization:Algorithm and applications[J].Future Generation Computer Systems,2019,97(2):849-872.
- [13] 胡啸,张呈越,卞炜,等.基于改进哈里斯鹰优化算法的动态路径规划研究[J].控制工程,2024,31(4):591-600.
Hu Xiao,Zhang Chengyue,Bian Wei,et al.Research on dynamic path planning based on improved Harris hawk algorithm[J].Control Engineering of China,2024,31(4):591-600.
- [14] 杨海马,郑和庆,黄宏欣.一种混合策略改进的哈里斯鹰算法及应用[J].智能计算机与应用,2024,14(6):169-176.
Yang Haima,Zheng Heqing,Huang hongxin.A hybrid strategy improved Harris hawks algorithm and its application[J].Intelligent Computer and Applications,2024,14(6):169-176.
- [15] 舒奕彬,李立君,张振翮,等.基于改进海马优化算法的PID参数优化[J].机床与液压,2024,52(13):189-194.
Shu Yibin,Li Lijun,Zhang Zhenhe,et al.PID parameter optimization based on improved sea horse optimization algorithm[J].Machine Tool and Hydraulics,2024,52(13):189-194.
- [16] 刘妍,都威,黄琦.基于自适应动态鲸鱼优化算法的路径规划研究[J].自动化应用,2024,65(9):30-34,41.
Liu Yan,Dou Wei,Huang Qi.Research on path planning based on adaptive dynamic whale optimization algorithm[J].Automation Application,2024,65(9):30-34,41.
- [17] 雷岚栋,池亚平,张亮亮.一种基于柯西分布的网络拥塞控制策略[J].北京电子科技学院学报,2021,29(2):32-42.
Lei Landong,Chi Yaping,Zhang Liangliang.A network congestion control strategy based on the Cauchy distribution[J].Journal of Beijing Electronic Science and Technology Institute,2021,29(2):32-42.
- [18] 陈伟.混合策略改进的风驱动优化算法[J].佳木斯大学学报(自然科学版),2024,42(5):43-46.
Chen Wei.Wind driven optimization algorithm improved by hybrid strategy[J].Journal of Jiamusi University(Natural Science Edition),2024,42(5):43-46.
- [19] 閻大海,李元香,祝婕.基于正交设计的反向学习差分进化算法[J].华中科技大学学报(自然科学版),2017,45(5):23-27,44.
He Dahai,Li Yuanxqiang,Zhu Jie.Differential evolution algorithm using orthogonal design opposition-based learning[J].Journal of Huazhong University of Science and Technology(Natural Science Edition),2017,45(5):23-27,44.
- [20] 王天雷,张绮媚,李俊辉,等.基于正交对立学习的改进麻雀搜索算法[J].电子测量技术,2022,45(10):57-66.
Wang Tianlei,Zhang Qimei,Li Junhui,et al.Improved sparrow search algorithm based on orthogonal-opposition-based learning[J].Electronic Measurement Technology,2022,45(10):57-66.
- [21] 王宗山,丁洪伟,王杰,等.基于正交设计的折射反向学习樽海鞘群算法[J].哈尔滨工业大学学报,2022,54(11):122-136.
Wang Zongshan,Ding Hongwei,Wang Jie,et al.Salp swarm algorithm based on orthogonal refracted opposition-based learning[J].Journal Of Harbin Institute of Technology,2022,54(11):122-136.
- [22] Xue J,Shen B.A novel swarm intelligence optimization approach:Sparrow search algorithm[J].Systems Science and Control Engineering,2020,8:22-34.
- [23] Mirjalili S,Lewis A.The whale optimization algorithm[J].Advances in Engineering Software,2016,95:51-67.
- [24] 汪杰,汪祖民.多策略改进的被囊群算法在入侵检测中的应用[J].计算机工程与设计,2024,45(3):684-690.
Wang Jie,Wang Zumin.Application of multi-strategy improved tunicate swarm algorithm in intrusion detection[J].Computer Engineering and Design,2024,45(3):684-690.
- [25] Mirjalili S,Mirjalili S M,Lewis A.Grey wolf

optimizer[J].Advances in Engineering
Software,2014,69(2):46-61.

收稿日期: 2024-09-24

修回日期: 2024-10-20

基金项目: 某国家部门科技委基金项目
(19-163-21-TS-001-014-01)

CSTF Project in A National Sector(19-163-21-TS-001-014-01)

作者简介:

徐天宇(1999-), 男, 硕士研究生。研究方向: 群智能算法、
天线优化。

单志勇(1967-), 男, 通信作者, E-mail:davidshan@163.com,
博士, 副教授。研究方向: 电磁场与微波技术、无线通信、
人工智能。

Xu Tianyu(1999-),male,master degree candidate.Research
direction:Swarm intelligence algorithm and
antenna optimization.

Shan Zhiyong(1967-), male, corresponding author,
E-mail:davidshan@163.com, doctor, associate professor.
Research direction: Electromagnetic field and microwave
technology,wireless communication and artificial intelligence.