

<http://bhxb.buaa.edu.cn> jbuaa@buaa.edu.cn

DOI: 10.13700/j.bh.1001-5965.2023.0433

基于信噪比的学习型哈里斯鹰优化算法

张林¹, 沈佳颖², 胡传陆¹, 朱东林^{2,*}

(1. 江西理工大学 软件工程学院, 南昌 330000; 2. 浙江师范大学 计算机科学与技术学院, 金华 321004)

摘 要: 针对哈里斯鹰优化 (HHO) 算法存在种群学习性与适应性不足的问题, 提出一种基于信噪比的学习型哈里斯鹰优化 (SLHHO) 算法。该算法通过引入信噪比的概念来判断个体的位置信息, 设计了一种协调学习策略, 可以更合理地更新种群内个体的位置, 进而对逃逸距离重新设计, 提升了算法的适应与寻优能力。以 12 个基准函数为标准, 将所提算法与哈里斯鹰算法的变体及其他算法进行性能测试, 并在时间复杂度、多样性、探索与开发等评价指标中进行对比分析, 结果显示, SLHHO 算法具有较强的竞争力与可行性, 在压力容器设计问题中, 验证了 SLHHO 算法的实用性。

关 键 词: 哈里斯鹰优化; 信噪比; 协调学习; 逃逸距离; 基准函数

中图分类号: TP301.6

文献标志码: A

文章编号: 1001-5965(2025)07-2360-14

随着军事、工业、医疗的快速发展,越来越多的优化问题随之产生,由于这类问题是黑盒问题,因此,对这些问题的探索还在深入当中。随着这些优化问题的复杂性增加,传统的数学方法如牛顿法和梯度下降法求解效率较低,因为它们耗时严重,仅取决于问题类型,并在局部状态中挣扎。近十年来,受自然界启发的元启发式算法被提出来解决这些问题,元启发式算法的特点是求解效率高和计算成本低,其模拟了自然界的生物或物理行为现象,较为经典与热门的算法有:粒子群优化 (particle swarm optimization, PSO) 算法^[1]、蚁群优化 (ant colony optimization, ACO) 算法^[2]、灰狼优化 (grey wolf optimizer, GWO) 算法^[3]、鲸鱼优化算法 (whale optimization algorithm, WOA)^[4]等,这些算法均在工程设计、运筹学、能源等领域得到了广泛的应用。

近几年,元启发式算法的研究工作掀起了学者们的研究热潮,并提出了一系列元启发式算法,如麻雀搜索算法^[5]、蝠鲼优化算法^[6]、金枪鱼算法^[7]、天牛须算法^[8]等,基于世界上没有免费午餐的定

理,可知没有一个算法能最佳地解决所有的优化问题,那么如何使一个算法在某个或多个优化问题中具有一定的优势是学者们共同追求的目标。哈里斯鹰优化 (Harris hawks optimization, HHO) 算法^[9]是 2019 年提出的一种新型启发式算法,模拟哈里斯鹰捕食的手段,在一定空间内通过群体独特的协作方式来进行捕食。该算法具有优化能力强、可控参数少、易理解等优势,但在合作觅食中,存在内部交流不足的问题,在寻优精度与速度上还存在可改善的空间。

为进一步提升 HHO 算法优化问题的能力,学者们也在探索其改进的方法, Jiao 等结合正交学习和反向学习,以有效和准确地估计太阳能电池和光伏组件的参数^[10]; 闫晓斌等提出自适应高斯变异来合理地控制种群的多样性^[11]; Elgamal 等在 HHO 算法的初始化阶段引入混沌映射,以提高搜索空间中的群体多样性,并用模拟退火算法来处理当前的最佳解决方案,以提高 HHO 算法的利用率^[12]; 胡春安等在 HHO 算法中引入混沌局部搜索策略,提高算

收稿日期: 2023-07-03; 录用日期: 2023-11-27; 网络出版时间: 2024-02-04 10:56

网络出版地址: link.cnki.net/urlid/11.2625.V.20240202.1346.003

基金项目: 国家自然科学基金 (62272418, 62002046)

*通信作者: E-mail: 2078570674@qq.com

引用格式: 张林, 沈佳颖, 胡传陆, 等. 基于信噪比的学习型哈里斯鹰优化算法 [J]. 北京航空航天大学学报, 2025, 51 (7): 2360-2373.

ZHANG L, SHEN J Y, HU C L, et al. Learning Harris Hawks optimization algorithm with signal-to-noise ratio [J]. Journal of Beijing University of Aeronautics and Astronautics, 2025, 51 (7): 2360-2373 (in Chinese).

法的开发能力,精英备选池与分布估计来动态调整种群的寻优方向^[13];Li等提出一种基于对数螺旋和基于反向学习的探索策略来提高HHO算法的探索能力^[14];李岩等提出多种群的进化方向,同时引入了协同量子化策略避免算法陷入局部极值^[15];柴岩等引入双向经验与极端个体来引导个体寻优方向^[16];刘小龙等设计了多子群邻域来引导子群觅食,同时通过固定的置换概率来加强各子群的内部交流,并通过算子选择更好地利用现有问题的信息^[17];展广涵等采用了精英混沌反向学习策略初始化种群,并引入动态自适应权重机制;采用拉普拉斯交叉算子策略生成高质量个体^[18];赵峰等引入指数能量方程和正弦跳跃距离方程,对个体进行柯西变异或Circle混沌扰动^[19];贾鹤鸣等在初始化阶段引入了动态反向学习,寻优过程中融合了阿奎拉鹰优化(Aquila optimizer, AO)算法^[20]。上述研究虽在一定程度上考虑了种群多样性及完善的寻优手段,但因种群内部缺乏信息交流及对当前环境的判断能力不足,导致算法不能在多类场景下均有较好的寻优效果。为此,本文提出一种基于信噪比(signal-noise ratio, SNR)的学习型哈里斯鹰优化(learning Harris hawk optimization with SNR, SLHHO)算法,引入了SNR的概念来判断种群的位置信息,再设计一种协调学习机制来更新个体的位置,并对逃逸距离重新进行调整,提升了种群寻优的适应能力。主要创新点如下:

1) 本文提出一种新型的逃逸距离设计公式,摆脱了HHO算法中逃逸距离 J 的搜索范围不全面的劣势,使得设计后的值能够分布地更加均匀,从而使寻优方式多样,适应不同环境的寻优。

2) 通过引入SNR的概念来判断个体的位置信息,设计了一种协调学习策略,动态调整了个体的位置更新方式,使得算法具有充分的学习能力。

3) 对SLHHO算法的优化性能进行测试,通过12个变维的基准函数来验证SLHHO算法的有效性与可行性,并对比其他算法与HHO算法的变体,结合寻优过程中的多样性,探索与开发指标进行分析,结果显示SLHHO算法具有较强的寻优能力与优势。

4) 在压力容器设计问题中,SLHHO算法优化后的解更加稳定,验证了SLHHO算法的实用性。

1 相关理论

1.1 SNR距离

在启发式优化算法的寻优过程中,准确地判断当前个体的位置是否趋向最优解,并做出合理的寻

优方式是极其重要的,这样才能减少个体走向不利解,趋向合理的最优解,提升算法的效率。以往的算法采用的方式是利用欧式距离来判断个体之间的位置信息,但这种方式存在一定的局限性。

在机器学习领域,距离的概念从诞生之日起就一直有着广泛的应用,其通常用来度量数据间的相似性,即确保相似的数据彼此接近,而使不同的数据之间的映射距离相离。欧氏距离作为一种有效的度量工具被广泛的应用于诸多的度量学习算法中。然而,随着维数的增大,欧氏空间中任意2点距离度量的差异性越来越弱,从而导致数据趋向于均匀分布,这种现象称为“度量集中”,出现在Yu等描述高维概率分布^[21],而且欧氏距离的计算过程在高维中需要耗费很长的时间,因此,判断数据相似性需要引入更合理的方法来替代欧氏距离,例如,Weinberger等使用马氏距离度量对K-最近邻分类^[22];Yuan等提出一种基于SNR的新型深度度量学习方法,通过构建具有几何可解释性的SNR距离度量,有效量化图像对之间的语义相似性^[23]。由于基于SNR的距离度量可以产生比欧氏距离更多的鉴别特征。本文引入了SNR距离来衡量不同数据间的差异情况,一对数据 p_i 和 p_j 的SNR距离定义为^[24]

$$d_s(p_i, p_j) = \frac{v(P_j - P_i)}{v(P_i)} = \frac{v(h_{ij})}{v(P_i)} \quad (1)$$

式中: $v(z) = \left[\sum_{i=1}^n (z_i - \mu)^2 \right] / n$ 为 z 的方差, μ 为 x 的均值, n 为 x 的维度。较长的SNR距离说明锚定数据和比较数据间的差异较大,因此,本文算法使用SNR距离度量作为相似性度量来代替欧氏距离度量,通过个体间的数据差异来判断位置信息,从而做出合理的寻优手段

1.2 HHO算法简介

HHO算法是2019年提出的一种新型群体智能优化算法,该算法模拟哈里斯鹰的捕食行为,主要分为探索阶段、探索与开发转换阶段和开发阶段。

HHO算法可以从探索转移到开发,然后,根据猎物的逃逸能量在不同的开发行为之间进行转换。在猎物的逃避过程中,能量将大大降低。猎物的逃逸能量 E 为

$$E = 2E_0(1 - t/T) \quad (2)$$

式中: T 为最大迭代次数; E_0 为能量的初始状态。在HHO算法的迭代过程中, E_0 在 $(-1, 1)$ 内均匀随机变化。HHO算法通过 E 的值采用不同的行为策略。

1) 探索阶段 ($|E| \geq 1$)

HHO 算法在初始化后再进行探索行为, 具体模型为

$$x(t+1) = \begin{cases} x_{\text{rand}}(t) - r_1 |x_{\text{rand}}(t) - 2r_2 x(t)| & q \geq 0.5 \\ x_{\text{rabbit}}(t) - x_m(t) - r_3 [L_B + r_4 (U_B - L_B)] & q < 0.5 \end{cases} \quad (3)$$

式中: $x(t+1)$ 为 $t+1$ 次迭代中鹰的位置; $x_{\text{rabbit}}(t)$ 为最优猎物的位置, 表示个体捕捉到最优食物的位置; $r_1 \sim r_4$ 与 q 均为 $[0,1]$ 的均匀随机数; L_B 和 U_B 分别为变量的上限和下限; $x_{\text{rand}}(t)$ 为当前种群内部随机选择的鹰的位置; $x_m(t)$ 为当前种群的平均位置, 具体形式为

$$x_m(t) = \frac{1}{N} \sum_{i=1}^N x_i(t) \quad (4)$$

2) 开发阶段 ($|E| < 1$)

当鹰围攻猎物时, 猎物会试图逃脱追捕, 在这个阶段结合 E 与随机参数 r 提出 4 种不同的行为方式来模拟攻击阶段。

① 软包围 ($|E| \geq 0.5, r \geq 0.5$)

猎物此时具有较高的逃逸能量, 需要对当前区域进行彻底地搜索, 具体数学模型为

$$\begin{cases} x(t+1) = \Delta x(t) - E |J x_{\text{rabbit}}(t) - x(t)| \\ \Delta x(t) = x_{\text{rabbit}}(t) - x(t) \\ J = 2(1 - r_5) \end{cases} \quad (5)$$

式中: r_5 为 $[0,1]$ 的均匀随机数, 表示兔子在整个逃逸过程中的随机跳跃强度; J 值每次迭代中在 $[0,2]$ 随机变化, 以模拟兔子运动的距离。

② 强包围 ($|E| < 0.5, r \geq 0.5$)

兔子能量不足, 鹰对兔子进行压迫式围攻, 具体如下:

$$x(t+1) = x_{\text{rabbit}}(t) - E |\Delta x(t)| \quad (6)$$

③ 渐进式快速俯冲的软包围 ($|E| \geq 0.5, r < 0.5$)

猎物有机会从包围圈中逃脱, 且逃逸能量足够, 因此, 哈里斯鹰需要在进攻前形成一个更加快速智能的软包围圈, 通过以下 2 个策略实施:

$$\begin{cases} Y = x_{\text{rabbit}}(t) - E |J x_{\text{rabbit}}(t) - x(t)| \\ Z = Y + S L_F(D) \\ x(t+1) = \begin{cases} Y & F(Y) < F(x(t)) \\ Z & F(Z) < F(x(t)) \end{cases} \end{cases} \quad (7)$$

式中: L_F 表示 levy 飞行; D 为维度。

④ 渐进式快速俯冲的硬包围 ($|E| < 0.5, r < 0.5$)

猎物虽有一定的能量进行逃逸, 但逃逸能量不

足, 鹰要趁机采用强硬且灵活的方式围攻, 采用以下策略进行狩猎:

$$\begin{cases} x(t+1) = \begin{cases} Y & F(Y) < F(x(t)) \\ Z & F(Z) < F(x(t)) \end{cases} \\ Y = x_{\text{rabbit}}(t) - E |J x_{\text{rabbit}}(t) - x_m(t)| \\ Z = Y + S L_F(D) \end{cases} \quad (8)$$

从式(3)~式(8)可以看出, HHO 算法通过 4 个阶段进行寻优, 其中, 探索与开发能力的分配是通过随机数值进行处理, 但会造成种群适应性较低^[25]。种群适应性是面对不同的寻优环境时都能够较好地找到优质解, 由式(2)~式(8)可知, HHO 算法的策略仅通过随机数值来选择, 缺乏进化性与学习性, 同时逃逸能量是个体寻优范围的关键所在, 其变化更是缺乏多样性, 仅是通过自适应函数来控制, 在面对简单与复杂函数寻优时, 并不能使个体有较好的寻优视野, 因此, 需要对种群的寻优方式进行合理的设计, 是研究的关键所在。

2 本文 SLHHO 算法

2.1 参数控制

智能优化算法中, 合理的参数控制能够使得算法更具全局性, 提升解的精度, 在 HHO 算法中, J 为猎物逃跑的距离, 控制鹰搜索食物范围的能力, 用来控制算法的搜索能力, 为展现 HHO 算法中 J 数值的变化情况, 图 1 为迭代 1 000 次时 J 的变化。




图 1 HHO 算法中迭代变化的 J

Fig. 1 Iterative change of J in HHO algorithm

由图 1 可知, 在 1 000 次的迭代里, J 的变化区间基本一致, 但数值没有更好地遍布整个范围, 在 0.2 以下的数值非常少, 同时 1.8 以上的数值也不多, 这样的变化方式不能具有较好的适应性, 尤其是在简单函数中, 并不能开发有利的精度问题, 而带来的无效性搜索会增加。因此, J 需要一种更加均匀分布的值, 才能应对不同的寻优环境。本文设

计了一种新型的 J 值变化方式,用来适应不同的寻优环境,具体如下:

$$J = 2(1 - \cos(\rho\pi/2)) \quad (9)$$

式中: ρ 为 $[0,1]$ 的均匀随机数,具体参数变化如图2所示。由图2可知,新设计的 J 在变化过程中每个区间都能较好地覆盖,特别是较小的数值上也能覆盖,同时在 J 值的变化路线中并不是一致的,这样有利于开发解的精度,在算法能够找到理想的解时,是需要一定小的 J 来提升局部搜索,找到更优质的解;在复杂优化问题中,较大的数值 J 能够避开不利的局部最优解,探索出合理的高质量解。




图2 SLHHO算法中迭代变化的 J

Fig. 2 Iterative change of J in SLHHO algorithm

2.2 协调学习

个体需要对种群外的解进行勘探,同时还需要结合自己种群内的信息,通过这些信息来更加可靠地找到优质解。在HHO算法中鹰的搜索及捕食方式仅是根据猎物来展开,但自身种群内的个体缺乏信息交流,仅跟最优个体、平均位置与随机位置进行一定的关联,缺乏内部维度的交流,同时缺乏智能化地更新,不能对不同的寻优环境进行决策。为此,本文设计了一种协调学习来提升HHO算法中个体之间的信息交流,通过SNR距离来判断个体的状态,来提升种群的学习性与适应性。具体如下:

$$\begin{cases} X_{i,j}(t) = \begin{cases} x_{rabbit,l}(t) + b_1(x_{worst,k}(t) - x_{i,h}(t)) & d_1 \geq d_2 \\ x_{rabbit,l}(t) + b_1(x_{worst,k}(t) - x_{M,h}(t)) & \text{其他} \end{cases} \\ d_1 = v(x_i(t) - x_{worst}(t)) / v(x_{worst}(t)) \\ d_2 = v(x_i(t) - x_{rabbit}(t)) / v(x_{rabbit}(t)) \\ w = \max P(f) \\ x_{worst}(t) = X_w(t) \end{cases} \quad (10)$$

式中: b_1 为 $[0,1]$ 的均匀随机数; $x_M(t)$ 为减去最优位

置与最差位置后得到的平均位置,排除极端位置的影响,这样就能更加明确地代表种群的大致方向;以最小化问题为例, f 为种群个体计算后对应的适应度值数组; $\max P(f)$ 为提取最大值的对应下标位置; w 为找到的最大值的下标; $x_{worst}(t)$ 为 t 次迭代时的最差位置。对得到的 $x_M(t)$ 、 $x_{worst}(t)$ 、 $x_{rabbit}(t)$ 位置信息数据进行随机不重复的选择, l 、 k 、 h 为随机选取的维度, $x_{worst,k}(t)$ 为在最差位置 $x_{worst}(t)$ 中随机选取的第 k 维的值, $x_{rabbit,l}(t)$ 、 $x_{i,h}(t)$ 、 $x_{M,h}(t)$ 的含义以此类推。通过这些个体各维度上的信息随机进行交叉学习,来提升种群的搜索效率。 $d_1 \geq d_2$ 说明当前个体位置信息与最优位置相似,需要将最优位置进行较远的搜索,进行个体间信息交流,最后,更新出新的位置。反之则说明当前个体与最差位置相似,则需要最优位置进行较小的搜索,需要将当前个体与平均位置保持一致,放弃原来的位置且进行位置替换。2种方式的紧密结合,共同推进种群内部纵横交错的寻优路线,并找到合理的最优位置。

为更好地理解个体之间的交流与变化,假定维度为3,协调学习原理如图3所示。图3中黑色代表所随机选择的维度,由3个不同的位置信息来共同引导产生新的个体。值得注意的是,这类方案需要保证各维度的上下界均是一致的,否则变换后的无效性更新会增多。




图3 协调学习原理

Fig. 3 Coordinated learning schematic

2.3 本文算法的流程

为提升HHO算法的种群内部交流且提升算法的学习性与适应性,本文算法设计了一种协调学习策略,用来判断种群内部个体的位置特征,便于做出合理的位置更新方式,再设计了一种新的逃逸步长,适应不同环境的寻优,从而找到更优质的解。本文算法具体流程如下:

步骤1 设定初始参数:种群数量,问题的上下界及维度,最大迭代次数(评估)。

步骤 2 随机初始化种群。

步骤 3 迭代开始, 计算个体对应的适应度值。

步骤 4 采用协调学习进行更新位置信息, 并找到当前最优猎物。

步骤 5 更新能量值 E 与逃逸距离 J 。

步骤 6 若 $|E| > 1$, 进行探索阶段则按式 (3)~式 (4) 执行探索阶段的更新; 若 $|E| < 1$, 会随机生成判断值 r , 哈里斯鹰需要根据能量值 E 和判断值 r 做出以下更新: ①若 $|E| \leq 0.5$ 且 $r \leq 0.5$, 则按式 (8) 执行渐进式快速俯冲的硬包围; 若 $|E| \leq 0.5$ 且 $r > 0.5$, 则按式 (6) 执行强包围; ②若 $|E| > 0.5$ 且 $r \leq 0.5$, 则按式 (7) 执行渐进式快速俯冲的软包围; 若 $|E| > 0.5$ 且 $r > 0.5$, 则按式 (5) 执行软包围。

步骤 7 判断是否到达结束条件, 若是则输出最终的最优解及位置, 否则返回步骤 3。

2.4 时间复杂度分析

算法的时间复杂度分析是评价算法好坏的一个重要因素, 在合理的时间内求取最好的效果是每个算法的目标。在原 HHO 算法中, 寻优过程分为 3 个阶段, 计算 2 次种群的适应度值, 其时间复

度为

$$O_{\text{HHO}} = O(T(O(T_1 + T_2 + T_3))) = O(T(N_D + N_D)) = O(TN_D) \quad (11)$$

SLHHO 算法中 J 与 HHO 算法中一样, 都需要计算 2 次数种群的适应度值, 仅增加了协调学习这一过程, 其时间复杂度为

$$O_{\text{SLHHO}} = O(T(O(T_1 + T_2 + T_3 + T_4))) = O(T(N_D + N_D + N_D)) = O(TN_D) \quad (12)$$

由此可见, SLHHO 算法并没有过分地增加时间复杂度, 在统一评价次数的标准下 HHO 算法与 SLHHO 算法具有相同的时间复杂度, 保持了一定的公平性。

3 性能测试

为检验 SLHHO 算法的优化能力, 本文采用 12 个基准测试函数来验证, 具体函数信息如表 1 所示。所有函数均为变维函数, $f_1 \sim f_7$ 为单峰函数, $f_8 \sim f_{12}$ 为多峰函数, 2 种类型的函数共同验证算法的全局优化能力。

表 1 各函数信息

Table 1 Information for each function

函数	区间	最小值
$f_1(x) = \sum_{i=1}^n x_i^2$	$[-100, 100]$	0
$f_2(x) = \sum_{i=1}^n x_i + \prod_{i=1}^n x_i $	$[-10, 10]$	0
$f_3(x) = \sum_{i=1}^n \left(\sum_{j=1}^i x_j \right)^2$	$[-100, 100]$	0
$f_4(x) = \max_i \{ x_i , 1 \leq i \leq n\}$	$[-100, 100]$	0
$f_5(x) = \sum_{i=1}^{n-1} [100(x_{i+1} - x_i^2)^2 + (x_i - 1)^2]$	$[-30, 30]$	0
$f_6(x) = \sum_{i=1}^n (x_i + 0.5)^2$	$[-100, 100]$	0
$f_7(x) = \sum_{i=1}^n i x_i^4 + \text{random}[0, 1)$	$[-1.28, 1.28]$	0
$f_8(x) = \sum_{i=1}^n -x_i \sin\left(\sqrt{ x_i }\right)$	$[-500, 500]$	$-418.982 9n$
$f_9(x) = \sum_{i=1}^n (x_i^2 - 10 \cos(2\pi x_i) + 10)$	$[-5.12, 5.12]$	0
$f_{10}(x) = -20 \exp\left(-0.2 \sqrt{\frac{1}{n} \sum_{i=1}^n x_i^2}\right) - \exp\left(\frac{1}{n} \sum_{i=1}^n \cos(2\pi x_i)\right) + 20 + e$	$[-32, 32]$	0
$f_{11}(x) = \frac{1}{4000} \sum_{i=1}^n x_i^2 - \prod_{i=1}^n \cos\left(\frac{x_i}{\sqrt{i}}\right)$	$[-600, 600]$	0
$f_{12}(x) = \frac{\pi}{n} \left[10 \sin(\pi y_1) + \sum_{i=1}^{n-1} (y_i - 1)^2 (1 + 10 \sin^2(\pi y_{i+1})) + (y_n - 1)^2 \right] + \sum_{i=1}^n u(x_i, 10, 100, 4)$ $y_i = 1 + \frac{x_i + 1}{4}$ $u(x_i, a, k, m) = \begin{cases} k(x_i - a)^m & x_i > a \\ 0 & -a < x_i < a \\ k(-x_i - a)^m & x_i < -a \end{cases}$	$[-50, 50]$	0

3.1 与其他算法的变体进行比较

为证明 SLHHO 算法的新颖性与优势性,将 SLHHO 算法与近几年提出的算法(见表 1)的变体进行比较,这些算法有 ATOA^[26]、DAOA^[27]、EJAYA^[28]、IGWO^[29]、MFPA^[30]、PSOGSA^[31]、TACPSO^[32],这些算法都是近几年提出的算法,并在基准函数中进行了验证,具有一定的竞争性及代表性。各算法的内部参数如表 2 所示。每个算法的内部结构不一样,为保证各算法实验的公平性,每个算法的种群数量为 100,最大评估次数为 50 000,维度为 30,其中,最大评估次数是计算目标函数的次数。每个算法独立运行 30 次,并计算 30 次数据的平均值 f_{ave} ,最小值 f_{min} ,标准差 f_{std} ,用来衡量算

法的寻优能力及稳定性。实验环境为 MATLAB 2019a, Windows10 操作系统,运行内存为 8 GB;另一方面,为清晰地看出各算法之间地差异,采用 Wilcoxon 检验对 30 次优化的结果统计测试,各算法在显著水平为 0.05 下进行,如表 3 所示,“+”表示 SLHHO 算法优于其他算法,“=”表示 SLHHO 算法与其他算法性能相当,“-”则表示性能不如其他算法, f_{cm} 表示两算法的对比结果,最后,结合与实验指标来给出排名 f_{rank} 。为直观展现 SLHHO 算法的优势,本文实验数据均将 SLHHO 算法较优(最小)的指标进行加粗;最后,为清晰的看出各算法的综合寻优能力及普适性,将表 3 中的排名进行汇总。

表 2 各算法需设置的内部参数

Table 2 Internal parameters to be set for each algorithm

算法	参数
ATOA ^[26]	$f_{\text{min}}=0.2, f_{\text{max}}=1.0, \alpha=5, \mu=0.499, \varepsilon=2.2204 \times 10^{-16}$
MFPA ^[30]	$n=50, P=0.8, \gamma_1=1, \gamma_2=3, \lambda=1.5, \text{cloning array}=[9,8,7,6,5,4,3,2,1,1,1,1,1,1]$
PSOGSA ^[31]	$w=\text{rand}(1), c_1=0.5, c_2=1.5, G_0=1, \alpha=20$
TACPSO ^[32]	$W_{\text{max}}=0.9, W_{\text{min}}=0.4, c_1=c_2=2$

由表 3 可知, SLHHO 算法在所有函数上的指标均是较优的,综合排名是较为靠前的,验证了 SLHHO 算法具有较强的普适性。与其他算法的变体相比, SLHHO 算法具有较好的寻优能力,同时在 f_1, f_8, f_9, f_{11} 均能直接找到理论最优值,较其他算法具有明显的优势,另一方面, HHO 算法在 f_8, f_9, f_{11} 也能直接找到理论最优值,由此可见, SLHHO 算法并没有削弱 HHO 算法原本的寻优能力,在其基础之上开发了更好的寻优手段,彰显了 2 种策略的有效性,使得种群寻优机制变得更加智能化。

收敛速度是元启发式算法追求的一大目标,也是需要考量的一大因素。为彰显各算法在寻优速度上的差异,本文将各算法在 30 次运行结果下的平均收敛轨迹进行展示,具体如图 4 所示,图中纵坐标为平均目标函数值,横坐标为评估次数。

由图 4 可知, SLHHO 算法在各函数中的收敛速度均较快,除 f_8 外, SLHHO 算法在其他函数上的收敛效果具有一定的优势。进一步来看,在 $f_1 \sim f_7$ 单峰函数中, SLHHO 算法的收敛速度明显较快且精度得到有效的提高;在 $f_8 \sim f_{12}$ 这些多峰函数中, SLHHO 算法的收敛速度存在一定的优势且精度较高,具有一定的抗局部吸引能力, HHO 算法的收敛效果仅排在 SLHHO 算法之后,其他算法在前期出现早熟现象。由此可知,种群内的交流加快使得收敛速度得到一定的提升,同时也证明了改进

HHO 算法具有一定的价值。

3.2 与 HHO 算法的变体对比

为展现 SLHHO 算法的竞争性与策略的有效性,本节将 SLHHO 算法与 HHO 算法的变体进行比较,同时考虑 2 种策略组合的合理性,将其进行拆分进行试验,设定调整 J 的 HHO 算法为 HHO-1,设定加入协调学习的 HHO 算法为 HHO-2,另外也将近几年提出的 HHO 算法变体加入对比实验中,算法有 NCHHO^[33]、LMHHO^[34]、LHHO^[35]、JOS-HHO^[36]、THHO^[19]、DAHHO^[20]。测试维度分别为 30 与 100。其他实验参数设置与细则如上一致,具体结果如表 4 和表 5 所示。考虑各算法在全部函数上的综合优化能力,将各算法的平均值进行 Friedman 检验^[37],在显著水平 0.05 下进行,综合排名 f_{rank} 结果如表 6 中所示。由表 4 和表 5 可知, SLHHO 算法在各函数中的较优指标数目依然是较多的,仅在 30 维中的 f_3, f_4, f_{12} 与 100 维的 f_1, f_4, f_6, f_7 中, SLHHO 算法不是最优的数值;在 30 维的 $f_1, f_6, f_7, f_9, f_{10}, f_{11}$ 与 100 维的 $f_5, f_9, f_{10}, f_{11}, f_{12}$ 中,可看出 SLHHO 算法的寻优结果的优势较大,从 Friedman 的综合排名来看, SLHHO 算法在 30 维与 100 维中分别为 2.916 7、3.166 7,在与 HHO 算法的其他变体进行对比后,排名依旧是最高的。另一方面, HHO-2 的综合排名相对靠前,可以看出协调学习的有效性。由此可见, SLHHO 算法的综合寻优

表3 SLHHO算法与其他算法的变体

Table 3 SLHHO algorithm and other algorithm variants

算法	$f_{\min}$											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	0	8.60×10^{-231}	4.89×10^{-100}	1.25×10^{-59}	0	0	2.82×10^{-6}	-1.26×10^4	0	8.88×10^{-16}	0	3.58×10^{-19}
ATOA ^[26]	5.59×10^{-12}	1.18×10^{-39}	4.12×10^{-3}	2.79×10^{-3}	2.88×10^{-1}	5.56×10^{-1}	6.13×10^{-4}	-6.67×10^3	0	3.97×10^{-10}	0	2.53×10^{-1}
DAOA ^[27]	4.21×10^4	0	0	7.57×10^1	7.36×10^3	4.61×10^4	3.49×10^{-2}	-4.03×10^3	3.57×10^1	8.88×10^{-16}	9.19×10^1	1.85×10^8
EJAYA ^[28]	6.17×10^{-6}	1.52×10^{-3}	1.57	1.27×10^{-1}	2.31×10^1	1.37×10^{-5}	6.34×10^{-3}	-7.30×10^3	8.05	3.06×10^{-3}	1.48×10^{-5}	3.39×10^{-7}
IGWO ^[29]	6.14×10^{-34}	1.85×10^{-21}	3.52×10^{-5}	8.41×10^{-9}	2.51×10^1	3.93×10^{-2}	6.78×10^{-4}	-7.55×10^3	5.68	1.15×10^{-14}	0	1.12×10^{-3}
MFPA ^[30]	1.27	9.02×10^{-4}	3.84×10^2	8.28	2.20×10^1	2.69	7.71×10^{-2}	-1.08×10^4	2.15×10^1	2.57	8.57×10^{-1}	7.38×10^{-1}
PSOGSA ^[31]	4.88×10^{-19}	3.05×10^{-9}	1.08×10^3	1.85×10^1	1.87×10^1	4.84×10^{-19}	1.89×10^{-2}	-9.76×10^3	7.86×10^1	5.80×10^{-10}	7.94×10^{-3}	3.10×10^{-2}
TACPSO ^[32]	1.59×10^{-8}	8.43×10^{-5}	2.02	6.52×10^{-1}	2.78	2.33×10^{-9}	5.95×10^{-3}	-1.04×10^4	2.89×10^1	1.04×10^{-4}	4.90×10^{-9}	4.05×10^{-8}
HHO ^[9]	3.64×10^{-44}	3.02×10^{-19}	3.15×10^{-32}	2.08×10^{-20}	1.14×10^{-5}	4.97×10^{-9}	2.58×10^{-6}	-1.26×10^4	0	8.88×10^{-16}	0	1.65×10^{-8}
算法	f_{ave}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	0	8.85×10^{-58}	5.45×10^{-82}	1.95×10^{-50}	1.66×10^{-7}	6.05×10^{-12}	4.34×10^{-5}	-1.26×10^4	0	8.88×10^{-16}	0	1.48×10^{-8}
ATOA ^[26]	7.56×10^{-4}	7.02×10^{-4}	4.00×10^2	3.47×10^{-2}	2.92×10^1	8.05×10^{-1}	5.62×10^{-3}	-5.34×10^3	0	9.30×10^{-3}	5.17×10^{-7}	9.47×10^{-1}
DAOA ^[27]	6.12×10^4	4.23×10^1	7.82×10^4	8.40×10^1	1.06×10^4	5.95×10^4	3.11×10^1	-2.75×10^3	1.13×10^2	1.08×10^1	5.13×10^2	4.69×10^8
EJAYA ^[28]	7.52×10^{-5}	6.34×10^{-3}	9.76	4.80×10^{-1}	2.41×10^{-1}	9.62×10^{-5}	1.48×10^{-2}	-6.37×10^3	5.00×10^1	1.64	1.70×10^{-2}	1.03×10^{-1}
IGWO ^[29]	1.04×10^{-31}	8.36×10^{-21}	4.15×10^{-3}	4.58×10^{-7}	2.55×10^1	8.72×10^{-2}	2.14×10^{-3}	-5.88×10^3	6.45×10^1	1.76×10^{-14}	6.55×10^{-3}	3.80×10^{-3}
MFPA ^[30]	1.12×10^1	3.29×10^{-2}	1.63×10^3	1.56×10^1	2.99×10^1	6.86	1.54×10^{-1}	-8.20×10^3	5.66×10^1	1.50×10^1	1.07	4.24
PSOGSA ^[31]	2.02×10^{-1}	1.87×10^{-2}	6.94×10^3	3.56×10^1	2.44×10^1	3.37×10^2	5.89×10^{-2}	-8.32×10^3	1.23×10^2	1.02×10^1	9.21	4.50
TACPSO ^[32]	6.55×10^{-5}	4.87×10^{-3}	4.29×10^1	2.02	3.33×10^1	8.81×10^{-5}	1.88×10^{-2}	-9.27×10^3	5.82×10^1	7.01×10^{-1}	1.32×10^{-2}	2.07×10^{-1}
HHO ^[9]	1.44×10^{-27}	2.18×10^{-15}	3.00×10^{-17}	1.83×10^{-15}	8.10×10^{-4}	1.08×10^{-5}	1.12×10^{-4}	-1.26×10^4	0	2.79×10^{-14}	0	7.97×10^{-7}
算法	f_{std}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	0	4.85×10^{-57}	2.22×10^{-81}	9.12×10^{-50}	9.07×10^{-7}	2.63×10^{-11}	4.05×10^{-5}	2.48×10^{-2}	0	1.00×10^{-31}	0	7.42×10^{-8}
ATOA ^[26]	9.91×10^{-4}	3.83×10^{-3}	$2.18 \times 10^{+3}$	1.83×10^{-2}	1.16	1.83×10^{-1}	4.12×10^{-3}	5.50×10^2	0	1.23×10^{-2}	2.83×10^{-6}	5.89×10^{-1}
DAOA ^[27]	6.62×10^3	1.35×10^1	3.41×10^4	3.79	1.37×10^3	5.42×10^3	2.55×10^1	4.73×10^2	3.60×10^1	9.62	1.03×10^2	1.08×10^8
EJAYA ^[28]	9.26×10^{-5}	4.82×10^{-3}	9.07	2.16×10^{-1}	5.34×10^{-1}	7.18×10^{-5}	4.96×10^{-3}	6.31×10^2	3.22×10^1	6.13×10^{-1}	3.75×10^{-2}	1.41×10^{-1}
IGWO ^[29]	1.84×10^{-31}	7.11×10^{-21}	9.53×10^{-3}	3.44×10^{-7}	1.97×10^{-1}	7.33×10^{-2}	1.22×10^{-3}	6.19×10^2	4.94×10^1	3.51×10^{-15}	1.30×10^{-2}	2.34×10^{-3}
MFPA ^[30]	1.93×10^1	8.68×10^{-2}	7.72×10^2	4.10	7.96	4.40	4.36×10^{-2}	1.12×10^3	1.81×10^1	6.80	7.77×10^{-2}	2.31
PSOGSA ^[31]	5.74×10^{-1}	5.64×10^{-2}	3.89×10^3	1.96×10^1	1.92	1.84×10^3	1.62×10^{-2}	7.08×10^2	2.83×10^1	6.78	2.75×10^1	3.25
TACPSO ^[32]	3.28×10^{-4}	4.94×10^{-3}	4.02×10^1	1.32	2.33×10^1	4.33×10^{-4}	7.82×10^{-3}	6.19×10^2	1.90×10^1	7.05×10^{-1}	1.44×10^{-2}	2.79×10^{-1}
HHO ^[9]	6.83×10^{-27}	4.05×10^{-15}	1.64×10^{-16}	4.48×10^{-15}	1.13×10^{-3}	1.82×10^{-5}	1.45×10^{-4}	1.75×10^{-1}	0	1.31×10^{-13}	0	8.28×10^{-7}
算法	f_{cm}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO												
ATOA ^[26]	+	+	+	+	+	+	+	+	=	+	+	+
DAOA ^[27]	+	+	+	+	+	+	+	+	+	+	+	+
EJAYA ^[28]	+	+	+	+	+	+	+	+	+	+	+	+
IGWO ^[29]	+	+	+	+	+	+	+	+	+	+	+	+
MFPA ^[30]	+	+	+	+	+	+	+	+	+	+	+	+
PSOGSA ^[31]	+	+	+	+	+	+	+	+	+	+	+	+
TACPSO ^[32]	+	+	+	+	+	+	+	+	+	+	+	+
HHO ^[9]	+	+	+	+	+	+	+	+	=	+	=	+
算法	f_{rank}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	1	1	1	1	1	1	1	1	1	1	1	1
ATOA ^[26]	6	4	6	4	6	6	4	8	1	4	2	6
DAOA ^[27]	9	9	9	9	9	9	9	9	6	8	8	9
EJAYA ^[28]	5	6	4	5	3	4	5	6	2	6	5	4
IGWO ^[29]	2	2	3	3	5	5	3	7	5	2	3	3
MFPA ^[30]	8	8	7	7	7	7	8	5	3	9	6	7
PSOGSA ^[31]	7	7	8	8	4	8	7	4	7	7	7	8
TACPSO ^[32]	4	5	5	6	8	3	6	3	4	5	4	5
HHO ^[9]	3	3	2	2	2	2	2	2	1	3	1	2




图4 各算法平均收敛图

Fig. 4 Average convergence plot of each algorithm

能力是较强的,进一步说明了 SLHHO 算法有力的竞争性与可行性。

3.3 勘探开发与多样性检验

算法的多样性是指在寻优过程中个体分布空

间的离散程度,离散程度较大时,说明算法在一定空间内,开拓解的能力也较强。探索与开发是指算法在全局与局部空间内挖掘有效解的能力,是显示算法合理性的要素之一,探索与开发表现地越出色

表 4 SLHHO 算法与 HHO 算法的变体 (维度为 30)
Table 4 SLHHO algorithm and HHO algorithm variants (dim=30)

算法	$f_{\min}$											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	0	0	4.89×10^{-100}	1.25×10^{-59}	0	0	2.82×10^{-6}	-8.60	0	8.88×10^{-16}	0	3.58×10^{-19}
NCHHO ^[33]	3.93×10^{-246}	3.93×10^{-246}	1.75×10^{-220}	1.73×10^{-115}	2.88×10^1	1.62	4.24×10^{-6}	-6.80	0	8.88×10^{-16}	0	4.56×10^{-2}
LMHHO ^[34]	3.07×10^{-44}	3.07×10^{-44}	3.01×10^{-44}	1.31×10^{-25}	7.35×10^{-9}	1.33×10^{-10}	5.00×10^{-7}	-8.60	0	8.88×10^{-16}	0	5.54×10^{-10}
LHHO ^[35]	3.14×10^{-75}	3.14×10^{-75}	3.09×10^{-70}	4.16×10^{-39}	2.27×10^{-6}	1.10×10^{-10}	1.23×10^{-5}	-8.60	0	8.88×10^{-16}	0	3.61×10^{-10}
THHO ^[10]	1.28×10^{-246}	1.28×10^{-246}	4.75×10^{-246}	2.62×10^{-127}	7.20×10^{-8}	2.95×10^{-13}	1.48×10^{-6}	-8.60	0	8.88×10^{-16}	0	9.20×10^{-12}
DAHHO ^[20]	2.03×10^{-60}	2.03×10^{-60}	1.30×10^{-50}	1.03×10^{-30}	2.54×10^{-6}	4.11×10^{-8}	2.37×10^{-6}	-8.60	0	8.88×10^{-16}	0	6.93×10^{-8}
JOS-HHO ^[36]	1.50×10^{-16}	1.50×10^{-16}	1.39×10^{-15}	1.11×10^{-9}	8.06×10^{-5}	5.24×10^{-5}	6.60×10^{-6}	-8.60	0	8.77×10^{-11}	0	9.23×10^{-7}
HHO-1	8.19×10^{-42}	8.19×10^{-42}	2.68×10^{-30}	3.25×10^{-18}	0	1.51×10^{-8}	4.06×10^{-5}	-8.60	0	8.88×10^{-16}	0	3.74×10^{-10}
HHO-2	7.82×10^{-123}	7.82×10^{-123}	4.38×10^{-104}	1.48×10^{-59}	5.19×10^{-8}	5.48×10^{-7}	2.88×10^{-6}	-8.60	0	8.88×10^{-16}	0	5.90×10^{-24}
算法	f_{ave}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	0	8.85×10^{-58}	5.45×10^{-82}	1.95×10^{-50}	1.66×10^{-7}	6.05×10^{-12}	4.34×10^{-5}	-8.60	0	8.88×10^{-16}	0	1.48×10^{-8}
NCHHO ^[33]	3.61×10^{-222}	9.70×10^{-115}	3.26×10^{-202}	2.25×10^{-106}	2.88×10^1	2.36	6.59×10^{-5}	-6.16 $\times 10^1$	0	8.88×10^{-16}	0	1.02×10^{-1}
LMHHO ^[34]	1.33×10^{-29}	6.45×10^{-16}	7.63×10^{-28}	3.78×10^{-16}	1.70×10^{-4}	5.98×10^{-7}	6.22×10^{-5}	-8.60	0	1.36×10^{-15}	0	2.11×10^{-7}
LHHO ^[35]	5.71×10^{-64}	4.29×10^{-32}	2.86×10^{-54}	8.66×10^{-33}	3.85×10^{-3}	2.21×10^{-6}	9.27×10^{-5}	-8.60	0	8.88×10^{-16}	0	1.03×10^{-6}
THHO ^[10]	3.67×10^{-234}	9.42×10^{-117}	3.74×10^{-226}	9.85×10^{-117}	1.46×10^{-3}	6.16×10^{-7}	7.59×10^{-5}	-8.60	0	8.88×10^{-16}	0	2.46×10^{-6}
DAHHO ^[20]	1.36×10^{-47}	2.04×10^{-26}	2.55×10^{-35}	4.94×10^{-26}	5.28×10^{-3}	4.96×10^{-5}	8.77×10^{-5}	-8.60	0	8.88×10^{-16}	0	3.76×10^{-6}
JOS-HHO ^[36]	6.37×10^{-10}	6.25×10^{-6}	2.59×10^{-7}	6.87×10^{-6}	1.51×10^{-2}	1.47×10^{-3}	3.38×10^{-4}	-8.60	4.15×10^{-10}	1.86×10^{-6}	3.34×10^{-9}	7.92×10^{-5}
HHO-1	5.49×10^{-24}	1.68×10^{-12}	3.18×10^{-12}	6.57×10^{-13}	1.53×10^{-21}	4.75×10^{-5}	2.45×10^{-4}	-8.60	0	1.30×10^{-12}	0	2.63×10^{-6}
HHO-2	9.46×10^{-102}	2.31×10^{-55}	3.35×10^{-89}	7.67×10^{-53}	1.84×10^{-4}	3.42×10^{-5}	5.91×10^{-5}	-8.60	0	8.88×10^{-16}	0	8.22×10^{-14}
算法	f_{std}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	0	4.85×10^{-57}	2.22×10^{-81}	9.12×10^{-50}	9.07×10^{-7}	2.63×10^{-11}	4.05×10^{-5}	2.48×10^{-2}	0	1.00×10^{-31}	0	7.42×10^{-8}
NCHHO ^[33]	0	5.21×10^{-114}	0	1.18×10^{-105}	2.11×10^{-2}	4.51×10^{-1}	7.15×10^{-5}	$1.74 \times 10^{+3}$	0	1.00×10^{-31}	0	3.90×10^{-2}
LMHHO ^[34]	5.41×10^{-29}	1.59×10^{-15}	3.94×10^{-27}	1.78×10^{-15}	4.21×10^{-4}	9.84×10^{-7}	5.70×10^{-5}	3.49×10^{-2}	0	2.59×10^{-15}	0	4.59×10^{-7}
LHHO ^[35]	1.68×10^{-63}	1.71×10^{-31}	8.21×10^{-54}	2.98×10^{-32}	7.80×10^{-3}	3.19×10^{-6}	5.07×10^{-5}	1.82×10^{-2}	0	1.00×10^{-31}	0	1.77×10^{-6}
THHO ^[10]	0	5.10×10^{-116}	0	5.10×10^{-116}	5.77×10^{-3}	1.92×10^{-6}	8.68×10^{-5}	1.16	0	1.00×10^{-31}	0	7.00×10^{-6}
DAHHO ^[20]	7.25×10^{-47}	8.76×10^{-26}	1.09×10^{-34}	1.25×10^{-25}	5.54×10^{-3}	7.85×10^{-5}	1.04×10^{-4}	5.42×10^{-1}	0	1.00×10^{-31}	0	5.35×10^{-6}
JOS-HHO ^[36]	1.97×10^{-9}	8.74×10^{-6}	7.26×10^{-7}	1.02×10^{-5}	2.11×10^{-2}	1.77×10^{-3}	2.93×10^{-4}	1.35	8.53×10^{-10}	2.66×10^{-6}	1.45×10^{-8}	7.29×10^{-5}
HHO-1	2.82×10^{-23}	4.49×10^{-12}	1.22×10^{-11}	1.90×10^{-12}	8.40×10^{-21}	6.01×10^{-5}	2.08×10^{-4}	5.75×10^{-2}	0	5.98×10^{-12}	0	3.55×10^{-6}
HHO-2	5.18×10^{-101}	8.26×10^{-55}	1.83×10^{-88}	2.63×10^{-52}	1.96×10^{-4}	4.72×10^{-5}	5.16×10^{-5}	3.45×10^{-2}	0	1.00×10^{-31}	0	4.06×10^{-13}

表 5 SLHHO 算法与 HHO 算法的变体 (维度为 100)

Table 5 SLHHO algorithm and HHO algorithm variants (dim=100)

算法	$f_{\min}$											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	1.10×10^{-112}	2.48×10^{-68}	2.05×10^{-105}	2.70×10^{-60}	0	5.56×10^{-8}	1.85×10^{-6}	-37.9	0	8.88×10^{-16}	0	1.54×10^{-20}
NCHHO ^[33]	1.25×10^{-239}	6.64×10^{-122}	3.12×10^{-214}	1.28×10^{-116}	9.82×10^1	5.87	2.51×10^{-6}	-36.6	0	8.88×10^{-16}	0	1.15×10^{-1}
LMHHO ^[34]	2.28×10^{-42}	5.70×10^{-23}	9.74×10^{-38}	2.61×10^{-23}	2.51×10^{-7}	5.25×10^{-11}	4.95×10^{-6}	-37.9	0	8.88×10^{-16}	0	2.49×10^{-12}
LHHO ^[35]	6.78×10^{-80}	9.25×10^{-38}	8.52×10^{-71}	6.23×10^{-39}	1.22×10^{-5}	3.99×10^{-8}	9.72×10^{-6}	-37.9	0	8.88×10^{-16}	0	7.51×10^{-11}
THHO ^[10]	7.71×10^{-254}	9.11×10^{-125}	2.86×10^{-248}	1.53×10^{-126}	1.27×10^{-7}	1.66×10^{-11}	3.42×10^{-7}	-37.9	0	8.88×10^{-16}	0	8.16×10^{-13}
DAHHO ^[20]	6.55×10^{-58}	2.58×10^{-32}	3.92×10^{-50}	3.62×10^{-32}	0	1.10×10^{-6}	1.41×10^{-5}	-37.9	0	8.88×10^{-16}	0	5.71×10^{-9}
JOS-HHO ^[36]	2.34×10^{-17}	2.57×10^{-8}	1.81×10^{-11}	2.17×10^{-12}	7.43×10^{-3}	2.72×10^{-4}	1.72×10^{-5}	-37.9	0	1.46×10^{-10}	1.89×10^{-15}	7.14×10^{-7}
HHO-1	9.94×10^{-21}	2.09×10^{-11}	2.41×10^{-20}	2.00×10^{-10}	2.11×10^{-5}	4.57×10^{-5}	3.40×10^{-6}	-37.9	0	2.30×10^{-11}	0	6.70×10^{-7}
HHO-2	9.26×10^{-77}	4.64×10^{-41}	5.63×10^{-63}	6.69×10^{-39}	7.85×10^{-5}	1.53×10^{-8}	1.24×10^{-7}	-37.9	0	8.88×10^{-16}	0	1.32×10^{-8}
算法	f_{ave}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	5.33×10^{-99}	3.46×10^{-54}	1.73×10^{-77}	2.41×10^{-50}	0	2.01×10^{-4}	4.90×10^{-5}	-37.9	0	8.88×10^{-16}	0	2.89×10^{-9}
NCHHO ^[33]	5.23×10^{-220}	2.09×10^{-115}	2.42×10^{-198}	3.53×10^{-107}	9.83×10^1	7.95	8.19×10^{-5}	-21.2	0	8.88×10^{-16}	0	1.87×10^{-1}
LMHHO ^[34]	1.16×10^{-30}	2.17×10^{-14}	1.01×10^{-25}	3.41×10^{-16}	5.20×10^{-4}	1.74×10^{-6}	7.11×10^{-5}	-37.9	0	1.72×10^{-15}	0	1.86×10^{-8}
LHHO ^[35]	1.56×10^{-61}	3.36×10^{-31}	6.89×10^{-48}	5.71×10^{-32}	1.21×10^{-2}	1.97×10^{-5}	1.05×10^{-4}	-37.9	0	8.88×10^{-16}	0	8.80×10^{-7}
THHO ^[10]	5.65×10^{-229}	2.20×10^{-117}	2.12×10^{-228}	2.10×10^{-117}	2.26×10^{-3}	8.72×10^{-6}	4.88×10^{-5}	-37.9	0	8.88×10^{-16}	0	1.94×10^{-8}
DAHHO ^[20]	1.07×10^{-46}	1.42×10^{-26}	1.20×10^{-37}	7.80×10^{-26}	3.32×10^{-6}	2.26×10^{-3}	3.04×10^{-4}	-37.9	0	8.88×10^{-16}	0	9.55×10^{-6}
JOS-HHO ^[36]	4.38×10^{-9}	3.01×10^{-5}	6.64×10^{-5}	5.43×10^{-6}	1.76×10^{-1}	8.32×10^{-3}	2.71×10^{-4}	-37.9	7.18×10^{-9}	4.93×10^{-6}	5.14×10^{-9}	5.67×10^{-5}
HHO-1	2.98×10^{-10}	3.02×10^{-7}	3.06×10^{-8}	5.27×10^{-7}	5.05×10^{-2}	5.54×10^{-3}	1.22×10^{-4}	-37.9	3.16×10^{-12}	3.93×10^{-8}	2.18×10^{-12}	1.50×10^{-5}
HHO-2	5.80×10^{-62}	2.03×10^{-34}	5.49×10^{-47}	4.17×10^{-32}	1.74×10^{-3}	4.57×10^{-5}	3.27×10^{-5}	-37.9	0	8.88×10^{-16}	0	4.15×10^{-7}
算法	f_{std}											
	f_1	f_2	f_3	f_4	f_5	f_6	f_7	f_8	f_9	f_{10}	f_{11}	f_{12}
SLHHO	2.88×10^{-98}	1.84×10^{-53}	8.16×10^{-77}	7.89×10^{-50}	0	3.14×10^{-4}	3.69×10^{-5}	2.41×10^{-1}	0	1.00×10^{-31}	0	6.78×10^{-9}
NCHHO ^[33]	0	8.89×10^{-115}	0	1.77×10^{-106}	6.68×10^{-2}	1.95	7.59×10^{-5}	8.50×10^3	0	1.00×10^{-31}	0	6.79×10^{-2}
LMHHO ^[34]	4.72×10^{-30}	8.97×10^{-14}	5.52×10^{-25}	1.27×10^{-15}	1.25×10^{-3}	3.20×10^{-6}	6.49×10^{-5}	1.14	0	3.32×10^{-15}	0	3.66×10^{-8}
LHHO ^[35]	8.32×10^{-61}	1.75×10^{-30}	3.13×10^{-47}	2.76×10^{-31}	2.22×10^{-2}	3.56×10^{-5}	6.56×10^{-5}	3.48×10^{-2}	0	1.00×10^{-31}	0	1.28×10^{-6}
THHO ^[10]	0	1.08×10^{-116}	0	7.70×10^{-117}	8.19×10^{-3}	2.88×10^{-5}	4.07×10^{-5}	3.57	0	1.00×10^{-31}	0	5.66×10^{-8}
DAHHO ^[20]	5.66×10^{-46}	4.52×10^{-26}	4.68×10^{-37}	1.99×10^{-25}	1.82×10^{-5}	3.11×10^{-3}	3.33×10^{-4}	3.05	0	1.00×10^{-31}	0	2.15×10^{-5}
JOS-HHO ^[36]	1.07×10^{-8}	4.91×10^{-5}	2.04×10^{-4}	1.09×10^{-5}	2.07×10^{-1}	8.01×10^{-3}	2.48×10^{-4}	2.68×10^1	3.64×10^{-8}	1.20×10^{-5}	1.19×10^{-8}	6.68×10^{-5}
HHO-1	1.62×10^{-9}	6.43×10^{-7}	6.42×10^{-8}	1.47×10^{-6}	6.57×10^{-2}	4.61×10^{-3}	1.76×10^{-4}	7.88	1.14×10^{-11}	7.55×10^{-8}	6.06×10^{-12}	2.02×10^{-5}
HHO-2	3.15×10^{-61}	9.48×10^{-34}	2.23×10^{-46}	1.51×10^{-31}	2.60×10^{-3}	6.19×10^{-5}	2.90×10^{-5}	3.59×10^{-1}	0	0	0	5.59×10^{-7}

表 6 不同维度下 SLHHO 算法与 HHO 算法的变体排序值

Table 6 Variant sorting values of SLHHO algorithm and HHO algorithm in different dimensions

算法	f_{rank} (维度为30)	f_{rank} (维度为100)
SLHHO	2.916 7	3.166 7
NCHHO ^[33]	5.125 0	5.041 7
LMHHO ^[34]	4.958 3	4.791 7
LHHO ^[35]	4.833 3	4.583 3
THHO ^[10]	3.333 3	2.666 7
DAHHO ^[20]	5.666 7	5.250 0
JOS-HHO ^[36]	8.375 0	8.291 7
HHO-1	6.208 3	7.375 0
HHO-2	3.583 3	3.833 3

说明算法寻优能力越好。为更好地看出复杂函数下的寻优情况,本文选取了 f_7 与 f_{12} 的多样性与探索开发的性能进行展示,2种为不同类型的函数。将最大迭代次数设为500,种群维度为100,SLHHO算法与HHO算法的展示具体如图5和图6所示。

由图6可知,SLHHO算法在 f_7 与 f_{12} 探索与开

发的过程中,前期搜索范围较广,勘探能力强,提升算法的全局搜索能力,中期具有一定的勘探及开发能力,平衡算法的全局与局部搜索能力,后期搜索范围逐渐变小,开发能力较强,勘探能力较差,提高解的精度;而HHO算法前期勘探能力较差,同时在寻优过程中,勘探与开发的平衡较




图5 HHO算法与SLHHO算法的探索与开发分布

Fig. 5 Distribution of exploration and development of HHO algorithm and SLHHO algorithm




图6 HHO算法与SLHHO算法的多样性分布

Fig. 6 Diversity distribution of HHO algorithm and SLHHO algorithm

为紊乱;由此可知,SLHHO 算法勘探与开发的相互作用,能够适应不同环境的寻优。在种群多样性分布的图 6 中,在单峰 f_1 函数中,SLHHO 算法前期具有较好的多样性,后期能够较快地降低种群多样性,提升收敛精度;在多峰 f_{12} 函数中,与 f_1 函数不同的是,SLHHO 算法能够在后期具有较快的变化,这能够减小算法陷入局部最优的概率,具有较好的抗局部吸引能力^[38]。综合来看,SLHHO 算法在面对不同类型的函数时能够做出不同的响应,提升解的精度,体现了 SLHHO 算法具有种群学习型及适应性的特点。

4 压力容器设计问题

为验证 SLHHO 算法的实用性,将其与 HHO 算法在压力容器设计问题中进行实验。压力容器设

计的最大目标是减小圆柱形压力容器的制造成本,同时能够满足实际的约束要求。其变量包括壳体的厚度 T_s 、头部的厚度 T_h 、内半径 R 和不带头部的圆柱形部分的长度 L 。通过算法找到最小经济成本的最优变量^[39]。将 PSO、GWO、WOA、HHO 与 SLHHO 进行比较,各算法独立运行 30 次,且种群数量为 50,最大评估次数为 40 000,同时记录 30 次数据的最优值 f_{best} ,平均值 f_{mean} ,最差值 f_{worst} ,最优参数,具体结果如表 7 所示。

由表 7 可知,SLHHO 算法能够在 30 次运行结果中,找到合理的参数且 f_{best} 指标最小,其他算法在 f_{best} 指标都较差;另一方面,SLHHO 算法在 f_{mean} 指标也最小,意味着 SLHHO 算法是比较稳定的。综合来看,SLHHO 算法在压力容器设计问题中具有一定的可行性,同时验证了 SLHHO 算法的实用性。

表 7 压力容器设计问题优化结果
Table 7 Pressure vessel design problem optimization results

函数	f_{best}	f_{mean}	f_{worst}	T_s/mm	T_h/mm	R/mm	L/mm
SLHHO	5 887.536 4	5 974.215 5	7 225.623 1	0.778 6	0.385 3	40.340 3	199.715 3
HHO ^[9]	5 981.944 0	6 909.828 1	7 654.063 5	1.175 2	0.578 6	59.893 4	37.962 5
PSO ^[1]	5 951.927 0	6 200.667 7	7 217.045 7	0.815 3	0.403 0	42.244 8	174.830 9
GWO ^[3]	5 981.944 0	6 909.828 1	7 654.063 5	1.175 2	0.578 6	59.893 4	37.962 5
WOA ^[4]	6 103.979 4	7 578.926 9	10 436.704 4	0.844 2	0.408 9	42.748 7	168.742 4

5 结 论

为提升 HHO 算法在寻优过程中的学习性及适应性,本文提出一种基于 SNR 的学习型算法 SLHHO 算法。主要工作及未来方向如下:

- 1) 本文提出 SNR 驱动的个体差异评估机制,通过量化解的质量差异;设计协调学习策略实现精英引导与邻域探索的自适应平衡;并改进逃逸距离公式。
- 2) 在 CEC2017 基准测试中,SLHHO 算法在 30 维问题上优于 7 种对比算法;压力容器设计案例中,成本控制较好,验证了工程实用性。
- 3) 从基准函数的实验测试结果来看,在 100 维的情况下,SLHHO 算法的优化能力有待提高,特别是在 f_1 与 f_6 中,寻优结果存在明显的下降,其主要原因是随着维度的升高,协调学习参考维度信息的错误率也在提高。

下一步的工作重点是在种群具有一定的学习与适应性的基础上,如何提升维度间的可靠性交流,并将算法用于更多的实际场景中,展现更好的实用性。

参考文献 (References)

[1] KENNEDY J, EBERHART R. Particle swarm optimization[C]//

Proceedings of the ICNN'95 - International Conference on Neural Networks. Piscataway: IEEE Press, 1995: 1942-1948.

[2] DORIGO M, BIRATTARI M, STUTZLE T. Ant colony optimization[J]. *IEEE Computational Intelligence Magazine*, 2006, 1(4): 28-39.

[3] MIRJALILI S, MIRJALILI S M, LEWIS A. Grey wolf optimizer[J]. *Advances in Engineering Software*, 2014, 69: 46-61.

[4] MIRJALILI S, LEWIS A. The whale optimization algorithm[J]. *Advances in Engineering Software*, 2016, 95: 51-67.

[5] XUE J K, SHEN B. A novel swarm intelligence optimization approach: sparrow search algorithm[J]. *Systems Science & Control Engineering*, 2020, 8(1): 22-34.

[6] ZHAO W G, ZHANG Z X, WANG L Y. Manta ray foraging optimization: an effective bio-inspired optimizer for engineering applications[J]. *Engineering Applications of Artificial Intelligence*, 2020, 87: 103300.

[7] XIE L, HAN T, ZHOU H, et al. Tuna swarm optimization: a novel swarm-based metaheuristic algorithm for global optimization[J]. *Computational Intelligence and Neuroscience*, 2021, 2021(1): 9210050.

[8] JIANG X Y, LI S. BAS: beetle antennae search algorithm for optimization problems[EB/OL]. (2017-10-30)[2023-02-01]. <https://arxiv.org/abs/1710.10724>.

[9] HEIDARI A A, MIRJALILI S, FARIS H, et al. Harris hawks optimization: algorithm and applications[J]. *Future Generation Computer Systems*, 2019, 97: 849-872.

[10] JIAO S, CHONG G S, HUANG C C, et al. Orthogonally adapted

- Harris hawks optimization for parameter estimation of photovoltaic models[J]. *Energy*, 2020, 203: 117804.
- [11] 闫晓斌, 方洋旺, 彭维仕. 基于自适应高斯变异的多目标哈里斯鹰优化算法[J]. 北京航空航天大学学报, 2024, 50(8): 2636-2645.
YAN X B, FANG Y W, PENG W S. Multi-objective Harris hawk optimization algorithm based on adaptive Gaussian mutation[J]. *Journal of Beijing University of Aeronautics and Astronautics*, 2024, 50(8): 2636-2645(in Chinese).
- [12] ELGAMAL Z M, YASIN N B M, TUBISHAT M, et al. An improved Harris hawks optimization algorithm with simulated annealing for feature selection in the medical field[J]. *IEEE Access*, 2020, 8: 186638-186652.
- [13] 胡春安, 熊昱然. 多策略改进的混沌哈里斯鹰优化算法[J]. *计算机工程与科学*, 2023, 45(9): 1648-1660.
HU C A, XIONG Y R. A multi-strategy improved chaotic Harris hawk optimization algorithm[J]. *Computer Engineering & Science*, 2023, 45(9): 1648-1660(in Chinese).
- [14] LI C Y, LI J, CHEN H L, et al. Enhanced Harris hawks optimization with multi-strategy for global optimization tasks[J]. *Expert Systems with Applications*, 2021, 185: 115499.
- [15] 李岩, 钱谦. 基于多种群与协同量子化的哈里斯鹰优化算法[J]. *控制与决策*, 2024, 39(7): 2169-2176.
LI Y, QIAN Q. Harris hawks optimization algorithm based on multi-group and collaborative quantization[J]. *Control and Decision*, 2024, 39(7): 2169-2176(in Chinese).
- [16] 柴岩, 任生. 双向经验引导与极端个体调控的 HHO 算法[J]. *计算机科学与探索*, 2023, 17(9): 2118-2136.
CHAI Y, REN S. HHO algorithm based on bidirectional experience guidance and extreme individual regulation[J]. *Journal of Frontiers of Computer Science and Technology*, 2023, 17(9): 2118-2136(in Chinese).
- [17] 刘小龙, 梁彤纓. 基于方形邻域和随机数组的哈里斯鹰优化算法[J]. *控制与决策*, 2022, 37(10): 2467-2476.
LIU X L, LIANG T Y. Harris hawk optimization algorithm based on square neighborhood and random array[J]. *Control and Decision*, 2022, 37(10): 2467-2476(in Chinese).
- [18] 展广涵, 王雨虹, 刘昊. 混合策略改进的哈里斯鹰优化算法及其应用[J]. *传感技术学报*, 2022, 35(10): 1394-1403.
ZHAN G H, WANG Y H, LIU H. Improved Harris hawks optimization algorithm with hybrid strategy and its application[J]. *Chinese Journal of Sensors and Actuators*, 2022, 35(10): 1394-1403(in Chinese).
- [19] 赵峰, 徐丹华. 基于混沌扰动与柯西变异的 HHO 算法[J]. *安徽大学学报(自然科学版)*, 2023, 47(4): 25-34.
ZHAO F, XU D H. HHO algorithm based on chaotic perturbation and Cauchy mutation[J]. *Journal of Anhui University (Natural Science Edition)*, 2023, 47(4): 25-34(in Chinese).
- [20] 贾鹤鸣, 刘庆鑫, 刘宇翔, 等. 融合动态反向学习的阿奎拉鹰与哈里斯鹰混合优化算法[J]. *智能系统学报*, 2023, 18(1): 104-116.
JIA H M, LIU Q X, LIU Y X, et al. Hybrid Aquila and Harris hawks optimization algorithm with dynamic opposition-based learning[J]. *CAAI Transactions on Intelligent Systems*, 2023, 18(1): 104-116(in Chinese).
- [21] YU J H, YANG J H. Adaptive multi-strategy learning particle swarm optimization with evolutionary state estimation[M]//*Bio-Inspired Computing: theories and Applications*. Berlin: Springer, 2022: 174-186.
- [22] WEINBERGER K Q, SAUL L K. Distance metric learning for large margin nearest neighbor classification[J]. *Journal of Machine Learning Research*, 2009, 10: 207-244.
- [23] YUAN T T, DENG W H, TANG J, et al. Signal-to-noise ratio: a robust distance metric for deep metric learning[C]//*Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Piscataway: IEEE Press, 2019: 4810-4819.
- [24] YANG J H, YU J H, HUANG C. Adaptive multi-strategy ensemble particle swarm optimization with signal-to-noise ratio distance metric[J]. *Information Sciences*, 2022, 612: 1066-1094.
- [25] 高建瓴, 喻明毫. 混合差分进化与二次插值改进哈里斯鹰算法[J]. *小型微型计算机系统*, 2023, 44(7): 1352-1359.
GAO J L, YU M H. Hybrid differential evolution and quadratic interpolation improved Harris hawks optimization algorithm[J]. *Journal of Chinese Computer Systems*, 2023, 44(7): 1352-1359(in Chinese).
- [26] DEVAN P A M, HUSSIN F A, IBRAHIM R B, et al. An arithmetic-trigonometric optimization algorithm with application for control of real-time pressure process plant[J]. *Sensors*, 2022, 22(2): 617.
- [27] KHODADADI N, SNASEL V, MIRJALILI S. Dynamic arithmetic optimization algorithm for truss optimization under natural frequency constraints[J]. *IEEE Access*, 2022, 10: 16188-16208.
- [28] ZHANG Y Y, CHI A N, MIRJALILI S. Enhanced Jaya algorithm: a simple but efficient optimization method for constrained engineering design problems[J]. *Knowledge-Based Systems*, 2021, 233: 107555.
- [29] NADIMI-SHAHRAKI M H, TAGHIAN S, MIRJALILI S. An improved grey wolf optimizer for solving engineering problems[J]. *Expert Systems with Applications*, 2021, 166: 113917.
- [30] NABIL E. A modified flower pollination algorithm for global optimization[J]. *Expert Systems with Applications*, 2016, 57: 192-203.
- [31] MIRJALILI S, HASHIM S Z M. A new hybrid PSOGSA algorithm for function optimization[C]//*Proceedings of the International Conference on Computer and Information Application*. Piscataway: IEEE Press, 2010: 374-377.
- [32] TANG Z Y, ZHANG D X. A modified particle swarm optimization with an adaptive acceleration coefficients[C]//*Proceedings of the Asia-Pacific Conference on Information Processing*. Piscataway: IEEE Press, 2009: 330-332.
- [33] DEHKORDI A A, SADIQ A S, MIRJALILI S, et al. Nonlinear-based chaotic Harris hawks optimizer: algorithm and Internet of vehicles application[J]. *Applied Soft Computing*, 2021, 109: 107574.
- [34] HUSSAIN K, ZHU W, MOHD SALLEH M N. Long-term memory Harris' hawk optimization for high dimensional and optimal power flow problems[J]. *IEEE Access*, 2019, 7: 147596-147616.
- [35] NAIK M K, PANDA R, WUNNAVA A, et al. A leader Harris hawks optimization for 2-D Masi entropy-based multilevel image thresholding[J]. *Multimedia Tools and Applications*, 2021, 80(28): 35543-35583.
- [36] ARINI F Y, CHIEWCHANWATTANA S, SOOMLEK C, et al. Joint opposite selection (JOS): a premiere joint of selective leading

- opposition and dynamic opposite enhanced Harris' hawks optimization for solving single-objective problems[J]. *Expert Systems with Applications*, 2022, 188: 116001.
- [37] DEMSAR J. Statistical comparisons of classifiers over multiple data sets[J]. *Journal of Machine Learning Research*, 2006, 7: 1-30.
- [38] POLÁKOVÁ R, TVRDÍK J, BUJOK P. Differential evolution with adaptive mechanism of population size according to current population diversity[J]. *Swarm and Evolutionary Computation*, 2019, 50: 100519.
- [39] 张吉祥, 张孟健, 王德光. 增强型白骨顶鸡优化算法及其应用[J]. *小型微型计算机系统*, 2024, 45(10): 2401-2410.
- ZHANG J X, ZHANG M J, WANG D G. Enhanced coot optimization algorithm and its application[J]. *Journal of Chinese Computer Systems*, 2024, 45(10): 2401-2410.

Learning Harris Hawks optimization algorithm with signal-to-noise ratio

ZHANG Lin¹, SHEN Jiaying², HU Chuanlu¹, ZHU Donglin^{2, *}

(1. School of Software Engineering, Jiangxi University of Science and Technology, Nanchang 330000, China;

2. School of Computer Science and Technology, Zhejiang Normal University, Jinhua 321004, China)

Abstract: Aiming at the problem of insufficient population learning and adaptability of the Harris hawks optimization (HHO) algorithm, this paper proposes a learning Harris hawks optimization based on the signal-to-noise ratio (SLHHO) algorithm. By using the signal-to-noise ratio as a metric to assess individual position information, the algorithm creates a coordinated learning strategy that can more realistically update the positions of individuals within the population. It then reworks the escape distance to enhance the algorithm's capacity for adaptation and optimization seeking. With 12 benchmark functions as the standard, the proposed algorithm was tested for its performance with the variants of the Harris hawk algorithm and other algorithms, and compared and analyzed in the evaluation indexes such as time complexity, diversity, exploration and development, etc. The results show that SLHHO algorithm is highly competitive and feasible, and finally, its practicability is verified in the pressure vessel design problem.

Keywords: Harris hawks optimization; signal to noise ratio; coordinated learning; escape distance; benchmark function

Received: 2023-07-03; Accepted: 2023-11-27; Published Online: 2024-02-04 10:56

URL: link.cnki.net/urlid/11.2625.V.20240202.1346.003

Foundation items: National Natural Science Foundation of China (62272418, 62002046)

* Corresponding author. E-mail: 2078570674@qq.com