

# 基于改进哈里斯鹰算法的 PSS 参数优化策略

侯 凯<sup>1</sup>, 张志高<sup>2</sup>, 何信林<sup>3</sup>, 燕 翔<sup>2</sup>, 张 岗<sup>2</sup>, 赵学健<sup>4\*</sup>

- ( 1. 国电南瑞科技股份有限公司, 江苏 南京 211106;  
2. 华能澜沧江水电股份有限公司, 云南 昆明 650214;  
3. 西安热工研究院有限公司, 陕西 西安 710054;  
4. 南京邮电大学 宽带无线通信与传感网技术教育部重点实验室, 江苏 南京 210003)

**摘 要:** 电力系统稳定器( Power System Stabilizer, PSS) 可有效抑制电力系统运行过程中发生的低频振荡问题, 因此 PSS 参数的合理设置至关重要。该文提出一种基于改进哈里斯鹰优化算法( Improved Harris Hawks Optimization, IHHO) 的 PSS 参数优化策略。首先, 该算法通过反向学习策略优化初始化种群, 使初始化种群能够覆盖更广泛的区域, 避免算法陷入局部最优; 其次, 该算法在搜索阶段引入平滑技术以有效减少搜索过程中的跳跃幅度, 避免个体在搜索过程中出现剧烈的波动, 从而增强算法的全局搜索能力; 最后, 该算法采用动态自适应逃逸能量调整策略灵活调整全局与局部搜索的时间分配, 增强算法的鲁棒性, 避免算法过早收敛和易陷入局部最优的问题。实验结果表明, IHHO 算法具有良好的精度、稳定性及时间效率, 为 PSS 参数优化问题提供了新的解决思路。

**关键词:** 哈里斯鹰算法; 励磁系统; 电力系统稳定器; 参数优化; 平滑技术; 动态自适应逃逸能量调整策略

**中图分类号:** TP301.6

**文献标识码:** A

**文章编号:** 1673-629X( 2025) 11-0204-10

doi: 10.20165/j.cnki.ISSN1673-629X.2025.0175

## Parameter Optimization Strategy for Power System Stabilizer Based on Improved Harris Hawks Optimization

HOU Kai<sup>1</sup>, ZHANG Zhi-gao<sup>2</sup>, HE Xin-lin<sup>3</sup>, YAN Xiang<sup>2</sup>, ZHANG Gang<sup>2</sup>, ZHAO Xue-jian<sup>4\*</sup>

- ( 1. NARI Technology Co., Ltd., Nanjing 211106, China;  
2. Huaneng Lancang River Hydropower Inc., Kunming 650214, China;  
3. Xi'an Thermal Power Research Institute Co., Ltd., Xi'an 710054, China;  
4. Key Laboratory of Broadband Wireless Communication and Sensor Network Technology of Ministry of Education, Nanjing University of Posts and Telecommunications, Nanjing 210003, China)

**Abstract:** The Power System Stabilizer ( PSS) can effectively suppress low-frequency oscillations during power system operation, making the rational configuration of PSS parameters critically important. We propose a PSS parameter optimization strategy based on an Improved Harris Hawks Optimization ( IHHO) algorithm. Firstly, the algorithm employs an opposition-based learning strategy to optimize the initial population, enabling broader coverage of the solution space during initialization and preventing convergence to local optima. Secondly, a smoothing technique is introduced during the search phase to effectively reduce jumping amplitudes in the search process, mitigating drastic fluctuations in individual search trajectories and thereby enhancing the algorithm's global exploration capability. Finally, a dynamic adaptive escape energy adjustment strategy is implemented to flexibly coordinate the time allocation between global and local searches, which strengthens the algorithm's robustness while avoiding premature convergence and local optimum entrapment. Experimental results demonstrate that the IHHO algorithm exhibits superior precision, stability, and time efficiency, providing a novel solution approach for PSS parameter optimization problems.

**Key words:** Harris hawks optimization; excitation system; power system stabilizer; parameter optimization; smoothing technique; dynamic adaptive escape energy adjustment strategy

收稿日期: 2025-02-28

修回日期: 2025-06-30

基金项目: 国家自然科学基金( 62303239) ; 中国华能集团有限公司科技项目( HNKJ22-H88)

作者简介: 侯 凯( 1981-) , 男, 正高级工程师, 博士, 研究方向为电力电子与励磁控制; 通信作者: 赵学健( 1982-) , 男, 博士, 副教授, 研究方向为人工智能及物联网关键技术。

## 0 引言

随着电力行业的蓬勃发展和电网规模的不断扩大,电力系统的低频振荡问题也随之凸显<sup>[1]</sup>。低频振荡是指在电力系统中,由于发电机的电磁惯性或励磁调节等原因,发电机的转子角、转速等相关参数发生近似等幅或增幅的振荡现象,其振荡频率一般在 0.1 Hz 至 2.5 Hz 之间<sup>[2]</sup>。低频振荡通常与同步发电机并列运行时在受到扰动后发电机转子间的相对摇摆有关,特别是在缺乏足够的阻尼时,这种振荡会持续存在。在大型电力系统中,低频振荡是一个很普遍的问题,它会引起电网不稳定甚至是解列、系统电压和频率异常波动,威胁电力系统的稳定。目前,电力系统通常采用电力系统稳定器(Power System Stabilizer, PSS)抑制电力系统的低频振荡问题<sup>[3]</sup>。PSS 作为一种附加的励磁控制装置,对电力系统稳定性的改善具有重要作用,可以显著提高发电机和整个电力系统的阻尼能力,抑制自发低频振荡的发生,加速功率振荡的衰减。然而, PSS 存在多个可供调节的参数<sup>[4]</sup>,参数设置的合理与否严重影响 PSS 的性能,合理配置 PSS 参数对提高电力系统的稳定性至关重要。

长期以来, PSS 参数通常通过现场试验的方法进行设置,严重依赖试验人员的经验,工作量大,存在一定的盲目性,且难以保证 PSS 参数达到最优配置,难以满足大规模互联电网的稳定性要求。

近年来,国内外学者尝试采用群智能优化算法进行 PSS 参数的优化配置,取得了较好的效果。然而,群优化算法存在易陷入局部最优,收敛速度慢,无法获得全局最优解等问题,在处理大规模复杂电力系统 PSS 参数配置时,计算时间过长,精度不佳,稳定性不高,一定程度限制了 PSS 对电力系统稳定性的进一步提升。

为此,该文提出一种基于改进哈里斯鹰优化算法(Improved Harris Hawks Optimization, IHHO)的 PSS 参数优化策略。该算法通过引入反向学习策略、平滑技术及动态自适应逃逸能量调整策略提升算法的精度、稳定性和时效性,进一步优化 PSS 参数的配置。该文的主要工作包括以下 3 个方面:

(1) 构建了 PSS 优化数学模型,明确了优化参数,并选取施加扰动后频率震荡的衰减速度为优化目标函数。

(2) 提出了基于改进哈里斯鹰优化算法(IHHO),该算法通过反向学习策略优化初始种群,在搜索阶段引入平滑技术有效减少搜索过程中的跳跃幅度,采用动态自适应逃逸能量调整策略灵活调整全局与局部搜索的时间分配,避免算法陷入局部最优,增强算法的全局搜索能力。

(3) 基于 Matlab 平台 Simulink 可视化仿真工具搭建了单机无穷大 PSS 仿真模型,进行了消融实验、对比实验,验证了 IHHO 算法的有效性。

## 1 相关工作

针对励磁系统 PSS 参数优化问题,国内外学者提出了线性/非线性规划、深度学习及群智能优化等解决思路。

最早被用于 PSS 参数优化的方法是线性/非线性规划方法,如单纯形法<sup>[5]</sup>、共轭梯度法<sup>[6]</sup>、Prony 算法<sup>[7]</sup>等。此类优化方法具有计算量小,收敛速度快,终止准则明确等优点,在处理单极值问题时表现出色,能够快速找到局部最优解。然而,由于 PSS 参数优化问题通常涉及多运行方式和复杂的系统动态,传统优化方法在多极值问题上无法有效找到最优解,且对初始值的选择较为敏感。

深度学习算法的出现为 PSS 参数优化问题提供了一种全新的解决思路。文献[8]提出一种基于强化学习的 PSS 参数优化方法,该算法能够在线优化控制增益,有效抑制低频振荡,提高系统稳定性。文献[9]探讨了人工神经网络技术在电力系统稳定性中的应用,特别是在 PSS 参数优化中的潜力。文献[10]提出了一种融合模仿学习和强化学习的 PSS 参数设置方法,相对于传统 PSS 参数优化方法,该方法在抑制低频振荡方面的性能得到了有效提升。深度学习算法具有全局搜索能力强、算法精度高等优点,然而此类算法通常存在计算复杂度高、收敛速度慢、样本效率低等问题,在面对计算资源有限、数据量不足、实时性要求高的应用场景时,难以发挥其优势。

群智能优化算法具有全局优化能力强、适应性强、计算复杂度低、实时性好等特点,在人工智能、通信网络和工业生产等领域得到广泛应用,已成为智能优化领域的研究热点。国内外学者近年来开始尝试将群智能算法应用于复杂非线性电力系统参数优化问题,包括 PSS 参数优化问题。文献[11]提出一种结合差分进化算法和粒子群算法的差分进化粒子群算法(Differential Evolution Based Particle Swarm Optimization, DEPSO),该算法具有动态自适应性,能够较容易地跳出局部最优,仿真结果表明利用该算法设计的 PSS 稳定性有了较大的提高。文献[12]提出一种基于飞蛾扑火优化(Moth-Flame Optimization, MFO)算法的多运行方式 PSS 参数协调优化方法,该算法本身拥有较强的收敛性,对多种 PSS 运行方式均有良好的适应性。文献[13]提出了一种基于爬行动物搜索算法(Reptile Search Algorithm, RSA)的 PSS 参数设计算法,该算法具有良好的鲁棒性。此外,诸如沙猫群优化

算法(Sand Cat Swarm Optimization, SCSO)<sup>[14]</sup>、野狗优化算法(Dingo Optimization Algorithm, DOA)<sup>[15]</sup>、黑寡妇优化算法(Black Widow Optimization Algorithm, BWOA)<sup>[16]</sup>等新型群智能优化算法在解决 PSS 参数优化问题上也展示出了良好的性能。

虽然群智能优化算法在解决 PSS 参数优化问题上展现出一定优势,但是由于群智能算法本身的局限性,算法性能还存在较大的提升空间。许多学者尝试在经典群智能算法的基础上进行改进,以期更好地解决特定问题。文献[7]将社会学习机制引入到粒子群优化算法中,提出了一种基于社会学习的粒子群优化算法(Social Learning Particle Swarm Optimization, SLPSO),该算法解决了普通粒子群优化算法优化 PSS 参数中存在的收敛性差、优化效果差等问题,通过将社会学习粒子群优化算法应用于 PSS 参数的寻优工作中,其 PSS 的优化效果和稳定性都得到了较大的提升。文献[8]提出一种结合相位补偿法和麻雀搜索算法(Sparrow Search Algorithm, SSA)的 PSS2A 参数优化方法,该算法能够先优化速度传感器参数,再优化超前滞后环节参数,以改善 PSS2A 的相频特性。文献[9]提出了一种改进的蜻蜓算法(Improved Dragonfly Algorithm, IDA)以改善系统性能并减少处理时间,该算法通过改进随机系数和引入新的适应度函数来提高优化性能。此外,文献[20-23]分别通过混沌映射改进初始化,迭代阶段引入自适应策略,引入非线性收敛因子,多种群智能算法相互融合等改进策略,提升算法的优化性能。但是上述改进算法往往在某一方面性能表现优异,不能兼顾算法精度、时间效率和稳定性。为此,针对 PSS 参数优化问题,该文提出一种基于改进哈里斯鹰的优化算法(IHHO),力求兼顾算法的精度、稳定性和时效性,进一步优化 PSS 参数的配置。

## 2 PSS 优化模型

### 2.1 励磁系统模型

文中发电机数学模型选用经典的六阶模型,励磁系统数学模型选用 IEEE-ST1 型。IEEE-ST1 型励磁模型与 PSS 的结构匹配如图 1 所示。




图 1 PSS 结构

励磁系统数学模型如式 1 所示。

$$E'_{Fd} = \frac{1}{T_A} [K(V_{ref} - V_t + U_{PSS}) - E'_{Fd}] \quad (1)$$

其中,  $V_t$  和  $V_{ref}$  分别代表机端电压和参考电压,  $U_{PSS}$  是稳定器信号,  $K$  和  $T_A$  是瞬态增益以及励磁时间常数。

### 2.2 PSS 数学模型

典型的 IEEE PSS1A 控制器模型<sup>[24]</sup>包括增益、隔直环节以及两个超前滞后补偿环节,传递函数如式 2 所示。

$$U = K \frac{sT_\omega}{1+sT_\omega} \frac{(1+sT_1)}{(1+sT_2)} \frac{(1+sT_3)}{(1+sT_4)} \Delta\omega \quad (2)$$

其中:  $U$  为发电机的 PSS 输出信号;  $\Delta\omega$  为发电机的转速偏差输入信号;  $T_\omega$  为隔直时间常数;  $T_1$ 、 $T_2$ 、 $T_3$  和  $T_4$  为补偿环节的时间常数。文中  $T_2$  和  $T_4$  为与被控对象相关的时间常数; PSS 增益  $K$  和时间常数  $T_1$ 、 $T_3$  为待优化的参数。

### 2.3 PSS 优化目标函数

PSS 稳定器性能对系统频率的影响较大,该文从系统频率入手,选取施加扰动后频率震荡的衰减速度为优化目标函数,具体如式 3 所示。

$$J = \frac{\sum_{i=1}^{N-1} (A_i - A_{i+1})}{\min(A_i)} \quad (3)$$

其中:  $A_i$  为第  $i$  个振荡峰值的包络线幅值;  $N$  为观察的振荡次数;  $J$  代表引入扰动后系统频率震荡的衰减速度,在优化过程中,  $J$  越大表明系统的稳定性越好。

根据参数的边界特性, PSS 参数配置转化为如式 4 所示的优化问题。

$$\begin{cases} \text{Optimize } J \\ X_{PSS, \min} \leq K_{PSS} \leq K_{PSS, \max} \\ T_{1, \min} \leq T_1 \leq T_{1, \max} \\ T_{3, \min} \leq T_3 \leq T_{3, \max} \end{cases} \quad (4)$$

其中,  $K_{PSS}$  的取值范围为  $[0.01, 50]$ ,  $T_1$ 、 $T_3$  的典型取值范围是  $[0.06, 1.0]$ 。

## 3 IHHO 算法

### 3.1 HHO 算法

HHO(Harris Hawks Optimization)是一种模拟哈里斯鹰捕食行为的元启发式算法,该算法的寻优过程包括三个阶段:全局搜索阶段、全局搜索与局部开发转换阶段和局部开发阶段。

#### 3.1.1 全局搜索阶段

算法迭代初期,哈里斯鹰群体根据两种策略探测猎物,具体公式如下:

$$X(t+1) = \begin{cases} X_{rand}(t) - r_1 |X_{rand}(t) - 2r_2 X(t)| & \text{if } q \geq 0.5 \\ (X_{target}(t) - X_{ave}(t)) - r_3(lb + r_4(ub - lb)) & \text{if } q < 0.5 \end{cases} \quad (5)$$

式中: 当  $q < 0.5$  时, 哈里斯鹰会根据其它成员和猎物的位置进行栖息; 当  $q \geq 0.5$  时, 哈里斯鹰会随机栖息在种群活动范围内的某棵树上。其中:  $X(t)$  为第  $t$  次迭代过程中该哈里斯鹰个体的位置;  $ub$ 、 $lb$  为搜索空间上、下限;  $X_{\text{rand}}$  为随机选取的个体位置;  $X_{\text{target}}$  为目标猎物位置;  $X_{\text{ave}}$  为种群内所有个体的平均位置;  $q$ 、 $r_1$ 、 $r_2$ 、 $r_3$ 、 $r_4$  均为  $[0, 1]$  内的随机数。

### 3.1.2 全局搜索与局部开发转换阶段

算法迭代中期, 哈里斯鹰群体逐渐减小寻优范围, 由全局大范围搜索逐渐转变为局部小范围搜索。引入逃逸能量  $E$  来控制哈里斯鹰群里寻优策略的转变, 逃逸能量计算公式如下:

$$E = 2E_0(1 - t/t_{\max}) \quad (6)$$

其中,  $E_0$  表示初始逃逸能量, 决定了算法进行全局搜索和局部搜索的时间分配。 $t$  代表当前迭代次数,  $t_{\max}$  代表最大迭代次数。 $E$  的初始值为  $2E_0$ , 随着迭代次数的增加,  $E$  的值逐渐减小到某一定值, 此时算法由全局搜索阶段转变为局部开发阶段。

### 3.1.3 局部开发阶段

算法迭代后期, 哈里斯鹰开始对猎物进行突袭。根据猎物的逃逸能量  $E$  和随机数  $r$  ( $r$  为  $[0, 1]$  内的随机数), 哈里斯鹰算法演变出了四种寻优策略。

#### (1) 轻柔围攻。

当  $r \geq 0.5$  且  $|E| \geq 0.5$  时, 算法认为目标猎物仍然有足够的逃逸能量, 哈里斯鹰群选择轻柔围攻的策略, 缓慢地缩小包围圈, 对猎物进行软围困, 如式 7 所示。

$$X(t+1) = X_{\text{target}}(t) - X(t) - E|J \cdot X_{\text{target}}(t) - X(t)| \quad (7)$$

其中,  $J$  为猎物逃跑过程中的跳跃距离, 计算公式如下:

$$J = 2 * (1 - r) \quad (8)$$

#### (2) 强硬围攻。

当  $r \geq 0.5$  且  $|E| < 0.5$  时, 目标猎物逃逸能量降低, 很难再逃脱鹰群的围捕, 此时哈里斯鹰群选择强硬围攻的策略, 快速缩小包围圈对目标进行硬围困, 如式 9 所示。

$$X(t+1) = X_{\text{rabbit}}(t) - E|X_{\text{rabbit}}(t) - X(t)| \quad (9)$$

#### (3) 渐进式快速俯冲的轻柔围攻。

当  $r < 0.5$  且  $|E| \geq 0.5$  时, 哈里斯鹰通过包围的方式来消耗猎物逃逸的体力, 然后对没有足够体力的猎物发动突袭。该过程引入了莱维飞行的概念来模拟哈里斯鹰群的俯冲速降和猎物多变的逃跑路线, 如式 10 所示。

$$\begin{cases} X(t+1) = \begin{cases} Y & \text{if fitness}(Y) < \text{fitness}(X(t)) \\ Z & \text{if fitness}(Z) < \text{fitness}(X(t)) \end{cases} \\ Z = Y + S * \text{LF}(D) \\ Y = X_{\text{target}}(t) - E|J \cdot X_{\text{target}}(t) - X(t)| \end{cases} \quad (10)$$

其中,  $\text{fitness}(\bullet)$  表示对应可行解适应度的值,  $D$  为空间维度,  $S$  是一个  $1 \times D$  的随机向量,  $\text{LF}(D)$  为 Levy 飞行函数, 计算如式 11 所示。

$$\text{LF}(x) = 0.01 * \frac{u^* \sigma}{|v|^{\frac{1}{\beta}}} \quad \sigma = \left( \frac{\Gamma(1+\beta) * \sin(\frac{\pi\beta}{2})}{\Gamma(\frac{1+\beta}{2}) * \beta * 2^{\frac{\beta-1}{2}}} \right)^{\frac{1}{\beta}} \quad (11)$$

其中,  $u$ 、 $v$  为  $[0, 1]$  内的随机数,  $\beta = 1.5$ 。

#### (4) 渐进式快速俯冲的强硬包围。

当  $r < 0.5$  且  $|E| < 0.5$  时, 与渐进式快速俯冲的轻柔围攻类似, 哈里斯鹰会通过包围的方式来消耗猎物逃逸的体力, 但同时会快速拉近与猎物的距离, 进行强势围捕, 如式 12 所示。

$$\begin{cases} X(t+1) = \begin{cases} Y & \text{if fitness}(Y) < \text{fitness}(X(t)) \\ Z & \text{if fitness}(Z) < \text{fitness}(X(t)) \end{cases} \\ Z = Y + S * \text{LF}(D) \\ Y = X_{\text{target}}(t) - E|X_{\text{target}}(t) - X(t)| \end{cases} \quad (12)$$

## 3.2 IHHO 算法描述

为了进一步提升 HHO 算法的性能, IHHO 算法针对性地提出三种改进策略: 基于反向学习的种群初始化策略、基于平滑技术的搜索策略及动态逃逸能量调整策略。旨在进一步增强算法的全局搜索能力、提高收敛速度, 并避免陷入局部最优。

### 3.2.1 基于反向学习的种群初始化策略

HHO 算法在种群初始化阶段, 采用简单的随机数生成初始化种群, 导致初始种群的多样性不足, 难以在后续的搜索中对可行域进行充分的搜索。为此, IHHO 算法在初始化阶段引入反向学习机制丰富初始种群的多样性。反向学习主要在初始化阶段生成解的“对立”局部, 从而提高初始解的多样性。即使没有先验知识, 使用反向学习技术仍然可以获得更合适的初始种群, 提高探测效率, 如式 13 所示。

$$X_{\text{oj}} = lb_j + ub_j - X_{ij} \quad (13)$$

其中,  $i$  为哈里斯鹰的编号,  $j$  表示空间的维度。  $lb$ 、 $ub$  分别为目标可行域的上界和下界,  $X_i$  为第  $i$  只哈里斯鹰的初始位置,  $X_{oi}$  为第  $i$  只哈里斯鹰的对立位置。

接下来, 计算每个哈里斯鹰个体在其初始位置及

其对立位置的适应度,选择适应度较高的位置作为该个体的实际初始位置,如式 14 所示。

$$X_i' = \begin{cases} X_i & \text{if fitness}(X_i) \geq \text{fitness}(X_{oi}) \\ X_{oi} & \text{if fitness}(X_i) < \text{fitness}(X_{oi}) \end{cases} \quad (14)$$

### 3.2.2 基于平滑技术的搜索策略

HHO 算法在搜索阶段,哈里斯鹰个体根据猎物的位置进行随机游走,这虽然能够有效探索搜索空间,但容易导致算法过早收敛,尤其在处理复杂的多峰优化问题时更是如此。为了增强算法的全局搜索能力,该文在搜索阶段引入了平滑技术,通过对个体位置进行平滑处理,减少搜索过程中的波动,从而避免算法陷入局部最优,具体如式 15 所示。

$$\begin{cases} M = \text{sign}(X_k - X_{k-1}) \text{sign}(X_{k+1} - X_k) \\ X_k' = \begin{cases} iX_{k-1} + (1-i)X_{k+1} & \text{if } M < 0 \\ X_k & \text{if } M \geq 0 \end{cases} \end{cases} \quad (15)$$

其中,  $i$  是  $[0,1]$  之间的随机数,  $X_k'$  是  $X_k$  的平滑值。

从收敛性角度分析,该平滑技术构建了一个特殊的马尔可夫转移过程。设优化空间为  $\Omega$ ,其中全局最优解集为  $G^* \subset \Omega$ ,对于任意迭代  $t$  的位置状态  $X_t \notin G^*$ ,存在常数  $\varepsilon > 0$  使得:

$$P(X^{t+1} \in N_\varepsilon(G^*) | X^t) > \delta \quad (16)$$

其中,  $N_\varepsilon(G^*)$  表示  $G^*$  的  $\varepsilon$  邻域,  $\delta$  为正常数。

根据平滑机制(15),当检测到局部极值点时,有:

$$P(X_k^{t+1}) = P(M < 0) \cdot P(iX_{k-1} + (1-i)X_{k+1} \notin L_k) \quad (17)$$

其中,  $P(X_k^{t+1})$  代表  $X_k^{t+1}$  脱离局部极值的概率,  $L_k$  代表  $X_k$  所在的局部最优区域。

进一步分析可得,当系数  $i$  满足  $P(i \in (0,1)) = 1$  时,算法满足弱收敛条件,即:

$$\lim_{t \rightarrow \infty} P(X^t \in N_\varepsilon(G^*)) = 1 \quad (18)$$

特别地,当平滑处理的迭代次数足够多时,期望收敛速率可表示为:

$$E[\|X^{t+1} - X^*\|] \leq (1-\alpha) E[\|X^t - X^*\|] \quad (19)$$

其中,  $X^*$  是全局最优解,  $\alpha$  是与平滑参数  $i$  和局部结构相关的正常数。以上证明表明,平滑技术通过有选择地处理局部极值点,既保持了算法的随机性,又提供了跳出局部最优的机制。

平滑技术能够有效减少搜索过程中的跳跃幅度,避免个体在搜索过程中出现剧烈的波动。平滑技术的引入不仅能够增强算法的全局搜索能力,避免算法在搜索过程中陷入局部最优,还能帮助算法在全局范围内进行更有效的搜索,提高算法的收敛速度。

### 3.2.3 动态自适应逃逸能量调整策略

HHO 算法通过逃逸能量参数  $E$  采用线性递减策

略控制全局搜索与局部开发阶段的转换,容易导致算法初期全局搜索不充分或后期局部开发不足,致使全局与局部搜索失衡。此外,初始逃逸能量值固定也导致算法无法根据种群多样性动态调整,难以适应复杂多峰的优化问题。为此,IHHO 算法中引入基于种群多样性的自适应逃逸能量调整策略,采用动态优化的逃逸能量初始取值与衰减速率,以平衡算法的全局探索能力和局部开发能力。

动态自适应逃逸能量调整策略根据当前种群多样性动态调整  $E_0$ ,具体如式 20 所示。

$$E_0(t) = E_{\text{base}} + \alpha \cdot \text{Diversity}(t) \quad (20)$$

其中,  $E_{\text{base}}$  为基础能量值(文中取  $E_{\text{base}} = 0.5$ ),  $\alpha$  为调节参数(文中取  $\alpha = 0.3$ ),  $\text{Diversity}(t)$  为第  $t$  代种群多样性度量,计算方法如式 21 所示。

$$\text{Diversity}(t) = \frac{1}{N \cdot D} \sum_{i=1}^N \sum_{j=1}^D |X_{ij}(t) - \bar{X}_j(t)| \quad (21)$$

其中,  $N$  为种群规模,  $D$  为问题维度,  $\bar{X}_j(t)$  为第  $j$  维的平均值。当种群多样性较高时,增大  $E_0(t)$  以延长全局搜索;多样性较低时,减小  $E_0(t)$  以加速局部开发。

此外,为了平衡全局与局部搜索,IHHO 算法将逃逸能量方式改进为分段指数型衰减策略,该策略在初期采用指数衰减保留全局搜索能力,后期通过幂律衰减加速局部开发,如式 22 所示。

$$E(t) = \begin{cases} 2E_0(t) \cdot e^{-\beta t/t_{\max}} & \text{if } t \leq 0.5t_{\max} \\ E_{\min} + (E_{\max} - E_{\min}) \cdot (1 - \frac{t}{t_{\max}})^\gamma & \text{else} \end{cases} \quad (22)$$

其中,  $\beta = 1.5$ ,  $\gamma = 2$ ,  $E_{\min} = 0.1$ ,  $E_{\max} = 0.8$ 。

动态自适应逃逸能量调整策略不仅能够灵活调整全局与局部搜索的时间分配,有效避免局部最优,还能与反向学习和平滑技术协同作用,增强算法的鲁棒性。

IHHO 算法伪代码如下:

```
Algorithm 1: Improved Harris Hawks Optimization(IHHO)
1: Input: Population size  $N$ , maximum iterations  $t_{\max}$ , problem dimension  $D$ , bounds  $[lb, ub]$ 
2: Output: Optimal solution  $X_{\text{best}}$ 
3: procedure IHHO
4:   // 1. Opposition-Based Learning Initialization
5:   for  $i = 1$  to  $N$  do
6:     Generate random position  $X_i$  within  $[lb, ub]$ 
7:     Compute opposition position  $X_{oi,j} = lb_j + ub_j - X_{i,j}$  for  $j = 1, 2, \dots, D$ 
8:     Evaluate fitness  $f(X_i)$  and  $f(X_{oi})$ 
9:     if  $f(X_{oi}) < f(X_i)$  then
10:       $X_i \leftarrow X_{oi}$ 
11:   end if
12: end for
```

13: Initialize  $X_{\text{best}} \leftarrow \arg \min_x f(X)$   
 14: Initialize iteration counter  $t \leftarrow 1$   
 15: While  $t \leq t_{\max}$  do  
 16: // 2. Dynamic Adaptive Escape Energy Adjustment  
 17: Compute population diversity  $\text{Diversity}(t)$  using Eq  
 (19)  
 18: Update  $E_0(t) = E_{\text{base}} + \alpha \cdot \text{Diversity}(t)$   
 19: Calculate  $E = 2E_0(t) \cdot \left(1 - \frac{t}{t_{\max}}\right)^\beta$  if  $t < 0.5t_{\max}$   
 20: Otherwise,  $E = E_{\max} \cdot \left(1 - \frac{t}{t_{\max}}\right)^\gamma$   
 21: for each hawk  $X_i$  in population do  
 22: // Global Exploration Phase  
 23: if  $|E| \geq 1$  then  
 24: Update position using Eq. (6) with random  
 strategies  
 25: else  
 26: // Local Exploitation Phase  
 27: Determine strategy based on  $E$  and random  
 numberr

28: if  $r \geq 0.5$  and  $|E| \geq 0.5$  then  
 29: Soft besiege: Update using Eq(8) with Lévy flight  
 30: else if  $r \geq 0.5$  and  $|E| < 0.5$  then  
 31: Hard besiege: Update using Eq. (10)  
 32: else if  $r < 0.5$  and  $|E| \geq 0.5$  then  
 33: Progressive dive with soft besiege: Eq(11)  
 34: else  
 35: Progressive dive with hard besiege: Eq(13)  
 36: end if  
 37: end if  
 38: // 3. Smoothing Technique for Position Update  
 39: Apply smoothing:  $X'_k = \frac{X_{k-1} + X_k + \eta X_{k+1}}{2 + \eta}$   
 40: Replace  $X_k$  with  $X'_k$  if  $f(X'_k) < f(X_k)$   
 41: end for  
 42: Update  $X_{\text{best}}$  if better solution found  
 43:  $t \leftarrow t + 1$   
 44: end while  
 45: end procedure

IHHO 算法总体框架如图 2 所示。




图 2 IHHO 算法总体框架

## 4 实验分析

### 4.1 实验环境

为了验证 IHHO 算法的有效性, 该文进行了一系列消融实验和对比实验。实验环境配置如下:

显卡: NVIDIA GeForce RTX 4060(8 G);

CUP: Intel i5 12400F;

内存: 16 GB DDR4 3 200 MHz;

磁盘: KIOXIA - EXCERIA PLUS G3 SSD(2 000 GB);

操作系统: Windows10 Enterprise 22H2 64 位;

编程语言: Python3.9.7;

模型运行工具: Simulink。

### 4.2 实验设计

为了验证 IHHO 算法引入的反向学习初始化策略、平滑技术和动态自适应逃逸能量调整策略对算法性能的影响, 以及 IHHO 算法对 PSS 参数优化的有效性, 仿真实验设计如下:

(1) 基于 Matlab 平台的 Simulink 可视化仿真工具搭建了单机无穷大 PSS 仿真模型, 模拟电力系统运行

状态。

(2) 消融实验,分别验证去除反向学习策略、平滑技术、动态自适应逃逸能量调整策略对 IHHO 算法精度、搜索效率、稳定性和收敛性的影响。

(3) 对比实验,将 IHHO 算法与目前的优秀群智能优化算法进行对比,验证 IHHO 算法在 PSS 参数优化场景下的有效性与高效性。

为确保实验的公平性,每个算法均独立运行 30 次,设置种群规模大小均为 30,最大迭代次数为 150 次。

#### 4.3 PSS Simulink 仿真

该文基于 Matlab Simulink 可视化仿真工具及电力系统仿真模块集 SimPower Systems Blockset 搭建了 PSS 仿真模型,模型采用典型 IEEE PSS1A 数学模型。发电机及输电线主要参数设置如表 1 所示。

表 1 模型参数设置

| 模型参数                      | 数值    |
|---------------------------|-------|
| 发电机的额定容量 $P_n$ /MVA       | 1 100 |
| 发电机的额定电压 $V$ /kV          | 27    |
| 额定频率 $f$ /Hz              | 50    |
| 发惯性时间常数 $H$ /s            | 3.7   |
| 发电机直轴同步电抗 $X_d$           | 2.61  |
| 发电机交轴同步电抗 $X_q$           | 2.48  |
| 发电机直轴暂态电抗 $X'_d$          | 0.264 |
| 发电机直轴次暂态电抗 $X''_d$        | 0.225 |
| 发电机交轴次暂态电抗 $X''_q$        | 0.248 |
| 直轴暂态开路时间常数 $T'_{do}$ /s   | 8.86  |
| 直轴次暂态开路时间常数 $T''_{do}$ /s | 0.036 |
| 交轴次暂态开路时间常数 $T''_q$       | 0.085 |
| 定子绕组电阻 $r_s$              | 0.001 |
| 励磁器增益 $K_{AVR}$           | 300   |
| 励磁时间常数 $T_A$              | 0.03  |
| 电缆电抗 $X_l$                | 0.3   |
| 电缆电阻 $R$                  | 0.026 |

#### 4.4 评价指标

该文采用均方误差 (Mean Squared Error, MSE)、平均搜索时间 (Average Search Time, AST)、稳定性 (Standard Deviation, SD) 作为评估指标,计算公式如下:

$$a = \frac{1}{m} \sum_{j=1}^m (J_i - \bar{J})^2 \quad (23)$$

$$b = \frac{1}{m} \sum_{j=1}^m T_j \quad (24)$$

$$c = \sqrt{\frac{1}{m-1} \sum_{j=1}^m (J_i - \bar{J})^2} \quad (25)$$

其中,  $a$  (MSE) 为多次运行中目标函数  $J$  的方差,其值越低,说明算法的精度越好。  $b$  (AST) 为多次运行中算法进行迭代寻优所需的平均搜索时间,其值越低,说明算法的搜索效率越高。  $c$  (SD) 用于衡量算法多次运行中目标函数值的波动性,其值越小,表明算法的稳定性越强。

#### 4.5 消融实验

为了验证文中改进策略对算法性能的影响,分以下五种情况进行仿真实验。

(1) 传统 HHO 算法;

(2) 去除动态自适应策略的 IHHO (IHHO without Dynamic Adaptive Strategy), 以下简称 w/o DAS;

(3) 去除平滑技术的 IHHO (IHHO without Smooth Technology), 以下简称 w/o ST;

(4) 去除反向学习策略的 IHHO (IHHO without Reverse Learning Strategy), 以下简称 w/o RLS;

(5) 完整 IHHO 算法。

消融实验收敛曲线如图 3 所示。




图 3 基于不同改进策略的 HHO 收敛曲线对比

从图 3 可以看出,不同算法的收敛趋势存在显著差异。基本 HHO 算法的收敛速度最慢,且整体波动较大,在迭代后期收敛效果不佳,难以达到更优解,这表明其优化精度和稳定性较差,在不同运行条件下的表现不稳定,容易陷入局部最优,无法持续优化; w/o DAS 的收敛曲线在优化过程中的表现不如完整的 IHHO 算法,表明动态自适应策略在平衡算法全局搜索与局部开发方面起到了重要作用,缺少该策略会影响算法的寻优效率和最终结果; w/o ST 的收敛曲线的波动相对较大,在搜索过程中无法很好地避免局部最优解,导致优化精度有所下降,体现出平滑技术在减少搜索波动、增强全局搜索能力上的关键作用; w/o RLS 在初始阶段的收敛速度明显慢于完整的 IHHO 算法,这进一步证实了反向学习技术能够有效提高初始解的多样性,使算法在早期能更快速地向最优解收敛。

完整的 IHHO 算法结合了三种改进策略,其收敛曲线在初期下降迅速,得益于反向学习技术提高了初始解的多样性,避免过早陷入局部最优;在中后期,动

态自适应策略平衡了算法的局部搜索与全局搜索时间,平滑技术减少了控制函数的波动,增强了全局搜索能力。综合来看,IHHO 算法在收敛速度、优化精度和稳定性方面均展现出显著优势,验证了文中改进策略

的有效性。

消融实验均方误差、平均搜索时间、稳定性结果如表 2 所示。

表 2 消融实验均方误差、平均搜索时间、稳定性对比

| 算法      | 均方误差      | 平均搜索时间/s | 稳定性       |
|---------|-----------|----------|-----------|
| HHO     | 0.022 449 | 675.71   | 0.000 602 |
| w/o DAS | 0.018 423 | 725.84   | 0.000 748 |
| w/o ST  | 0.019 724 | 705.43   | 0.000 674 |
| w/o RLS | 0.017 959 | 740.32   | 0.000 83  |
| IHHO    | 0.017 243 | 745.57   | 0.000 87  |

由表 2 可以看出,HHO 算法虽然平均搜索时间最短,但其优化精度和稳定性较差,表明其搜索效率较低,在不同运行条件下的表现较为不稳定。IHHO 算法的平均搜索时间比传统 HHO 算法仅增加约 10.34%,但其均方误差降低约 23.19%,稳定性提高约 44.52%,表明反向学习、平滑技术和动态自适应策略的结合能够在保证优化精度和稳定性的同时,有效控制计算成本。w/o DAS 相比 HHO,其均方误差降低约 17.93%,稳定性提高约 24.25%,表明动态自适应策略对提高算法的优化精度和稳定性存在影响。w/o ST 的搜索时间低于其他所有改进算法,相比 HHO 其均方误差降低约 12.14%,稳定性提高约 11.96%,表明平滑技术对算法的搜索时间影响较大,但也能够有效减少控制函数的波动,提高算法稳定性。w/o RLS 的搜索时间高于除 IHHO 外的其他所有算法,表明反向学习策略对算法的搜索时间影响最小,相比 HHO 其均方误差降低约 20%,稳定性提高约 37.87%,表明反向学习对算法稳定性和优化精度也有一定影响。

综上所述,反向学习技术显著提高了算法的早期收敛速度,平滑技术增强了算法的全局搜索能力,动态自适应策略调整全局与局部搜索的时间分配。IHHO 算法引入反向学习、平滑技术和动态自适应策略,有效提升了算法的收敛速度、算法精度和稳定性。

#### 4.6 对比实验

本小节将 IHHO 算法与 HHO 算法、病毒群体搜索算法(Virus Colony Search,VCS)<sup>[23]</sup>、饥饿游戏搜索算法(Hunger Games Search,HGS)<sup>[24]</sup>、黏菌算法(Slime Mould Algorithm,SMA)<sup>[25]</sup>、蜻蜓算法(Dragonfly Algorithm,DA)<sup>[26]</sup>、海鞘群算法(Salp Swarm Algorithm,SSA)<sup>[27]</sup>及文献[17]提到的 SLPSO 算法进行了对比分析。

各算法收敛曲线对比如图 4 所示。

由图 4 可以看出,IHHO 算法在迭代过程中表现出显著的收敛优势。相较于其他算法,IHHO 算法在

前 50 次迭代中迅速收敛,表明反向学习技术在种群初始化阶段有效提高了初始解的多样性,避免了算法过早陷入局部最优。在迭代后期中,算法仍能保持较高的收敛速度,表明平滑技术在搜索阶段有效减少了控制函数的波动,增强了全局搜索能力。相比之下,其他算法如 SSA 和 SMA 在早期收敛较快,但在中后期容易陷入局部最优,导致收敛曲线趋于平缓,无法进一步优化。




图 4 IHHO 与 7 种优化算法收敛曲线对比  
各算法均方误差对比如图 5 所示。




图 5 IHHO 与 7 种优化算法均方误差对比

由图 5 可以看出,IHHO 算法的均方误差与 DA、SSA 相比,分别降低 38.81%和 34.08%,与 SMA、VCS 相比,分别降低 17.37%和 12.7%,与 HGS、SLPSO 算法相比也略有降低,表明通过引入三种改进策略,IHHO

算法在 PSS 参数优化问题中具有较高的精度和稳定性,能够有效避免因控制函数波动导致的误差增大。DA 和 SSA 的均方误差较大,表明这些算法在处理复杂 PSS 参数优化问题时精度较低。

各算法的平均搜索时间对比如图 6 所示。




图 6 IHHO 与 7 种优化算法平均搜索时间对比

由图 6 可以看出,IHHO 算法的平均搜索时间仅比平均搜索时间最低的 DA 算法增加 15.97%,与 VCS 算法平均搜索时间相当,表明尽管 IHHO 算法引入了三种改进策略,增加了计算复杂度,但其搜索时间仍处于合理范围内,表明其在保证优化精度的同时,能够有效控制计算成本。同时,IHHO 算法在搜索时间上的略微增加,换来了更高的优化精度和稳定性,这表明算法在 PSS 参数优化问题中具有良好的时间与精度平衡能力。

各算法的稳定性对比如图 7 所示。




图 7 IHHO 与 7 种优化算法稳定性对比

由图 7 可以看出,IHHO 算法的稳定性虽然低于 DA、SSA 两种算法,但与 HHO、VCS、HGS、SMA、SLP SO 相比,算法稳定性分别高约 44.52%、76.47%、59.05%、18.53%、72.96%。这表明平滑技术和动态自适应策略的引入让 IHHO 算法的稳定性得到显著提高,其在多次运行中能够保持较高的稳定性,能够有效避免因初始条件不同导致的性能波动,具有较强的鲁棒性,能够适应不同的 PSS 参数优化场景。VCS 和 HGS 在多次运行中的稳定性较低,表明这些算法在处理复杂优化

问题时存在一定的随机性和不稳定性。

通过对比实验可以看出,该文提出的 IHHO 算法在早期迭代阶段即展现出较快的收敛速度,且在中后期能够持续优化,最终达到更优的解,表明其在 PSS 参数优化问题中具有较高的优化精度。尽管 IHHO 算法的搜索时间略高于部分算法,但其搜索效率仍然较高,且在不同运行条件下能够保持较高的稳定性,表明其在 PSS 参数优化问题中具有良好的时间与精度平衡能力。IHHO 算法在不同运行条件下的表现较为一致,表明其具有较强的鲁棒性,能够适应不同的 PSS 参数优化场景。通过初始化阶段进行反向学习、搜索阶段嵌入平滑技术等改进策略,改善了 HHO 的初始种群质量和全局搜索能力,解决 PSS 参数优化问题的效率和准确性得到显著提高,进行参数优化后的 PSS 模块能够更好地降低低频振荡为电力系统带来的影响。

## 5 结束语

面向 PSS 参数优化,该文提出一种基于改进哈里斯鹰优化算法(IHHO)。该算法通过反向学习策略优化初始化种群,在搜索阶段引入平滑技术以有效减少搜索过程中的跳跃幅度,避免个体在搜索过程中出现剧烈的波动,采用动态自适应逃逸能量调整策略灵活调整全局与局部搜索的时间分配。消融实验和对比实验表明,IHHO 算法在平均搜索时间未显著增加的前提下,具有较好的收敛性、精度和稳定性,为 PSS 参数优化提供了有效的解决思路,提高了 PSS 抑制电力系统低频振荡的能力。

## 参考文献:

- [1] 朱方,赵红光,刘增煌,等.大区电网互联对电力系统动态稳定性的影响[J].中国电机工程学报,2007(1):1-7.
- [2] 吴复霞.电力系统低频振荡的分析和控制[M].杭州:浙江大学,2007.
- [3] 孙华东,汤涌,马世英.电力系统稳定的定义与分类述评[J].电网技术,2006(17):31-35.
- [4] 牛振勇,杜正春,方万良,等.基于进化策略的多机系统 PSS 参数优化[J].中国电机工程学报,2004(2):23-28.
- [5] 陈思岐,李自成,何汶璟,等.典型二阶系统的单纯形法 PID 参数优化设计[J].现代工业经济和信息化,2024,14(2):170-172.
- [6] SHEN X,CAI R,BI M,et al.Preconditioned nonlinear conjugate gradient method for real-time interior-point hyperelasticity[C]//ACM SIGGRAPH 2024 conference papers. New York: Association for Computing Machinery,2024:1-11.
- [7] 雷琼.基于 PSS 的优化 Prony 算法在电力系统低频振荡中的应用研究[J].自动化与仪器仪表,2023(10):246-250.
- [8] KOSURU R,CHEN P,LIU S.A reinforcement learning based

- power system stabilizer for a grid connected wind energy conversion system [C] //2020 IEEE electric power and energy conference ( EPEC) .Edmonton: IEEE,2020: 1-5.
- [9] KALU N O,OYELEKE O,THOMAS S,et al.Artificial intelligence techniques for power system stabilization [C] //2021 1st international conference on multidisciplinary engineering and applied science ( ICMEAS) .Abuja: IEEE,2021: 1-5.
- [10] ZHANG Y,LIU Z W,CHI M.An imitation learning and reinforcement learning approach to power system stabilizer [C] //2023 6th international conference on intelligent autonomous systems ( ICoIAS) .Qinhuangdao: IEEE,2023: 373-378.
- [11] 王建波,刘毅力,梁继国,等.基于差分进化粒子群算法的 PSS 参数优化与整定 [J].计算机与数字工程,2018,46( 1): 53-58.
- [12] 潘晓杰,张立伟,张文朝,等.基于飞蛾扑火优化算法的多运行方式电力系统稳定器参数协调优化方法 [J].电网技术,2020,44( 8): 3038-3046.
- [13] BENTO M E C.PMU-based power system stabilizer design using reptile search algorithm [C] //2022 IEEE international conference on automation/XXV congress of the chilean association of automatic control ( ICA-ACCA) .Curicó: IEEE,2022: 1-6.
- [14] WU Y,FAN S,LIU P,et al.On optimization of multi-machine PSS parameters tuning based on SCSO algorithm [C] //2023 international conference on neuromorphic computing ( ICNC) .Wuhan: IEEE,2023: 435-440.
- [15] WANG X,ZHANG X.Comparative study of dingo optimization algorithm and other biological heuristic algorithms in power system optimization [C] //2023 IEEE international conference on image processing and computer applications ( ICIPCA) .Changchun: IEEE,2023: 1564-1570.
- [16] HIDAYAT M T I,ROBANDI I,WIBOWO R S,et al.Optimal tuning of power system stabilizer and virtual inertia control based on black widow optimization algorithm [C] //2024 international seminar on intelligent technology and its applications ( ISITIA) .Mataram: IEEE,2024: 65-70.
- [17] 张 程,邱炳林,刘佳静,等.基于社会学习的粒子群优化算法的电力系统稳定器参数协调优化设计 [J].电工电能新技术,2022,41( 4): 24-33.
- [18] 刘圣苻,刘毅力,李佼洁.基于相位补偿法和麻雀搜索算法的 PSS2A 参数优化 [J].国外电子测量技术,2022,41( 5): 37-45.
- [19] SHIVAKUMAR R,SOWRANCHANA S.Animproved dragonfly algorithm tuned optimizer for improving stability of multia-chine system [C] //2023 2nd international conference on advancements in electrical,electronics,communication,computing and automation( ICAECA) .Coimbatore: IEEE,2023: 1-6.
- [20] 潘志杰,舒 挺.基于改进鲸鱼算法的工业操作系统资源实例化调度算法研究 [J].软件工程,2025,28( 1): 23-27.
- [21] 陈 悦,冯 锋.基于多策略改进的蜚蠊优化算法 [J/OI].物联网技术. <http://kns.cnki.net/kcms/detail/61.1483.TP.20250221.1620.004.html>.
- [22] 柴 岩,常晓萌,任 生.融合多策略改进的白鲸优化算法 [J].计算机工程与应用,2025,61( 5): 76-93.
- [23] 李 念,陈学财,阮志红.融合策略改进的蝴蝶优化算法及其桁架优化 [J].现代计算机,2024,30( 11): 1-8.
- [24] HEIDARI A A,MIRJALILI S,FARIS H,et al.Harris hawks optimization: algorithm and applications [J].Future Generation Computer Systems,2019,97: 849-872.
- [25] LI M D,ZHAO H,WENG X W,et al.A novel nature-inspired algorithm for optimization: virus colony search [J].Advances in Engineering Software,2016,92: 65-88.
- [26] YANG Y,CHEN H,HEIDARI A A,et al.Hunger games search: visions, conception, implementation, deep analysis, perspectives, and towards performance shifts [J].Expert Systems with Applications,2021,177: 114864.
- [27] LI S,CHEN H,WANG M,et al.Slime mould algorithm: a new method for stochastic optimization [J].Future Generation Computer Systems,2020,111: 300-323.
- [28] MIRJALILI S.Dragonfly algorithm: a new meta-heuristic optimization technique for solving single-objective, discrete, and multi-objective problems [J].Neural Computing and Applications,2016,27: 1053-1073.
- [29] MIRJALILI S,GANDOMI A H,MIRJALILI S Z,et al.Salp swarm algorithm: a bio-inspired optimizer for engineering design problems [J].Advances in Engineering Software,2017,114: 163-191.