

多策略改进的被囊群算法在入侵检测中的应用

汪 杰, 汪祖民⁺

(大连大学 信息工程学院, 辽宁 大连 116622)

摘 要: 针对被囊群优化算法应用于网络入侵检测系统存在算法收敛速度较慢, 容易陷入局部最优解的缺陷, 提出一种适用于 XGBoost 的参数寻优以及特征选择的改进被囊群优化算法。应用 Tent 混沌映射和自适应步长两种策略加快算法的收敛, 融合莱维飞行策略增强个体的路径扰动帮助算法更好跳出局部最优解。仿真结果表明, 改进后优化算法收敛速度更快, 更加稳定, 寻优精度更高, 在 XGBoost 上的应用相较于其它机器学习算法, 取得了更好的检测结果, 有效提高了网络入侵检测的性能。

关键词: 被囊群算法; 混沌映射; 自适应步长; 莱维飞行; 参数寻优; 机器学习; 入侵检测

中图分类号: TP393.08 **文献标识号:** A **文章编号:** 1000-7024 (2024) 03-0684-07

doi: 10.16208/j.issn1000-7024.2024.03.007

Application of multi-strategy improved tunicate swarm algorithm in intrusion detection

WANG Jie, WANG Zu-min⁺

(College of Information Technology, Dalian University, Dalian 116622, China)

Abstract: In view of the shortcomings of the low convergence speed and the easiness to fall into local optimal solution when the tunicate swarm algorithm is applied to network intrusion detection systems, an improved tunicate swarm algorithm for XGBoost parameter optimization and feature selection was proposed. The Tent chaotic mapping and adaptive step were applied to accelerate the convergence of the algorithm, and the Levi's flight strategy was integrated to enhance the path perturbation of individuals to help the algorithm better jump out of the local optimal solution. Simulation results show that the improved optimization algorithm converges faster, is more stable, and has higher optimization accuracy. Compared with other machine learning algorithms, the application of the improved algorithm on XGBoost achieves better detection results and effectively improves the performance of network intrusion detection.

Key words: tunicate swarm algorithm; chaotic mapping; adaptive step; Levy flight; parameter optimization; machine learning; intrusion detection

0 引 言

近年来, 智能群优化算法被广泛应用于机器学习用来解决各种场景的入侵检测^[1]。为提高入侵检测性能, 文献 [2] 将改进灰狼优化算法应用于 BP 神经网络。文献 [3] 提出一种基于随机森林和人工免疫的入侵检测算法, 并构建了抗体森林的模型。文献 [4] 在鲸鱼算法中引入自适应步长和拥挤度因子以及高斯变异算子, 并将改进后的优化算法对支持向量机算法的参数进行寻优。文献 [5] 将人工蜂群算法用于特征提取, 并利用 XGBoost 算法对需要

评价的特征进行分类。文献 [6] 提出一种并行技术改进支持向量机算法在大规模数据下训练速度慢的问题, 并融合改进后的布谷鸟搜索算法设计了工控入侵检测模型。

综上所述, 机器学习算法在入侵检测的研究中十分常见。但是部分机器学习算法本身的性能不足, 如文献 [7] 实验证明同其它机器学习算法比较, XGBoost 在各种入侵检测中表现更为优异。同时由于大部分寻优算法收敛速度慢, 易陷入局部最优解, 因此本文提出利用改进被囊群算法对 XGBoost 算法的参数和数据集特征数量进行寻优, 提高入侵检测性能。仿真结果表明, 相比于其它机器学习算

收稿日期: 2022-06-08; 修订日期: 2024-03-01

作者简介: 汪杰 (1997—), 男, 江苏无锡人, 硕士研究生, CCF 学生会会员, 研究方向为网络空间安全、机器学习; + 通讯作者: 汪祖民 (1975—), 男, 河南信阳人, 博士, 教授, CCF 杰出会员, 研究方向为智能感知。E-mail: wangzumin@dlu.edu.cn

法, 该入侵检测模型的性能更好。

1 被囊群优化算法

被囊群优化算法 (tunicate swarm algorithm, TSA)^[8]是由 Kaur 等提出的一种元启发式算法, 其性能在 74 个基准问题中得到了有效证明。其数学模型如下。

1.1 喷气推进行为

1.1.1 避免搜索个体间冲突

为了避免搜索个体间的冲突, 使用向量 A 来计算新的个体位置

$$A = \frac{G}{M} \quad (1)$$

式中: G 表示重力

$$G = C_1 + C_2 - 2 \cdot C_3 \quad (2)$$

M 表示各个体间的社会力量

$$M = \lfloor P_{\min} + C_1 \cdot (P_{\max} - P_{\min}) \rfloor \quad (3)$$

C_1, C_2, C_3 都是属于 $[0, 1]$ 的随机数, $P_{\max}$ 和 $P_{\min}$ 分别是社会力量的初始速度和从属速度, 上述公式有助于个体在给定的搜索空间中随意移动, 并避免不同搜索个体之间的冲突。

1.1.2 向最佳搜索个体移动

个体在避免群体间冲突后向当前最佳搜索个体的位置移动, 由以下公式计算个体与最佳搜索个体间的距离

$$PD = P_{\text{best}} - r \cdot P(x) \quad (4)$$

式中: $P(x)$ 表示第 x 次迭代时被囊群个体的位置, r 是属于 $[0, 1]$ 的随机数, P_{best} 为当前最佳搜索个体的位置。

1.1.3 向最佳搜索代理汇聚

当每个个体求得自身在当前迭代与最佳个体间的距离后, 个体开始向当前迭代中的最佳个体位置汇聚

$$P(x) = \begin{cases} P_{\text{best}} + A \cdot PD, & r \geq 0.5 \\ P_{\text{best}} - A \cdot PD, & r < 0.5 \end{cases} \quad (5)$$

1.2 群体行为

TSA 通过整合当前个体的位置和上一次迭代个体的位置, 来模拟被囊群的群体行为, 其数学公式定义如下

$$P(x+1) = \frac{P(x) + P(x+1)}{2 + C_1} \quad (6)$$

2 多策略改进被囊群优化算法

2.1 Tent 混沌映射

基本被囊群算法的初始位置是随机生成的, 所以种群的初始位置在空间中分布不均匀, 会降低种群的多样性并影响收敛速度。因此本文提出采用混沌映射^[9]来初始化种群, 相比于另一种常用的 logistic 混沌映射, Tent 混沌映射具有更好的遍历性, 能够在 $[0, 1]$ 之间产生分布较均匀的初始值。因此基于 Tent 映射的 TSA 具有更好的种群多样性和收敛速度。

Tent 映射的表达式如下

$$T_{i+1}^n = \begin{cases} 2 \cdot T_i^n, & 0 \leq T_i^n \leq 0.5 \\ 2 \cdot (1 - T_i^n), & 0.5 < T_i^n \leq 1 \end{cases} \quad (7)$$

式中: $i = 1, 2, 3 \dots, P$ 为种群规模, $n = 1, 2, 3 \dots, D$ 表示当前求解问题的维度。

通过式 (7) 可以得到 $P \times D$ 个混沌序列, 再将其代入式 (8) 初始化种群位置

$$P(x) = T_i^n \cdot (ub - lb) + lb \quad (8)$$

式中: ub 代表个体位置的最大边界值, lb 代表个体位置的最小边界值。

2.2 自适应步长

在标准被囊群算法中, 算法的探索和开发能力主要受到群体行为的影响, 而式 (6) 中的参数 C_1 影响着群体行为的步长。当 C_1 越小时, 步长越大, 有利于算法的全局探索能力; 当 C_1 越大时, 步长越小, 有利于算法的局部探索能力。而算法在迭代前期, 需要更强的全局探索能力, 帮助算法跳出局部最优解; 而在迭代后期, 则需要更强的局部探索能力, 帮助算法获得更高的求解精度, 综上所述, C_1 的值应该随着迭代次数的增加而逐渐增大。由于标准算法中的 C_1 是 $[0, 1]$ 之间的随机数, 所以在群体位置更新时, 容易产生盲目性, 使算法难以获得更快的收敛和更高的精度。

针对以上问题, 本文将 C_1 由如下公式代替

$$\omega = 2 - \frac{e^{t/T_{\max}} - 1}{e - 1} \quad (9)$$

式中: t 是当前迭代次数, $T_{\max}$ 代表最大迭代次数, ω 是一个惯性权重, 它随着迭代次数的增加而自适应地减小。将式 (9) 代入式 (6) 更新为

$$P(x+1) = \frac{P(x) + P(x+1)}{2 + \omega} \quad (10)$$

2.3 莱维飞行

被囊群中个体的移动主要是依靠最优个体的位置信息进行移动, 其中式 (1) 中的向量 A 决定了个体的更新距离, 其值更是由多个范围为 $[0, 1]$ 的随机数决定, 这大大降低了个体移动的多样性。当最优个体陷入局部最优解时, 被囊群中的其它个体在向最优个体移动时, 很难再搜索到全局最优解, 因此本文提出利用莱维飞行^[10]来增强个体向当前最优位置移动时的路径扰动, 以此帮助算法更好的跳出局部最优解, 改进公式如下

$$S = \frac{\mu}{|\nu|^{1/\beta}} \quad (11)$$

$$\sigma_\mu = \left\{ \frac{\Gamma(1+\beta) \cdot \sin\left(\frac{\pi \cdot \beta}{2}\right)}{\Gamma\left(\frac{1+\beta}{2}\right) \cdot \beta \cdot 2^{\frac{\beta-1}{2}}} \right\}^{\frac{1}{\beta}} \quad (12)$$

$$P_{\text{Levy}}(x) = P(x) + \omega \cdot s \cdot (P_{\text{best}} - P(x)) \quad (13)$$

其中, $\mu \sim N(0, \sigma_\mu^2)$, $\nu \sim N(0, 1)$, $\beta = 1.5$, 而 ω 由式 (9)

计算得出, 用来控制莱维飞行策略在算法迭代期间的步长,

$P_{Levy}(x)$ 代表经过莱维飞行变异后的个体位置。

上述改进后的被囊群优化算法 (improved tunicate swarm algorithm, ITSA) 的算法流程如下:

步骤 1 种群个体的初始化位置由 Tent 混沌映射决定。

步骤 2 初始化算法的各个参数。

步骤 3 计算所有个体的适应度值, 此时最优解的值就是当前最优个体的值。

步骤 4 根据式 (1) 到式 (5) 进行个体位置更新。

步骤 5 根据式 (13) 利用莱维飞行策略对每个个体施加扰动, 其中个体移动步长由自适应步长式 (9) 得出。

步骤 6 根据式 (10) 进行群体位置更新, 其中个体移动步长由自适应步长式 (9) 得出。

步骤 7 检测每个个体的位置是否超出边界, 并调整超出边界的个体位置。

步骤 8 计算个体经过群体行为后的适应度值和经过莱维飞行扰动后的适应度值, 将两者中的最佳适应度值作为当前最优解。

步骤 9 算法满足停止条件则停止, 否则重复步骤 4~步骤 8。

步骤 10 返回最优解。

3 ITSA-XGBoost 入侵检测模型的构建

XGBoost 是机器学习中梯度提升树的高效实现, XGBoost 中有许多的参数难以整定, 同时不同数量的特征选择对检测精度有较大的影响, 本文主要利用 ITSA 算法对选取的部分 XGBoost 参数和特征数量进行寻优。寻优的参数及范围见表 1。

表 1 参数选取

参数名称	取值范围
eta	[0,1]
min_child_weight	[0,∞]
max_depth	[1,∞]
gamma	[0,∞]
colsample_bytree	(0,1]
subsample	(0,1]
feature_num	[1,max_feature]

表 2 中 max_feature 代表数据集可选取的最大特征数量。

表 2 12 个测试函数

函数	表达式	定义域	理论值
F1	$f(x) = \sum_{i=1}^{30} x_i^2$	$[-100, 100]$	0
F2	$f(x) = \sum_{i=1}^{30} x_i + \prod_{i=1}^{30} x_i $	$[-10, 10]$	0
F3	$f(x) = \sum_{i=1}^{30} \left(\sum_{j=1}^i x_j \right)^2$	$[-100, 100]$	0
F4	$f(x) = \max_i \{ x_i , 1 \leq i \leq 30 \}$	$[-100, 100]$	0
F5	$f(x) = \sum_{i=1}^{30} ix_i^4 + \text{random}[0, 1)$	$[-1.28, 1.28]$	0
F6	$f(x) = -20 \exp \left(-0.2 \sqrt{\frac{1}{30} \sum_{i=1}^{30} x_i^2} \right) - \exp \left(\frac{1}{30} \sum_{i=1}^{30} \cos 2\pi x_i \right) + 20 + e$	$[-32, 32]$	0
F7	$f(x) = \frac{1}{4000} \sum_{i=1}^{30} x_i^2 - \prod_{i=1}^{30} x_i \cos \left(\frac{x_i}{\sqrt{i}} \right) + 1$	$[-600, 600]$	0
F8	$f(x) = \frac{\pi}{30} \left\{ 10 \sin^2(\pi y_1) + \sum_{i=1}^{29} (y_i - 1)^2 \cdot [1 + 10 \sin^2(\pi y_{i+1})] + (y_n - 1)^2 \right\} + \sum_{i=1}^{30} u(x_i, 10, 100, 4), y_i = 1 + \frac{x_i + 1}{4}, u(x_i, a, k, m) = \begin{cases} k(x_i - a)^m, & x_i > a \\ 0, & -a \leq x_i \leq a \\ k(-x_i - a)^m, & x_i < -a \end{cases}$	$[-50, 50]$	0
F9	$f(x) = 4x_1^2 - 2.1x_1^4 + \frac{1}{3}x_1^6 + x_1x_2 - 4x_2^2 + 4x_4^2$	$[-5, 5]$	-1.031 628 5
F10	$f(x) = [1 + (x_1 + x_2 + 1)^2(19 - 14x_1 + 3x_1^2 - 14x_2 + 6x_1x_2 + 3x_2^2)] \times [30 + (2x_1 - 3x_2)^2 \times (18 - 32x_1 + 12x_1^2 + 48x_2 - 36x_1x_2 + 27x_2^2)]$	$[-2, 2]$	3
F11	$f(x) = -(x_2 + 47) \sin \left(\sqrt{\left x_2 + \frac{x_1}{2} + 47 \right } \right) - x_1 \sin \left(\sqrt{ x_1 - (x_2 + 47) } \right)$	$[-512, 512]$	-959.6407
F12	$f(x) = \left(\sum_{i=1}^5 i \cos((i+1)x_1 + i) \right) \left(\sum_{i=1}^5 i \cos((i+1)x_2 + i) \right)$	$[-10, 10]$	-186.7309

利用 ITSA 对 XGBoost 参数和特征数量寻优的具体流程如下:

步骤 1 删去入侵检测训练集和测试集中的重复数据, 对离散数据特征进行映射, 将离散特征转化为数字型特征, 对数据集进行归一化处理。

步骤 2 通过递归式特征消除 (recursive feature elimination, RFE)^[12] 对特征进行排序, 将 XGBoost 作为迭代分类器, 得到排序后的特征。

步骤 3 利用 ITSA 算法对 XGBoost 参数和特征数量进行寻优, 将在训练集中训练好的 XGBoost 模型用来对测试集进行预测, 并把测试集的准确度作为适应度值返回, 在达到最大迭代次数前, 找到使测试集准确度最高的参数及特征数量。

步骤 4 输出对 XGBoost 模型寻得最优解后的测试集分类结果。

ITSA-XGBoost 入侵检测模型流程如图 1 所示。




图 1 ITSA-XGBoost 入侵检测模型

4 实验设置

4.1 实验环境

实验硬件采用 Intel(R) Core(TM) i5-10400H CPU + GeForce GTX 1660Ti + 16 GB 内存; 软件环境, 在 ITSA 性能测试中采用 MATLAB R2022a, 在 ITSA-XGBoost 入侵检测实验中采用 Python 3.9.5。

4.2 ITSA 性能测试

在本文中, 被囊群算法的参数设置见表 1, 其中种群数量 pop 为 50, 最大迭代次数 Max_iter 为 500, 同时为了验证 ITSA 的算法性能, 本文将灰狼优化算法 (grey wolf optimizer, GWO)^[13]、海鸥优化算法 (seagull optimization algorithm, SOA)^[14]、TSA 和 ITSA 作对比。本文采用 12 个测试函数检验 ITSA 的寻优能力, 其中 F1~F4 为多维单峰函数, F5~F8 为多维多峰函数, F9~F12 为固定维度函数。上述 12 个测试函数表达式见表 2。收敛曲线如图 2 所示。

如图 2 所示, 在寻找最优解方面, ITSA 在多维单峰函数上提升较大, 而在多维多峰函数和固定维度函数上相较于 TSA 也有不小的提升。在收敛速度方面, ITSA 在不同函数上的表现都很好。因此实验验证利用 Tent 混沌映射、自适应步长和莱维飞行能够使算法提高收敛速度, 同时在算法迭代后期拥有跳出局部最优解的能力。

4.3 ITSA-XGBoost 模型性能分析

4.3.1 入侵检测数据集

本文采用由澳大利亚网络安全中心在 2015 年创建的 UNSW-NB15^[15] 数据集对模型进行性能测试。该数据集中共有 257 673 条样本, 其中 175 341 条训练集样本, 82 332

条测试集样本。但是其中有相当多的重复样本, 在将无用的 “id” 列剔除后, 删除重复样本, 此时数据集的样本数量与分布见表 3。

如表 3 所示, 除 Normal 类为正常网络行为, 剩余 9 类均为攻击行为。

4.3.2 实验基本设置

为测试 ITSA-XGBoost 模型的性能, 将 ITSA 算法与 TSA 算法中的种群数量设为 50, 迭代次数设为 100。对于 UNSW-NB15 数据集, 在将 “label” 和 “attack_cat” 列抽离后, 对离散数据特征进行映射, 将离散特征进行 Label-Encoder 编码转化为数字型特征后, 对数据集所有列进行归一化处理, 最后利用 RFE 对特征进行排序, 得到排序后的 42 个特征值供 ITSA-XGBoost 模型进行特征寻优。

4.3.3 评估指标

模型评价标准定义参考文献 [16], 定义如下:

准确率 (Accuracy, Acc)

$$Acc = \frac{TP + TN}{TP + TN + FP + FN} \quad (14)$$

精确率 (Precision, Pre)

$$Pre = \frac{TP}{TP + FP} \quad (15)$$

召回率 (Recall)

$$Recall = \frac{TP}{TP + FN} \quad (16)$$

F1-Score

$$F1-Score = \frac{2 \times Pre \times Recall}{Pre + Recall} \quad (17)$$

AUC (area under curve) 是 ROC (receiver operating characteristic) 曲线下的面积, 定义如下




图2 各算法在12个函数上的收敛曲线对比

表3 UNSW-NB15 的训练集和测试集

类型	训练集	比例/%	测试集	比例/%
Normal	51 890	48.16	34 206	61.14
Analysis	1594	1.48	446	0.80
Backdoor	1535	1.42	346	0.62
Dos	3806	3.53	1718	3.07
Exploits	19 844	18.42	7609	13.60
Fuzzers	16 150	14.99	4838	8.65
Generic	4181	3.88	3657	6.54
Reconnaissance	7522	6.98	2703	4.83
Shellcode	1091	1.01	378	0.68
Worms	127	0.12	44	0.08
总数	107 740	—	55 945	—

$$AUC = \int_0^1 \frac{TP}{TP + FN} d \frac{FP}{TN + FP} \quad (18)$$

上述公式中, TP (true positive) 是正确分类到正常网络行为的样本数, TN (true negative) 是正确分类到攻击行为的样本数, FP (false positive) 是将攻击行为错误分

类为正常网络行为的样本数, FN (false negative) 是将正常网络行为错误分类为攻击行为的样本数。

4.3.4 ITSA 优化 XGBoost 效果分析

为测试 ITSA-XGBoost 模型在参数寻优上的优越性, 将其与 TSA-XGBoost 模型进行比较。设置 TSA 和 ITSA 算法的种群数量为 50, 最大迭代次数为 100。两种模型在 UNSW-NB15 数据集上的准确率和 ROC 曲线如图 3 所示。




图3 TSA 和 ITSA 结合 XGBoost 算法性能对比

如图 3 所示, 在准确率对比曲线中, ITSA-XGBoost 模型在收敛速度和准确率上均优于 TSA-XGBoost 模型, 且

ITSA-XGBoost 模型不易陷入早熟收敛, 在迭代后期依旧有跳出局部最优解的能力。在 ROC 曲线中, ITSA-XGBoost 模型的 AUC 值为 0.9039, 而 TSA-XGBoost 模型的 AUC 值为 0.8545, 这表明 ITSA-XGBoost 模型获得了更高的真正率和更低的假正率。综上, ITSA-XGBoost 模型在参数寻优上优于 TSA-XGBoost 模型。

4.3.5 ITSA-XGBoost 模型二分类和多分类性能对比

为体现 ITSA-XGBoost 模型的性能, 本文选取了文献 [17] 中的人工神经网络算法 (artificial neural network, ANN)、逻辑回归算法 (logistic regression, LR)、K 近邻 (k-nearestneighbor, KNN)、支持向量机算法 (support vector machine, SVM)、决策树算法 (decision tree, DT) 进行性能对比, 对比结果见表 4、表 5。

表 4 二分类性能对比

算法	Acc/%	Pre/%	Recall/%	F1-Score/%
ANN	84.39	78.56	98.53	87.42
LR	77.64	73.18	93.74	82.2
KNN	84.46	80.31	95.09	87.08
SVM	60.89	58.89	95.88	72.97
DT	90.85	80.33	98.38	88.45
ITSA-XGBoost	90.21	90.49	90.21	90.27

表 5 多分类性能对比

算法	Acc/%	Pre/%	Recall/%	F1-Score/%
ANN	77.51	79.50	77.53	77.28
LR	65.29	70.88	65.29	65.96
KNN	72.30	77.24	72.30	73.81
SVM	61.53	53.95	61.52	51.31
DT	67.57	79.66	67.56	69.26
ITSA-XGBoost	79.24	80.46	79.24	78.91

通过表 4 的实验结果可以看出, 在二分类性能对比中, ITSA-XGBoost 模型在准确率上除了比决策树算法 (DT) 低 0.64%, 均高于其它算法, 在精确率和 F1-Score 上均优于其它算法, 而在召回率上则低于其它算法。

通过表 5 的实验结果可以看出, 在多分类性能对比中, ITSA-XGBoost 模型在准确率、精确率、召回率和 F1-Score 上均优于其它算法。

最后, 为体现 ITSA-XGBoost 模型的优越性, 本文选取了另外 6 篇论文中的随机森林树算法 (random forest, RF)^[18,19]、RepTree 算法^[20]、IELM 算法^[21]、深度置信网络算法 (deep belief network, DBN)^[22]、CNN-BiLSTM 算法^[23]进行二分类和多分类的准确率对比。对比结果见表 6。

表 6 测试集准确率对比

方法	二分类 Acc/%	多分类 Acc/%
ANN ^[17]	84.39	77.51
LR ^[17]	77.64	65.29
KNN ^[17]	84.46	72.3
SVM ^[17]	60.89	53.95
DT ^[17]	90.85	67.57
RF ^[18]	—	75.56
RF ^[19]	85.78	—
RepTree ^[20]	88.95	—
IELM ^[21]	—	75.36
DBN ^[22]	85.73	—
CNN-BiLSTM ^[23]	—	77.16
ITSA-XGBoost	90.21	79.24

ITSA-XGBoost 模型在二分类中准确率除了比决策树算法 (DT) 低 0.64%, 均高于其它算法。而在多分类中则均优于其它所有算法。因此, 与其它算法相比, ITSA-XGBoost 更加适合入侵检测。

5 结束语

本文利用 Tent 混沌映射, 自适应步长和莱维飞行 3 种策略改进被囊群优化算法, 并用于 XGBoost 参数寻优和特征选择以构建入侵检测模型。实验结果表明, 改进后的 ITSA 相比于其它优化算法收敛速度更快, 且具有跳出局部最优解的能力。同时相较于其它机器学习算法, 在 UNSW-NB15 数据集中, ITSA-XGBoost 模型的检测性能更好。在未来的研究中, 将通过生成对抗网络等方法处理少数样本数据, 提高入侵检测的性能。

参考文献:

[1] SHEN Yanping, ZHENG Kangfeng, YANG Yixian, et al. Survey of research on application of heuristic algorithm in machine learning [J]. Journal on Communications, 2019, 40 (12): 124-137 (in Chinese). [沈焱萍, 郑康锋, 杨义先, 等. 智能启发算法在机器学习中的应用研究综述 [J]. 通信学报, 2019, 40 (12): 124-137.]

[2] WANG Zhendong, LIU Yaodi, WANG Junling, et al. Use improved grey wolf algorithm to optimize BP neural network intrusion detection [J]. Journal of Chinese Computer Systems, 2021, 42 (4): 875-884 (in Chinese). [王振东, 刘尧迪, 王俊岭, 等. 利用改进灰狼算法优化 BP 神经网络的入侵检测 [J]. 小型微型计算机系统, 2021, 42 (4): 875-884.]

[3] ZHANG Ling, ZHANG Jianwei, HOU Zexiang, et al. Intrusion detection algorithm based on random forest and artificial immunity [J]. Computer Engineering, 2020, 46 (8): 146-

- 152 (in Chinese). [张玲, 张建伟, 侯泽翔, 等. 基于随机森林与人工免疫的入侵检测算法 [J]. 计算机工程, 2020, 46 (8): 146-152.]
- [4] WANG Huazhong, CHENG Qi. Research on intrusion detection of industrial control system based on improved whale algorithm [J]. Netinfo Security, 2021, 21 (2): 53-60 (in Chinese). [王华忠, 程奇. 基于改进鲸鱼算法的工控系统入侵检测研究 [J]. 信息安全, 2021, 21 (2): 53-60.]
- [5] XU Wei, LENG Jing. Network intrusion detection method based on abc algorithm and XGBoost [J]. Computer Applications and Software, 2021, 38 (3): 314-318 (in Chinese). [徐伟, 冷静. 基于人工蜂群算法和 XGBoost 的网络入侵检测方法研究 [J]. 计算机应用与软件, 2021, 38 (3): 314-318.]
- [6] CHEN Hanyu, WANG Huazhong, YAN Bingyong. Application of CUDA and cuckoo algorithm based SVM in industrial control system intrusion detection [J]. Journal of East China University of Science and Technology, 2019, 45 (1): 101-109 (in Chinese). [陈汉宇, 王华忠, 颜秉勇. 基于 CUDA 和布谷鸟算法的 SVM 在工控入侵检测中的应用 [J]. 华东理工大学学报 (自然科学版), 2019, 45 (1): 101-109.]
- [7] ZHANG Yang, YAO Yuangang. Research on network intrusion detection based on XGBoost [J]. Netinfo Security, 2018 (9): 102-105 (in Chinese). [张阳, 姚原岗. 基于 XGBoost 算法的网络入侵检测研究 [J]. 信息安全, 2018 (9): 102-105.]
- [8] Kaur S, Awasthi LK, Sangal AL, et al. Tunicate swarm algorithm: A new bio-inspired based metaheuristic paradigm for global optimization [J]. Engineering Applications of Artificial Intelligence, 2020, 90: 103541.
- [9] BAI Guozhen, JING Pengxiang. Trajectory planning of Delta manipulators based on modified gravitational [J]. Control Engineering of China, 2017, 24 (9): 1823-1828 (in Chinese). [白国振, 荆鹏翔. 基于改进引力搜索算法的 Delta 机械手轨迹规划 [J]. 控制工程, 2017, 24 (9): 1823-1828.]
- [10] Jia H, Peng X, Song W, et al. Multiverse optimization algorithm based on Lévy flight improvement for multithreshold color image segmentation [J]. IEEE Access, 2019, 7: 32805-32844.
- [11] Jiang Y, Tong G, Yin H, et al. A pedestrian detection method based on genetic algorithm for optimize XGBoost training parameters [J]. IEEE Access, 2019, 7: 118310-118321.
- [12] Darst BF, Malecki KC, Engelman CD. Using recursive feature elimination in random forest to account for correlated variables in high dimensional data [J]. BMC Genetics, 2018, 19 (1): 1-6.
- [13] Faris H, Aljarah I, Al-Betar MA, et al. Grey wolf optimizer: A review of recent variants and applications [J]. Neural Computing and Applications, 2018, 30 (2): 413-435.
- [14] Dhiman G, Kumar V. Seagull optimization algorithm: Theory and its applications for large-scale industrial engineering problems [J]. Knowledge-Based Systems, 2019, 165: 169-196.
- [15] Meftah S, Rachidi T, Assem N. Network based intrusion detection using the UNSW-NB15 dataset [J]. International Journal of Computing and Digital Systems, 2019, 8 (5): 478-487.
- [16] Vinayakumar R, Alazab M, Soman KP, et al. Deep learning approach for intelligent intrusion detection system [J]. IEEE Access, 2019, 7: 41525-41550.
- [17] Kasongo SM, Sun Y. Performance analysis of intrusion detection systems using a feature selection method on the UNSW-NB15 dataset [J]. Journal of Big Data, 2020, 7 (1): 1-20.
- [18] Khan NM, Madhav CN, Negi A, et al. Analysis on improving the performance of machine learning models using feature selection technique [C] //International Conference on Intelligent Systems Design and Applications. Springer, Cham, 2018: 69-77.
- [19] Zong W, Chow YW, Susilo W. A two-stage classifier approach for network intrusion detection [C] //International Conference on Information Security Practice and Experience. Springer, Cham, 2018: 329-340.
- [20] Belouch M, El Hadaj S, Idhammad M. A two-stage classifier approach using reptree algorithm for network intrusion detection [J]. International Journal of Advanced Computer Science and Applications, 2017, 8 (6): 389-394.
- [21] Gao J, Chai S, Zhang B, et al. Research on network intrusion detection based on incremental extreme learning machine and adaptive principal component analysis [J]. Energies, 2019, 12 (7): 1223.
- [22] Almogren AS. Intrusion detection in Edge-of-Things computing [J]. Journal of Parallel and Distributed Computing, 2020, 137: 259-265.
- [23] Jiang K, Wang W, Wang A, et al. Network intrusion detection combined hybrid sampling with deep hierarchical network [J]. IEEE Access, 2020, 8: 32464-32476.