

融合能量周期性递减与牛顿局部增强的改进HHO算法

赵世杰[†], 高雷阜, 于冬梅, 徒 君

- (1. 辽宁工程技术大学 优化与决策研究所, 辽宁 阜新 123000;
2. 辽宁工程技术大学 运筹与优化研究院, 辽宁 阜新 123000)

摘 要: 为增强栗翅鹰优化算法的全局探索能力和局部开采性能,提出一种融合能量周期性递减机制与牛顿局部增强策略的改进栗翅鹰优化算法(improved harris hawks optimization, IHHO). 该算法在传统HHO算法基础上,启发于自然界中鹰与猎物间的多轮围捕-逃逸现象且猎物能量整体上呈现递减态势,进而设计一种猎物能量的周期性递减调控因子并嵌入能量函数中,该机制有利于实现IHHO算法全局探索与局部搜索间的多轮动态迭代平衡. 牛顿局部增强策略借鉴牛顿迭代思想构造一种猎物邻域(当前最优解)的局部再搜索,并依概率实现IHHO算法的局部寻优性能改善. 数值实验验证了不同能量周期数和局部搜索次数对HHO算法性能的差异性影响、优越的并行迭代寻优性能以及高收敛精度、高维情形(100D~10 000D)的较好适用性.

关键词: 智能优化算法; 栗翅鹰优化算法; 能量周期性递减机制; 牛顿局部增强策略; 高维优化

中图分类号: TP391; TP301.6

文献标志码: A

DOI: 10.13195/j.kzyjc.2019.0810

开放科学(资源服务)标识码(OSID):



引用格式: 赵世杰,高雷阜,于冬梅,等. 融合能量周期性递减与牛顿局部增强的改进HHO算法[J]. 控制与决策, 2021, 36(3): 629-636.

Improved harris hawks optimization coupling energy cycle decline mechanism and Newton local enhancement strategy

ZHAO Shi-jie[†], GAO Lei-fu, YU Dong-mei, TU Jun

- (1. Institute of Optimization and Decision, Liaoning Technical University, Fuxin 123000, China; 2. Institute for Optimization and Decision Analytics, Liaoning Technical University, Fuxin 123000, China)

Abstract: To strengthen global exploration and local exploitation capacity of harris hawks optimization (HHO), an improved HHO (IHHO) algorithm is proposed by coupling the energy cycle decline mechanism and the Newton local enhancement strategy. On the basis of the canonical HHO algorithm, a control coefficient of the prey energy cycle decline mechanism is designed and absorbed into the original prey energy function, which inspires multi-round besiege-escaping phenomena between hawks and prey in nature. On the whole, the prey energy is declining with iterations. This mechanism contributes to dynamically balancing the global and local searching ability of HHO. Meanwhile, in consideration of better property of Newton iteration thought, a kind of Newton local reinforcement strategy is constructed for re-exploiting the local neighbourhood of prey (current optima), which results in improving the local searching performance of the IHHO algorithm with probability. Experimental results show the performance difference influence of different number of cycles and local searching on HHO, the superior parallel iterative optimization ability and convergence accuracy of the proposed algorithm, and its better applicability on high dimension cases (100D-10 000D).

Keywords: intelligence optimization algorithm; harris hawks optimization; energy cycle decline mechanism; Newton local enhancement strategy; high dimensional optimization

0 引 言

智能优化算法(intelligence optimization algorithm, IOA)是启发于特定自然现象的一类基于群体的随机优化技术,其以初值不敏感性、机理简单

易理解且不依赖于梯度信息等优点成为求解高维、非线性、复杂问题的一类重要算法,现已成功应用于机械优化设计^[1]、调度问题优配^[2]、函数寻优^[3-4]等领域. 目前,根据其启发机理的不同,IOA算法可以分为

收稿日期: 2019-06-07; 修回日期: 2019-08-22.

基金项目: 辽宁省科技厅博士科研启动基金项目(2019-BS-118, 20170520075); 国家自然科学基金项目(51704140); 辽宁省教育厅基金项目(LJ2019JL017, LJ2017QL031); 辽宁省自然科学基金指导计划项目(2019-ZD-0032).

[†]通讯作者. E-mail: zhaoshijie@lntu.edu.cn.

3类:基于遗传进化机制的进化规划、遗传算法等;模拟生物集群行为的粒子群优化算法、蚁群算法等;基于特定物理化学原理的模拟退火算法、多元宇宙优化算法^[5]等.同时新的IOA算法也不断被启悟并提出,如源于缎蓝亭鸟筑巢行为的缎鸟优化算法(SBO)^[6]、基于飞蛾向光性的蛾群算法(MSA)^[7]、模拟向日葵运动机制的向日葵优化算法(SFO)^[8]、参照生物神经系统的神经网络算法(NNA)^[9]、模仿蝴蝶觅食交配行为的蝴蝶优化算法(BOA)^[10]、仿拟分子动力学的原子搜索算法(ASO)等^[11].

栗翅鹰优化算法(harris hawks optimization, HHO)^[12]也是一种新的生物群集型IOA算法,源于栗翅鹰围捕猎物时的协作行为,通过模型化鹰的俯冲围捕、猎物能量减弱等启发机制被构造并提出.

HHO算法中,猎物能量的大小反映栗翅鹰对问题最优解的捕获能力,能量越大猎物越易逃脱鹰的围捕,反之越易被捕获.传统HHO算法中猎物的能量从最大值到最小值线性递减并依概率被捕获,但该模式并不能较好地反映自然界中鹰与猎物间的多轮围捕-逃逸过程.鉴于此,为模拟该过程而创新性地提出猎物能量的周期性递减调控机制,并与所提出的牛顿局部增强策略相融合进而提出一种改进HHO算法(improved HHO, IHHO).数值实验验证了改进算法的优越并行寻优性能及其高维问题寻优适用性.

1 栗翅鹰优化算法(HHO)

HHO算法是Heidari等^[12]受栗翅鹰捕捉逃跑猎物时的行为启发所提出的一种IOA算法,在并行迭代搜索过程中,栗翅鹰代表优化问题的可行解,猎物代表问题最优解并随迭代越趋逼近于理论最优解.

初始化时,栗翅鹰随机栖息在搜索空间 $[lb, ub]$ 的某位置并伺机观察围捕猎物;迭代时,根据其他个体与猎物的位置以概率 p 选择性更新,对应表达为

$$X(t+1) = \begin{cases} X_d(t) - r_1|X_d(t) - 2r_2X(t)|, & p \geq 0.5; \\ (X_t(t) - X_m(t)) - r_3(lb + r_4(ub - lb)), & \text{otherwise.} \end{cases} \quad (1)$$

其中: $X(t+1)$ 、 $X(t)$ 分别为第 $t+1$ 次和第 t 次迭代时栗翅鹰的位置, X_t 、 X_d 分别为猎物和随机选中的栗翅鹰个体的位置, $r_i(i=1,2,3,4)$ 和 p 均为 $[0,1]$ 内的随机数, $X_m = \sum_{i=1}^N X_i(t)/N$ 为第 t 次迭代时栗翅鹰种群中 N 个个体的平均位置.

迭代搜索过程中,猎物能量 E 线性动态递减以调控算法的全局探索和局部开采性能,定义为

$$E = 2E_0 \left(1 - \frac{t}{T}\right). \quad (2)$$

其中: T 为最大迭代次数, E_0 为 $(-1,1)$ 内的能量迭代初始值.当 $|E| \geq 1$ 时,HHO算法执行全局探索过程,表示猎物在整个解空间中逃逸;当 $|E| < 1$ 时,HHO算法搜索解邻域执行局部开采过程.此外,HHO算法通过因子 $\beta \in [0,1]$ 描述猎物是否逃脱成功,当 $\beta < 0.5$ 时表示猎物逃脱成功,反之则失败.同时,栗翅鹰根据猎物能量 E 与0.5的相对大小采取两种不同的围捕策略,包含4种情形:

1) 软围捕.当 $\beta \geq 0.5$ 且 $|E| \geq 0.5$ 时,猎物的能量 E 始终充沛并以随机跳跃的方式试图逃脱围捕,但最终失败并被捕获.鹰的位置更新式为

$$X(t+1) = \Delta X(t) - E|JX_t(t) - X(t)|. \quad (3)$$

其中: $\Delta X(t) = X_t(t) - X(t)$ 表示第 t 次迭代时鹰与猎物的位置偏差; $J = 2(1 - r_5)$ 表示猎物逃跑时的随机跳跃强度, $r_5 \in (0,1)$ 为一个随机数.

2) 硬围捕.当 $\beta \geq 0.5$ 且 $|E| < 0.5$ 时,猎物的能量 E 较低而被鹰直接捕获,其位置表达式为

$$X(t+1) = X_t(t) - E|\Delta X(t)|. \quad (4)$$

3) 累速俯冲式软围捕.当 $\beta < 0.5$ 且 $|E| \geq 0.5$ 时,猎物能量 E 充沛可保证逃脱成功,但鹰仍以最优方向俯冲并软围捕猎物,其位置更新式为

$$X(t+1) = \begin{cases} Y : X_t(t) - E|JX_t(t) - X(t)|, & f(Y) < f(X(t)); \\ Z : Y + S \times \text{LF}(D), & f(Z) < f(X(t)). \end{cases} \quad (5)$$

其中: D 为问题维度, S 为 D 维随机行向量,LF为文献[13]中的Levy函数, $<$ 为目标值更优.

4) 累速俯冲式硬围捕.当 $\beta < 0.5$ 且 $|E| < 0.5$ 时,猎物能量 E 较低,鹰俯冲并硬围捕猎物以减小与猎物的平均距离,其位置更新式为

$$X(t+1) = \begin{cases} Y : X_t(t) - E|JX_t(t) - X_m(t)|, & f(Y) < f(X(t)); \\ Z : Y + S \times \text{LF}(D), & f(Z) < f(X(t)). \end{cases} \quad (6)$$

HHO算法以能量 E 调控搜索进程,携因子 β 刻画鹰-猎物间的4种围捕机制,以实现问题优化求解.

2 改进栗翅鹰优化算法(IHHO)

2.1 能量周期性递减调控机制

HHO算法中,猎物能量 E 的大小反映栗翅鹰对问题最优解的搜寻捕获能力, E 越大表示HHO算法越易于进行全局探索,反之则越易于执行局部开采。但传统HHO算法中 E 由最大值到最小值单周期线性递减,并不能有效描述自然界中栗翅鹰群体需经多轮协同围捕并最终捕获猎物的现象,因此,为数学化栗翅鹰与猎物间的多轮“围捕-逃逸”现象,以猎物能量 E 的周期性递减特征来刻画这种博弈多轮性,进而提出能量周期性递减调控机制:栗翅鹰围捕并最终捕获猎物的轮次数以能量 E 的递变周期数来表示; E 周期性趋于0则反映栗翅鹰围捕逼近并依概率捕获猎物,进而实现待优化问题的多轮“全局+局部”寻优搜索。本文以余弦函数刻画该机制下猎物能量 E 的周期递变性,对应的能量定义为

$$E = 2E_0 \left(1 - \frac{t}{T}\right) \cdot \cos\left(\left(2k + \frac{1}{2}\right)\pi \frac{t}{T}\right), \quad (7)$$

其中 $k = 0, 1, \dots$ 为猎物能量 E 的递减周期数。

图1为能量 E 递减周期数 $k = 4$ 时栗翅鹰成功捕获猎物的直观示意图(虚线上的数为猎物在该等高线上的能量值)。由图1可知,猎物在搜索空间逃跑过程中能量整体呈周期递减趋势,并以寻求遮蔽物来避开鹰的围捕,猎物前3次均逃脱成功但第4次终被鹰依概率成功捕获,即算法迭代并寻得问题最优解。




图1 能量周期性递减机制下栗翅鹰成功捕获猎物示意

能量周期性递减调控机制中,周期数 k 调控猎物能量 E 的周期性递减变化,并以此实现HHO算法在全局探索与局部开采性能间的多轮交替性转换。周期数 k 越大,HHO在全局探索与局部开采间的性能转换越频繁且更偏重于局部搜索;相反, k 越小则其更偏重于全局搜索。因此,周期数 k 需要合理设定以平衡HHO算法的全局探索和局部开采性能。

2.2 牛顿局部增强策略

HHO算法中,猎物代表栗翅鹰种群并行搜索所得的当前最优解,同时它又反向引导着鹰栖息位置的

进化更新,直接决定着算法的迭代寻优性能。因此,为进一步增强算法的局部开采能力,需要对猎物位置的微小邻域进行再开采,以期寻得更优解。

鉴于牛顿迭代法^[14]对最优解邻域较强的局部收敛性和较高的收敛效率,基于该思想构造一种适定的牛顿局部增强策略以增强算法的局部开采性能。为延续IOA算法对优化问题凸性、可微、可导等特殊要求的特性,以函数两点间的斜率作为其导数的近似替代,构造该策略下的位置更新式为

$$X_{i+1} = X_i - \lambda \frac{f(X_i)}{f(X_i) - f(X_{i-1})} \Delta X_i, \quad (8)$$

$$i = 1, 2, \dots, n.$$

其中: X_i 和 X_{i+1} 分别为第 i 次和第 $i+1$ 次再搜索时栗翅鹰的新位置; $\Delta X_i = X_i - X_{i-1}$ 为第 i 次和第 $i-1$ 次位置的向量差; $f(\cdot)$ 为目标函数值; n 为该策略下的局部再搜索次数; λ 为权重递减因子,采用牛顿下山法中的因子定义式 $\lambda = (1/2)^{i-1}$ 。特别地,当 $i = 1$ 时, X_1 表示当前迭代 t 时猎物位置 $X(t)$ 而 X_0 为 $t-1$ 次迭代时猎物位置 $X(t-1)$ 。

根据最优原则更新猎物位置定义为

$$X_t = \begin{cases} X_{i+1}, & f(X_{i+1}) < f(X_t); \\ X_t, & \text{otherwise.} \end{cases} \quad (9)$$

图2为基于牛顿局部增强策略的猎物位置再开采示意图(以 $n = 3$ 为例)。由图2可见,该策略可增强对最优解(猎物位置)邻域的再搜索并以概率寻得更优解,同时依据两次相邻最优解的位置向量更新位置在一定程度上可增加算法跳出局部极值的可能性。




图2 牛顿局部搜索策略下局部再开采示意

2.3 改进算法的执行流程

将上述能量周期性递减调控机制与牛顿局部增强策略相融合,进而提出一种改进的HHO算法(improved HHO, IHHO),以增强HHO算法的全局搜索性能和局部开采性能,其具体执行伪码如下。

算法1 IHHO算法。

输入: 栗翅鹰数 N 、最大迭代数 T 、周期数 k 、再搜索次数 n ;

输出: 最优解 x^* (猎物位置)、最优适应度值 $f(x^*)$ 。

1) 在解空间 $[lb, ub]$ 中随机初始化 N 只栗翅鹰,

得初始种群 X

- 2) while 当前迭代次数 $t < T$
- 3) 按周期数 k 和式(7)更新猎物能量 E
- 4) if $|E| \geq 1$ //执行探索过程
- 5) 按式(1)更新栗翅鹰种群个体的位置
- 6) else if $|E| < 1$ //执行开采过程
- 7) 按式(3)~(6)更新栗翅鹰个体位置
- 8) end if
- 9) 计算栗翅鹰适应度值 $f(x)$, 并按最优原则更新猎物位置 x^*
- 10) if $t < 1$
- 11) 保存第1次迭代时的最优解 x^* 及其适应度值 $f(x^*)$
- 12) else
- 13) 扩增 x^* 与 $f(x^*)$ 序列, 并按式(8)执行 n 次局部再搜索

- 14) 按最优原则更新当代 x^* 、 $f(x^*)$ 及猎物位置
- 15) end if
- 16) $t = t + 1$
- 17) end while
- 18) return x^* 与 $f(x^*)$

3 数值实验

为验证 IHHO 算法的优越寻优性能, 共进行4组实验: 实验1和实验2分别以4组测试函数探究能量周期数 k 和局部再搜索次数 n 对 HHO 性能改善的有效性和影响差异性; 实验3以6种新近 IOA 算法为对比验证 IHHO 并行寻优能力的优越性; 实验4进一步验证函数高维情形下 IHHO 算法的良好适用性。

4组测试函数的基本信息见表1, 其中 f_1 和 f_2 为单峰函数且 f_3 和 f_4 为多峰函数, 分别测试算法的局部开采性能和全局探索性能等。

表1 基准测试函数

函数名	表达式	变量区间	最优解	最优值	单/多峰
High Conditioned Elliptic	$f_1(x) = \sum_{i=1}^D (10^6)^{\frac{i-1}{D-1}} x_i^2$	$[-100, 100]$	$(0, 0, \dots, 0)$	0	单峰
Schwefel2.22	$f_2(x) = \sum_{i=1}^D x_i + \prod_{i=1}^D x_i $	$[-10, 10]$	$(0, 0, \dots, 0)$	0	单峰
Alpine	$f_3(x) = \sum_{i=1}^D x_i \sin(x_i) + 0.1x_i $	$[-10, 10]$	$(0, 0, \dots, 0)$	0	多峰
Salomon	$f_4(x) = 1 - \cos\left(2\pi\sqrt{\sum_{i=1}^D x_i^2}\right) + 0.1\sqrt{\sum_{i=1}^D x_i^2}$	$[-100, 100]$	$(0, 0, \dots, 0)$	0	多峰

3.1 能量周期性递减机制的性能分析实验

为测试能量周期递减机制对 HHO 算法性能改善的有效性, 以周期 k 取0、1和2进行实验, 并分别记为 HHO-PD0、HHO-PD1 和 HHO-PD2. 实验参数同文献[12]: 栗翅鹰数 N 为30, 最大迭代次数 T 为500, 函数维度 D 为30. 为保证算法性能评价的客观性, 各实验组均独立运行30次, 并以30次实验结果的平均值(mean)、标准差(std)、最优值(best)和最劣值(worst)作为评价指标, 所得统计结果见表2.

由表2分析可知: 能量周期递减机制的不同周期 k 影响 HHO 算法的迭代寻优能力, 且与 HHO 算法相较其性能各具优劣. HHO-PD2 算法的4项指标在4组函数上均显著优于传统 HHO 算法, 但 HHO-PD0 和 HHO-PD1 的指标值均弱于 HHO 且以周期 $k = 1$ 时性能最弱. 同时, 图3以30次实验平均适应度值的迭代对比进一步直观展示了4种算法的优化进程差异, 上述结果表明, HHO-PD2 具有显著优越的寻优精度和不同周期 k 对 HHO 性能改善的差异性影响.

表2 不同周期 k 的 HHO 算法性能对比结果(30D)

		HHO	HHO-PD0	HHO-PD1	HHO-PD2
f_1	mean	4.115e-93	6.633e-71	3.438e-56	5.935e-102
	std	1.855e-92	2.509e-70	1.351e-55	3.176e-101
	worst	1.006e-91	1.145e-69	6.758e-55	1.740e-100
	best	2.319e-108	6.756e-92	1.004e-72	4.222e-134
f_2	mean	3.173e-51	3.715e-39	5.300e-33	1.266e-59
	std	9.827e-51	1.942e-38	1.277e-32	5.418e-59
	worst	4.149e-50	1.065e-37	5.091e-32	2.966e-58
	best	4.431e-58	1.459e-49	1.671e-40	2.201e-70
f_3	mean	1.562e-52	3.234e-41	1.064e-25	6.182e-57
	std	5.897e-52	1.388e-40	5.797e-25	3.296e-56
	worst	3.025e-51	7.536e-40	3.176e-24	1.806e-55
	best	2.568e-58	5.012e-54	3.114e-41	4.187e-72
f_4	mean	7.859e-51	9.748e-40	5.180e-31	2.890e-54
	std	2.736e-50	3.850e-39	1.826e-30	1.564e-53
	worst	1.490e-49	2.096e-38	8.419e-30	8.570e-53
	best	3.817e-56	2.651e-46	7.588e-49	2.908e-67





图3 HHO算法平均适应度值的对数对比曲线

为进一步探究HHO-PD算法中周期 k 对HHO性能改善的潜在影响,以 $k \in \{0, 1, 2, \dots, 20\}$ 各进行30次实验,并以其mean值绘制对比曲线如图4所示。

由图4分析可知:HHO-PD k 的寻优精度随周期 k 的不同呈波动变化态势,在周期 k 取相邻奇-偶数时性能近似呈“V”型变化,即偶数周期的HHO-PD k 性能相对优于相邻奇数周期;当周期 $k \geq 2$ 时,HHO-PD k 的平均性能几乎均优于传统HHO算法,且以 $k = 6$ 时性能表现最优,统计结果见表3。


由表2和表3统计结果对比可知:HHO-PD6的性能均优于HHO-PD2,且更显著优于HHO算法,即周期 $k = 6$ 时HHO-PD k 的性能在HHO-PD2的基础上又提升了几十个数量级,进一步验证了本文所提出能量周期递减调控策略的有效性。鉴于HHO-PD6算法的出色性能,后续IHHO实验中将设 $k = 6$ 。

图4 不同周期 k 的HHO算法性能对比表3 周期 k 为6时HHO-PD算法的实验统计结果(30D)

	f_1	f_2	f_3	f_4
mean	1.454e-124	2.523e-67	3.008e-67	8.769e-66
std	6.441e-124	1.070e-66	1.081e-66	1.941e-65
worst	3.515e-123	5.821e-66	5.370e-66	8.314e-65
best	1.695e-149	1.885e-84	4.822e-87	3.784e-83

3.2 牛顿局部增强策略的性能分析实验

为检验牛顿局部增强策略对HHO算法性能改善的有效性,以局部搜索数 $n \in \{1, 2, \dots, 20\}$ 和30D测试函数为实验对象,相应算法记为HHO-LS n ,实验参

图5 不同局部搜索次数 n 的HHO算法性能对比

数同3.1节,各实验均独立运行30次并以其逐代平均适应度值绘制HHO-LS n 性能对比曲线如图5所示.

由图5可知:HHO-LS n 算法的搜索精度随局部搜索次数 n 呈非线性变化,且在 $n \geq 3$ 时HHO-LS n 算法性能几乎均优于HHO算法,在 $n = 4$ 时HHO-LS n 性能相对较好.局部再搜索次数 n 的增大,必会导致

表4 HHO-LS4与HHO算法的性能对比

		mean	std	worst	best
f_1	HHO	4.115e-93	1.855e-92	1.006e-91	2.319e-108
	HHO-LS4	6.754e-134	3.695e-133	2.024e-132	1.003e-163
f_2	HHO	3.173e-51	9.827e-51	4.149e-50	4.431e-58
	HHO-LS4	4.585e-91	2.511e-90	1.375e-89	0
f_3	HHO	1.562e-52	5.897e-52	3.025e-51	2.568e-58
	HHO-LS4	5.735e-81	3.141e-80	1.720e-79	0
f_4	HHO	7.859e-51	2.736e-50	1.490e-49	3.817e-56
	HHO-LS4	1.385e-80	7.534e-80	4.127e-79	0

算法时间复杂度的增加,但只可能依概率改善HHO-LS n 的寻优精度,因此,为平衡HHO-LS n 算法的时间复杂度与优化性能,选用 $n = 4$ 作为后续IHHO实验的设置,统计结果见表4.

由表4分析可知:HHO-LS4算法在4组函数上均寻得最优指标,且优于HHO算法达30个数量级,特别是 $f_1 \sim f_4$ 的best值均已达最优.上述结果表明牛顿局部搜索策略对改善HHO算法寻优性能是有效的.

3.3 与其他新近IOA算法的性能对比实验

为验证IHHO算法的优异性能,以新近的IOA算法SBO^[6]、MSA^[7]、SFO^[8]、NNA^[9]、ASO^[10]、BOA^[11]和HHO^[12]作为对比算法,以4组50D函数为实验对象各进行30次独立实验.各实验组的种群规模 N 和最大迭代次数 T 仍为30和500,各算法的其他参数设置同原文献.30次实验的统计结果见表5.

表5 不同周期的HHO算法性能对比结果(50D)

		SBO	MSA	SFO	NNA	ASO	BOA	HHO	IHHO
f_1	mean	2.504e+4	2.243e-121	2.744e+4	7.135e+1	1.417e+6	2.862e-7	1.480e-92	3.369e-166
	std	1.237e+4	1.146e-120	3.166e+4	5.552e+1	8.781e+5	1.077e-7	7.155e-92	0
	worst	5.917e+4	6.290e-120	1.012e+5	2.432e+2	3.659e+6	5.013e-7	3.909e-91	1.011e-164
	best	1.041e+4	8.956e-139	8.895	1.354e+1	3.463e+5	1.039e-7	2.232e-111	7.465e-213
f_2	mean	5.822e-1	3.926e-63	1.222	1.839e-2	2.532	1.094e+23	1.175e-51	1.056e-133
	std	8.059e-2	2.060e-62	7.757e-1	6.339e-3	1.708	2.688e+23	3.839e-51	5.786e-133
	worst	7.467e-1	1.129e-61	2.655	3.371e-2	5.761	1.062e+24	1.951e-50	3.169e-132
	best	3.855e-1	1.198e-71	1.207e-1	4.465e-3	3.605e-2	2.860	3.722e-58	0
f_3	mean	4.145e-1	7.474e-65	2.490e-1	5.853	2.508e-1	4.091e-5	6.485e-52	2.543e-133
	std	1.004e-1	4.023e-64	1.774e-1	2.324	4.164e-1	9.174e-6	3.055e-51	1.392e-132
	worst	6.334e-1	2.205e-63	8.753e-1	1.486e+1	1.744	6.341e-5	1.679e-50	7.626e-132
	best	2.286e-1	3.346e-72	3.079e-2	1.730	8.107e-3	2.521e-5	4.577e-60	0
f_4	mean	1.754	6.918e-55	1.252	6.648e-1	4.254	9.990e-2	1.060e-49	2.010e-110
	std	4.798e-1	3.786e-54	5.383e-1	1.658e-1	6.831e-1	4.360e-5	3.458e-49	1.101e-109
	worst	3.306	2.074e-53	2.512	8.999e-1	5.500	1.001e-1	1.488e-48	6.031e-109
	best	1.104	3.064e-68	2.277e-1	2.999e-1	2.900	9.987e-2	7.076e-64	0

由表5分析可知:IHHO算法在4组函数上均显著优于其他对比算法,在同等种群规模和迭代次数条件下4项指标值均高出数十甚至上百个数量级,有效佐证了IHHO算法优越的并行寻优性能.最优mean值表明IHHO算法在重复实验中均寻得较优的单次精度且整体平均性能高;最优std值验证了改进HHO的良好算法稳健性;最优best值表明改进算法对问题解空间的充分探索和开采并以高精度寻得全局最优解;最优worst值暗示着IHHO算法在极端情境中仍保持高精度且高达1.0e-100,该值远优于其他算法的best值,表明IHHO算法在无先验知识领域中也保持较好的潜在适用性并依概率寻得更优的问题解.在同等实验情境下,IHHO算法对单-多峰函数均寻得最优精度,表明改进算法具有更强的局部开采能

力和收敛精度.同时,改进算法对多峰函数也可捕获问题最优值,表明其具有良好的全局搜索能力和局部极值规避性.

图6为8种算法平均适应度值的迭代对比曲线.由图6可知,不同算法在各测试函数上的动态迭代进程各不相同且以IHHO算法的性能表现最优.IHHO算法在迭代前期便表现出较高的搜索精度,这种优势持续保持到最大迭代次数并最终寻得更优目标值;即使在迭代前期陷入局部极值的情形下,IHHO算法仍能在后期成功逃逸并寻得更优值,而其他算法则几乎均丧失逃逸能力且增加迭代次数也难以得到有效改善.上述分析进一步表明IHHO算法较高的收敛精度及其在30次实验中良好的并行寻优同步性.




图6 8种算法的平均适应度值的对数迭代对比

3.4 高维情形下的性能分析实验

为进一步探究 IHHO 算法对高维问题的优化适用性,以 HHO 算法作为对比,分别对 100D、500D、1000D 和 10000D 函数各进行 30 次实验,种群规模 N 和最大迭代次数 T 分别为 40+500、50+1000、50+1500 和 50+2000,实验统计结果见表 6。

由表 6 分析可知:不同函数维度 D 下算法的寻优精度各不相同.在函数维度递增过程中,IHHO 算法随种群规模 N 和最大进化次数 T 的增加呈精度增强趋势,4 项指标值均优于 HHO 算法达几十到上百个数量级,表明 IHHO 算法的有限进化次数 ($N \times T$) 增

加能够更好地同步跟踪函数维度增加所导致的问题优化难度增加,并寻得更优的收敛精度.在 1000D 情形,HHO 算法的 best 值已高达 $1.0e-158$,而 IHHO 算法在 HHO 高精度的基础上仍可进一步提升 4 项指标值,均高达 $1.0e-210$;对 10000D 而言,IHHO 算法的寻优精度则高达 $1.0e-233$,该精度能较好地满足高维工程优化问题的误差限要求.上述结果有效证明了 IHHO 算法的强劲高维问题适用性。

综上所述,IHHO 算法具有优越的全局搜索性能和局部极值规避性等,对高维情形仍保持良好的适用性,有效验证了改进 HHO 算法优越的寻优性能。

表6 IHHO与HHO算法的高维性能对比统计

D	HHO				IHHO				
	mean	std	worst	best	mean	std	worst	best	
f_1	100	6.391e-91	3.362e-90	1.843e-89	5.879e-110	4.718e-172	0	1.415e-170	8.019e-214
	500	2.969e-182	0	8.874e-181	1.417e-208	2.099e-234	0	6.297e-233	4.321e-270
	1 000	7.277e-278	0	2.183e-276	8.861e-308	0	0	0	0
	10 000	0	0	0	0	0	0	0	
f_2	100	1.527e-52	6.105e-52	3.318e-51	1.800e-61	2.233e-129	1.178e-128	6.455e-128	0
	500	4.407e-99	2.265e-98	1.241e-97	2.602e-110	7.756e-175	0	2.242e-173	8.196e-202
	1 000	5.874e-148	1.953e-147	9.454e-147	5.507e-159	1.362e-213	0	2.284e-212	3.390e-238
	10 000	3.629e-196	0	3.627e-195	4.529e-209	2.823e-234	0	7.037e-233	8.724e-269
f_3	100	2.316e-52	7.935e-52	3.421e-51	7.964e-63	3.220e-130	1.764e-129	9.661e-129	7.376e-175
	500	4.256e-100	2.095e-99	1.148e-98	4.574e-113	1.434e-174	0	4.303e-173	6.968e-213
	1 000	4.149e-144	2.272e-143	1.245e-142	7.533e-162	1.124e-211	0	3.372e-210	1.038e-236
	10 000	1.289e-195	0	3.658e-194	6.688e-210	1.627e-235	0	3.396e-234	7.779e-267
f_4	100	5.039e-51	1.296e-50	5.373e-50	5.561e-58	2.648e-113	1.449e-112	7.939e-112	0
	500	1.774e-95	9.356e-95	5.128e-94	5.877e-111	0	0	0	0
	1 000	4.505e-143	2.452e-142	1.343e-141	4.390e-158	0	0	0	0
	10 000	0	0	0	0	0	0	0	

4 结 论

栗翅鹰优化算法(HHO)是受自然界中鹰围捕猎物时群体协作行为启发而提出的一种智能优化算法. 为进一步改善HHO算法的并行迭代搜索性能, 本文将自然界中鹰与猎物间的多轮围捕-逃跑过程引入传统HHO算法, 并数学化表达提出一种猎物能量周期性递减机制, 以动态平衡算法的全局探索与局部开采性能. 同时基于牛顿迭代思想提出一种牛顿局部增强策略, 以强化算法的局部开采能力, 进而融合两种策略提出一种改进HHO算法(IHHO). 数值结果表明, 猎物能量的不同递减周期数和局部牛顿搜索次数均差异性影响着HHO算法的优化性能; 相较于其他智能对比算法, IHHO算法表现出优越的全局寻优性能、强劲的算法稳健性和良好的局部极值规避性等; 同时在 $100D \sim 10\,000D$ 情形, 改进算法表现出较好的高维适用性和高收敛精度等. 接下来的工作主要是拓展IHHO算法的应用领域并验证其实际应用性能, 如多目标问题的高维优化、深度神经网络的结构超参数优化等.

参考文献(References)

- [1] Callegaro L, Ciobotaru M, Pagano D J, et al. Control design for photovoltaic power optimizers using bootstrap circuit[J]. IEEE Transactions on Energy Conversion, 2019, 34(1): 232-242.
- [2] Milan S T, Rajabion L, Ranjbar H, et al. Nature inspired meta-heuristic algorithms for solving the load-balancing problem in cloud environments[J]. Computers & Operations Research, 2019, 110: 159-187.
- [3] 赵世杰, 高雷阜, 于冬梅, 等. 基于变因子加权学习与邻代维度交叉策略的改进CSA算法[J]. 电子学报, 2019, 47(1): 40-48.
(Zhao S J, Gao L F, Yu D M, et al. Improved crow search algorithm based on variable-factor weighted learning and adjacent-generations dimension crossover strategy[J]. Acta Electron Sinica, 2019, 47(1): 40-48.)
- [4] 赵世杰, 高雷阜, 徒君, 等. 耦合横纵向个体更新策略的改进MVO算法[J]. 控制与决策, 2018, 33(8): 1422-1428.
(Zhao S J, Gao L F, Tu J, et al. Improved multi verse optimizer coupling horizontal-and-vertical individual updated strategies[J]. Control and Decision, 2019, 33(8): 1422-1428.)
- [5] Mirjalili S, Mirjalili S M, Hatamlou A. Multi-verse Optimizer: A nature-inspired algorithm for global optimization[J]. Neural Computing and Applications, 2016, 27(2): 495-513.
- [6] Moosavi S H S, Bardsiri V K. Satin bowerbird optimizer: A new optimization algorithm to optimize anfis for software development effort estimation[J]. Engineering Applications of Artificial Intelligence, 2017, 60: 1-15.
- [7] Mohamed A A A, Mohamed Y S, El-Gaafary A A M, et al. Optimal power flow using moth swarm algorithm[J]. Electric Power Systems Research, 2017, 142: 190-206.
- [8] Gomes G F, da Cunha S S, Ancelotti A C. A sunflower optimization(SFO) algorithm applied to damage identification on laminated composite plates[J]. Engineering with Computers, 2019, 35(2): 619-626.
- [9] Sadollah A, Sayyaadi H, Yadav A. A dynamic metaheuristic optimization model inspired by biological nervous systems: Neural network algorithm[J]. Applied Soft Computing, 2018, 71: 747-782.
- [10] Arora S, Singh S. Butterfly optimization algorithm: A novel approach for global optimization[J]. Soft Computing, 2019, 23(3): 715-734.
- [11] Zhao W G, Wang L Y, Zhang Z X. Atom search optimization and its application to solve a hydrogeologic parameter estimation problem[J]. Knowledge-Based Systems, 2019, 163: 283-304.
- [12] Heidari A A, Mirjalili S, Faris H, et al. Harris hawks optimization: Algorithm and applications[J]. Future Generation Computer Systems, 2019, 97: 849-872.
- [13] Yang X S. Nature-inspired metaheuristic algorithms[M]. Beckington: Luniver Press, 2010: 14-17.
- [14] 曾繁慧. 数值分析[M]. 徐州: 中国矿业大学出版社, 2009: 25-30.
(Zeng F H. Numerical analysis[M]. Xuzhou: China Univesity of Mining and Technology Press, 2009: 25-30.)

作者简介

赵世杰(1987—), 男, 讲师, 博士, 从事智能优化与计算、机器学习与数据解析等研究, E-mail: zhaoshijie@lntu.edu.cn;

高雷阜(1963—), 男, 教授, 博士生导师, 从事最优化理论与方法等研究, E-mail: gaoleifu@163.com;

于冬梅(1986—), 女, 副教授, 博士, 从事最优化理论与方法等研究, E-mail: yudongmei@lntu.edu.cn;

徒君(1982—), 男, 副教授, 博士, 从事智能优化与供应链管理研究, E-mail: tujun@lntu.edu.cn.

(责任编辑: 郑晓蕾)